Econometria I Álgebra dos Mínimos Quadrados

Victor Oliveira

Núcleo de Economia Internacional e Desenvolvimento Econômico

PPGDE - 2023

Sumário



- Amostra Aleatória
- Mínimos Quadrados Ordinários
- 3 Método dos Momentos
- 4 Resíduos dos Mínimos Quadrados Ordinários
- Notação Matricial
- 6 Matriz de Projeção
- 🕜 Projeção Ortogonal
- 8 Estimação da Variância do Erro
- 9 Análise da Variância
- Omponentes da Regressão
- 🕕 Resíduos da Regressão
- Regressão de Mínimos Quadrados

Amostra Aleatória



- O melhor preditor de y dado x para um par de variáveis aleatórias $(y, x) \in \mathbb{R} \times \mathbb{R}^k$ é o modelo de projeção linear.
- Agora estamos interessados em **estimar** os parâmetros desse modelo, em particular o **coeficiente de projeção**

$$\beta = \left[\mathbb{E} \left(\boldsymbol{x} \boldsymbol{x}' \right) \right]^{-1} \mathbb{E} (\boldsymbol{x} \boldsymbol{y}) \tag{1}$$

- Podemos estimar β usando amostras que incluem medidas conjunta de (y, x).
- \bullet Vamos diferenciar observações (realizações) das variáveis aleatórias.
- Variáveis aleatórias são (y, \boldsymbol{x}) , enquanto as observações são (y_i, \boldsymbol{x}_i) .
- Do ponto de vista do pesquisador, os últimos são números. Do ponto de vista da teoria estatística elas são realizações de variáveis aleatórias.

- Notação: Para observações individuais, vamos usar um subscrito i que vai de 1 a n, portanto, a i-ésima observação é (y_i, x_i) . O número n é o tamanho da amostra.
- Definição: Uma amostra aleatória é dada pelas observações

$$\{(y_1, x_1), (y_2, x_2), \dots, (y_i, x_i), \dots, (y_n, x_n)\}\$$
 (2)

- De forma mais simplificada temos $\{(y_i, x_i) : i = 1, ..., n\}$.
- As observações individuais podem ser extraídas de uma distribuição comum (homogênea) ou podem ser extraídas de distribuições heterogêneas. A abordagem mais simples é assumir a homogeneidade – que as observações são realizações de uma população subjacente idêntica.

Pressuposto

As variáveis $\{(\boldsymbol{y}_1, \boldsymbol{x}_1), (\boldsymbol{y}_2, \boldsymbol{x}_2),, (\boldsymbol{y}_i, \boldsymbol{x}_i), ..., (\boldsymbol{y}_n, \boldsymbol{x}_n)\}$ são identicamente distribuídas e são retirados de uma distribuição comum F.

- Vamos nos referir à distribuição comum F como sendo a **população**.
- O modelo de projeção linear se aplica as variáveis aleatórias (y, x). É o modelo de probabilidade que descrevemos anteriormente como o melhor preditor linear.

Critério de Otimização



 O análogo empírico da esperança do erro ao quadrado é o erro quadrático médio amostral:

$$S_n(\beta) = \frac{1}{n} \sum_{i=1}^n (y_i - x_i' \beta)^2$$
$$= \frac{1}{n} SQE_n(\beta)$$
(3)

em que $SQE_n(\beta) = \sum_{i=1}^n (y_i - x_i'\beta)$ é chamada de **função da** soma dos quadrados dos erros. Um estimador para β é obtido pela minimização da função $S_n(\beta)$:

$$\widehat{\boldsymbol{\beta}} = \underset{\boldsymbol{\beta} \in \mathbb{R}^k}{\operatorname{arg\,min}} S_n(\boldsymbol{\beta}) \tag{4}$$

Estimador de MQO



- O $\hat{\beta}$ é conhecido como o estimador de **Mínimos Quadrados** Ordinários (MQO) de β .
- Distinção: o parâmetro populacional β é fixo na população, enquanto o estimador $\hat{\beta}$ varia entre as amostras.

Caso Univariado



- Considere o caso de k=1 tal que o coeficiente de β é um escalar.
- Assim, a SQE é dada por:

$$SQE_n(\beta) = \sum_{i=1}^{n} (y_i - x_i \beta)^2$$

$$= \left(\sum_{i=1}^{n} y_i^2\right) - 2\beta \left(\sum_{i=1}^{n} y_i x_i\right) + \beta^2 \left(\sum_{i=1}^{n} x_i^2\right)$$
(5)

• O estimador de MQO minimiza esta função.

• Assim, o resultado da minimização do $SQE_n(\beta)$ é:

$$\widehat{\beta} = \frac{\sum_{i=1}^{n} y_i x_i}{\sum_{i=1}^{n} x_i^2}$$
(6)

• O modelo com apenas o intercepto é um caso especial de $x_i = 1$. Neste caso encontramos:

$$\hat{\beta} = \frac{\sum_{i=1}^{n} y_i}{\sum_{i=1}^{n} 1} = \frac{1}{n} \sum_{i=1}^{n} y_i = \overline{y}$$
 (7)

que é a média de y_i .

- Por esse resultado, o estimador de MQO num modelo com apenas o intercepto é a média amostral.
- O estimador $\hat{\beta}$ existe apenas se o denominador é não-zero. Por ser uma soma dos quadrados, necessariamente é não-negativo.

Portanto, $\hat{\beta}$ existe se $\sum x_i^2 > 0$.

Caso Multivariado



- Considere o caso de k>1 tal que o coeficiente de $\boldsymbol{\beta}$ agora é um vetor.
- Assim, a SQE é dada por:

$$SQE_n(\boldsymbol{\beta}) = \left(\sum_{i=1}^n y_i^2\right) - 2\boldsymbol{\beta}' \left(\sum_{i=1}^n y_i \boldsymbol{x}_i\right) + \boldsymbol{\beta}' \left(\sum_{i=1}^n \boldsymbol{x}_i \boldsymbol{x}_i'\right) \boldsymbol{\beta} \quad (8)$$

• A CPO para minimização de $SQE_n(\beta)$ é:

$$\frac{\partial}{\partial \boldsymbol{\beta}} SQE_n(\widehat{\boldsymbol{\beta}}) = \mathbf{0} \quad \Longleftrightarrow \quad = -2\sum_{i=1}^n \boldsymbol{x}_i y_i + 2\sum_{i=1}^n \boldsymbol{x}_i \boldsymbol{x}_i' \widehat{\boldsymbol{\beta}}$$
 (9)

• Por essa expressão temos um sistema de k equações com k elementos desconhecidos $\hat{\beta}$.

Condições Necessárias e Suficientes



12/45

 Resolvendo esse sistema encontramos uma fórmula explícita para o estimador de MQO:

$$\widehat{\boldsymbol{\beta}} = \left(\sum_{i=1}^{n} \boldsymbol{x}_{i} \boldsymbol{x}_{i}^{\prime}\right)^{-1} \left(\sum_{i=1}^{n} \boldsymbol{x}_{i} y_{i}\right)$$
(10)

- Este é um estimador natural do coeficiente de β da melhor projeção linear e também é conhecido como estimador da projeção linear.
- Obtendo a segunda derivada da eq. (9), temos:

$$\frac{\partial^2}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}'} SQE_n \boldsymbol{\beta} = 2 \sum_{i=1}^n \boldsymbol{x}_i \boldsymbol{x}_i' > 0$$
 (11)

que é uma matriz definida positiva. Logo, $\widehat{\beta}$ é o único que minimiza a função SQE_n .

Estimador dos Momentos



• Podemos escrever o coeficiente de projeção β como uma função explícita dos momentos populacionais Q_{xy} e Q_{xx} . O estimador dos momentos são os momentos amostrais:

$$\widehat{Q}_{xy} = \frac{1}{n} \sum_{i=1}^{n} x_i y_i \tag{12}$$

$$\widehat{\boldsymbol{Q}}_{xx} = \frac{1}{n} \sum_{i=1}^{n} \boldsymbol{x}_i \boldsymbol{x}_i' \tag{13}$$

ullet O estimador dos momentos de eta substitui o momento populacional pelos momentos amostrais:

$$\widehat{\boldsymbol{\beta}} = \widehat{\boldsymbol{Q}}_{xx}^{-1} \widehat{\boldsymbol{Q}}_{xy} = \left(\sum_{i=1}^{n} \boldsymbol{x}_{i} \boldsymbol{x}_{i}'\right)^{-1} \left(\sum_{i=1}^{n} \boldsymbol{x}_{i} y_{i}\right)$$
(14)

Definição

O estimador de mínimos quadrados $\hat{\beta}$ é

$$\widehat{\boldsymbol{\beta}} = \underset{\boldsymbol{\beta} \in \mathbb{R}^k}{\operatorname{arg\,min}} S_n(\boldsymbol{\beta}) \tag{15}$$

em que

$$S_n(\beta) = \frac{1}{n} \sum_{i=1}^n (y_i - \boldsymbol{x}_i' \boldsymbol{\beta})^2$$
 (16)

E tem como solução

$$\widehat{\boldsymbol{\beta}} = \left(\sum_{i=1}^{n} \boldsymbol{x}_{i} \boldsymbol{x}_{i}^{\prime}\right)^{-1} \left(\sum_{i=1}^{n} \boldsymbol{x}_{i} y_{i}\right)$$
(17)

14/4514 / 45

Teorema

 $Se\sum_{i=1}^{n} x_i x_i' > 0$, o estimador de Mínimos Quadrados é único e igual

$$\widehat{\boldsymbol{\beta}} = \left(\sum_{i=1}^{n} \boldsymbol{x}_{i} \boldsymbol{x}_{i}^{\prime}\right)^{-1} \left(\sum_{i=1}^{n} \boldsymbol{x}_{i} y_{i}\right)$$
(18)

Resíduos



16/45

16 / 45

• Como um subproduto da estimação, definimos o valor ajustado

$$\widehat{y}_i = \boldsymbol{x}_i' \widehat{\boldsymbol{\beta}} \tag{19}$$

e os resíduos

$$\widehat{e}_i = y_i - \widehat{y}_i = y_i - \boldsymbol{x}_i' \widehat{\boldsymbol{\beta}}$$
 (20)

• Note que

$$y_i = \mathbf{x}_i' \hat{\boldsymbol{\beta}} + \hat{e}_i \tag{21}$$

• **Distinção:** O termo e_i é não observável enquanto o resíduo \hat{e}_i é um subproduto da estimação.

• A eq (20) implica que:

$$\sum_{i=1}^{n} x_i \hat{e}_i = \mathbf{0} \tag{22}$$

• Podemos demonstrar isso como:

$$\sum_{i=1}^{n} \boldsymbol{x}_{i} \widehat{e}_{i} = \sum_{i=1}^{n} \boldsymbol{x}_{i} \left(y_{i} - \boldsymbol{x}_{i}' \widehat{\boldsymbol{\beta}} \right)$$

$$= \sum_{i=1}^{n} \boldsymbol{x}_{i} y_{i} - \sum_{i=1}^{n} \boldsymbol{x}_{i} \boldsymbol{x}_{i}' \widehat{\boldsymbol{\beta}}$$

$$= \sum_{i=1}^{n} \boldsymbol{x}_{i} y_{i} - \sum_{i=1}^{n} \boldsymbol{x}_{i} \boldsymbol{x}_{i}' \left(\sum_{i=1}^{n} \boldsymbol{x}_{i} \boldsymbol{x}_{i}' \right)^{-1} \left(\sum_{i=1}^{n} \boldsymbol{x}_{i} y_{i} \right)$$

$$= \sum_{i=1}^{n} \boldsymbol{x}_{i} y_{i} - \sum_{i=1}^{n} \boldsymbol{x}_{i} y_{i}$$

$$= \mathbf{0}$$

17/45 17/45

• Quando x_i contém uma constante, uma implicação é:

$$\frac{1}{n}\sum_{i=1}^{n}\widehat{e}_{i} = 0 \tag{23}$$

- Os resíduos tem média amostral zero e a correlação amostral entre os regressores e o resíduo é zero.
- Estes são resultados algébricos e se mantem verdadeiros para todas estimativas da regressão linear.

Formato Matricial



• As n equações lineares $y = x'\beta + e$ formam um sistema de n equações. Podemos empilhar estas n equações juntas como:

$$y_1 = \mathbf{x}_1' \boldsymbol{\beta} + e_1$$
$$y_2 = \mathbf{x}_2' \boldsymbol{\beta} + e_2$$
$$\vdots$$
$$y_n = \mathbf{x}_n' \boldsymbol{\beta} + e_n$$

• Agora defina $\boldsymbol{y}_{n\times 1} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \, \boldsymbol{X}_{n\times k} = \begin{pmatrix} \boldsymbol{x}_1' \\ \boldsymbol{x}_2' \\ \vdots \\ \boldsymbol{x}_n' \end{pmatrix}, \, \boldsymbol{e}_{n\times 1} = \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix}$

 \bullet O sistema de n equações pode ser compactado em uma única equação

$$y = X\beta + e \tag{24}$$

 Somas de amostras pode ser escritas em notação matricial. Por exemplo

$$\sum_{i=1}^{n} x_i x_i' = X' X \tag{25}$$

$$\sum_{i=1}^{n} \boldsymbol{x}_{i} y_{i} = \boldsymbol{X}' \boldsymbol{y} \tag{26}$$

• E o estimador de mínimos quadrados pode ser escrito como:

$$\widehat{\boldsymbol{\beta}} = (\boldsymbol{X}'\boldsymbol{X})^{-1} (\boldsymbol{X}'\boldsymbol{y}) \tag{27}$$

• As versões matriciais se tornam

$$y = X\hat{\beta} + \hat{e} \tag{28}$$

ou equivalente ao vetor de resíduos

$$\widehat{e} = \boldsymbol{y} - \boldsymbol{X}\widehat{\boldsymbol{\beta}} \tag{29}$$

• Usando o vetor de resíduos podemos escrever

$$\mathbf{X}'\hat{e} = \mathbf{0} \tag{30}$$

21/45 21/45

Propriedades



• Vamos definir a matriz:

$$P = X \left(X'X \right)^{-1} X \tag{31}$$

• Observe que

$$PX = X (X'X)^{-1} X'X = X$$
(32)

• Esta é uma propriedade da matriz de projeção. Para qualquer matriz Z que pode ser escrita como $Z = X\Gamma$ para qualquer Γ , então

$$PZ = X\Gamma = X (X'X)^{-1} X'X\Gamma = X\Gamma = Z$$

ullet A matriz $m{P}$ é simétrica e idempotente. Podemos ver isso

$$P' = \left(X \left(X'X\right)^{-1} X'\right)'$$

$$= \left(X'\right)' \left(\left(X'X\right)\right)^{-1} X'$$

$$= X \left(\left(X'X\right)'\right)^{-1} X'$$

$$= X \left(\left(X\right)' \left(X'\right)'\right)^{-1} X'$$

$$= P$$
(33)

ullet Para ver que a matriz é idempotente, o fato que PX = X implica que

$$PP = PX (X'X)^{-1} X'$$

$$= X (X'X)^{-1} X'$$

$$= P$$
(34)

ullet O traço da matriz $oldsymbol{P}$ é:

$$\operatorname{tr} \boldsymbol{P} = \operatorname{tr} \left(\boldsymbol{X} \left(\boldsymbol{X}' \boldsymbol{X} \right)^{-1} \boldsymbol{X}' \right)$$

$$= \operatorname{tr} \left(\left(\boldsymbol{X}' \boldsymbol{X} \right)^{-1} \boldsymbol{X}' \boldsymbol{X} \right)$$

$$= \operatorname{tr} \left(\boldsymbol{I}_{k} \right)$$

$$= k \tag{35}$$

 \bullet A matriz \boldsymbol{P} tem uma propriedade de gerar os valores ajustados na regressão de mínimos quadrados:

$$Py = X (X'X)^{-1} X'y = X'\widehat{\beta} = \widehat{y}$$
 (36)

Teorema

A matriz de projeção $P = X(X'X)^{-1}X$ para qualquer X de dimensão $n \times k$ com $n \ge k$ tem as seguintes propriedades algébricas:

- \bullet P é simétrica (P' = P).
- $\mathbf{P} \in idempotente (\mathbf{PP} = \mathbf{P}).$
- os autovalores de P são 1 e zero. Existem k autovalores igualando a 1 e n-k igualando a zero.

Propriedades



• Vamos definir

$$M = I_n - P$$

$$= I_n - X (X'X)^{-1} X'$$
(37)

em que I_n é uma matriz identidade $n \times n$.

• Note que

$$MX = (I_n - P) X$$
$$= X - PX = X - X = 0$$
(38)

ullet Então M e X são ortogonais. Chamamos M de matriz de projeção ortogonal.

• A matriz de projeção ortogonal M é simétrica (M' = M) e idempotente (MM = M). Podemos calcular que

$$\operatorname{tr} \boldsymbol{M} = n - k \tag{39}$$

ullet Enquanto P gera os valores ajustados, M gera os resíduos:

$$My = y - Py = y - X\widehat{\beta} = \widehat{e}$$
 (40)

• Podemos usar (40) para escrever uma expressão alternativa para vetor de resíduos. Substituindo $y = X\beta + e$ para dentro $\hat{e} =$ My e usando MX = 0 encontramos

$$\hat{e} = My = M(X\beta + e) = Me \tag{41}$$

27/4527 / 45

Projeção e Variância



• A variância do erro $\sigma^2 = \mathbb{E}\left[e_i^2\right]$ é um momento, assim um estimador natural é o estimador de momentos. Se e_i^2 fosse observado estimaríamos σ^2 por

$$\tilde{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n e_i^2 \tag{42}$$

• Contudo e_i não é observado. Por isso é comum considerar uma estimação em dois passos. No primeiro passo os \hat{e}_i são calculados. No segundo passo, substituímos \hat{e}_i na eq. (42) para obter um estimador factível.

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \hat{e}_i^2 \tag{43}$$

• Considerando a notação matricial, podemos escrever eq. (42) e (43) como

$$\tilde{\sigma}^2 = n^{-1} e' e \tag{44}$$

 \mathbf{e}

$$\hat{\sigma}^2 = n^{-1} \hat{e}' \hat{e} \tag{45}$$

• Lembrando que a expressão $\hat{e} = My = Me$ e de (40) e (41) aplicado na eq (45) encontramos

$$\widehat{\sigma}^{2} = n^{-1}\widehat{e}'\widehat{e}$$

$$= n^{-1}y'MMy$$

$$= n^{-1}y'My$$

$$= n^{-1}e'Me$$
(46)

• Uma aplicação interessante é

$$\tilde{\sigma}^{2} - \hat{\sigma}^{2} = n^{-1} e' e - n^{-1} e' M e$$

$$= n^{-1} e' P e$$

$$\geq 0$$
(47)

- A desigualdade final mantém porque P é é positiva semi-definida e e'Pe é uma forma quadrática.
- Este resultado mostra que o estimador de $\hat{\sigma}^2$ é numericamente menor do que o estimador idealizado pela eq (42).

Decomposição



• Outra forma de escrever a eq (40) é

$$y = Py + My = \hat{y} + \hat{e} \tag{48}$$

• Esta decomposição é **ortogonal**, isto é:

$$\widehat{\boldsymbol{y}}'\widehat{\boldsymbol{e}} = (\boldsymbol{P}\boldsymbol{y})'(\boldsymbol{M}\boldsymbol{y}) = \boldsymbol{y}'\boldsymbol{P}\boldsymbol{M}\boldsymbol{y} = 0 \tag{49}$$

• Segue que

$$\mathbf{y}'\mathbf{y} = \widehat{\mathbf{y}}'\widehat{\mathbf{g}} + 2\widehat{\mathbf{y}}'\widehat{\mathbf{e}} + \widehat{\mathbf{e}}'\widehat{\mathbf{e}} = \widehat{\mathbf{y}}'\widehat{\mathbf{y}} + \widehat{\mathbf{e}}'\widehat{\mathbf{e}}$$
 (50)

ou

$$\sum_{i=1}^{n} y_i^2 = \sum_{i=1}^{n} \hat{y}_i^2 + \sum_{i=1}^{n} \hat{e}_i^2$$
 (51)

• Vamos subtrair \overline{y} de ambos os lados da eq (48) obtemos

$$y - 1\overline{y} = \hat{y} - 1\overline{y} + \hat{e} \tag{52}$$

ullet Esta decomposição é também ortogonal quando X contém uma constante, como

$$(\widehat{\boldsymbol{y}} - \mathbf{1}\overline{\boldsymbol{y}})'\widehat{\boldsymbol{e}} = \widehat{\boldsymbol{y}}'\widehat{\boldsymbol{e}} - \overline{\boldsymbol{y}}\mathbf{1}'\widehat{\boldsymbol{e}} = 0$$
 (53)

sob
$$\frac{1}{n} \sum_{i=1}^{n} \hat{e}_i^2 = 0.$$

• Segue que

$$(\mathbf{y} - \mathbf{1}\overline{\mathbf{y}})'(\mathbf{y} - \mathbf{1}\overline{\mathbf{y}}) = (\widehat{\mathbf{y}} - \mathbf{1}\overline{\mathbf{y}})'(\widehat{\mathbf{y}} - \mathbf{1}\overline{\mathbf{y}}) + \widehat{\mathbf{e}}'\widehat{\mathbf{e}}$$
 (54)

$$\sum_{i=1}^{n} (y_i - \overline{y})^2 = \sum_{i=1}^{n} (\widehat{y}_i - \overline{y})^2 + \sum_{i=1}^{n} \widehat{e}_i^2$$
 (55)

32/4532 / 45

Variância e Ajuste do Modelo



- As eq. (54) e (55) são chamadas de fórmula da análise da variância para regressão de mínimos quadrados.
- Uma medida de ajuste da regressão é o coeficiente de determinação ou \mathbb{R}^2 :

$$R^{2} = \frac{\sum_{i=1}^{n} (\widehat{y}_{i} - \overline{y})^{2}}{\sum_{i=1}^{n} (y_{i} - \overline{y})^{2}} = 1 - \frac{\sum_{i=1}^{n} \widehat{e}_{i}^{2}}{\sum_{i=1}^{n} (y_{i} - \overline{y})^{2}}$$
(56)

- O \mathbb{R}^2 é frequentemente descrito como a fração da variância amostral de y_i que é explicada pelo ajuste dos mínimos quadrados.
- Atenção: Uma restrição/crítica ao \mathbb{R}^2 é que ele aumenta quando incluímos mais regressores na regressão.

- Considere a partição $\boldsymbol{X} = [\boldsymbol{X}_1 \boldsymbol{X}_2]$ e $\boldsymbol{\beta} = \begin{pmatrix} \boldsymbol{\beta}_1 \\ \boldsymbol{\beta}_2 \end{pmatrix}$.
- Assim, o modelo de regressão pode ser reescrito como

$$y = X\hat{\beta} + \hat{e} \tag{57}$$

• O estimador de MQO de $\beta = (\beta_1', \beta_2')'$ é obtido pela regressão de y em $X = [X_1 X_2]$ e pode ser escrito como

$$y = X\hat{\beta} + \hat{e} = X_1\hat{\beta}_1 + X_2\hat{\beta}_2 + \hat{e}$$
 (58)

 \bullet Estamos interessados na expressão algébrica para $\widehat{\boldsymbol{\beta}}_1$ e $\widehat{\boldsymbol{\beta}}_2.$

- A álgebra aqui é idêntica a que fizemos anteriormente para os coeficientes da população.
- Particionar \widehat{Q}_{xx} e \widehat{Q}_{xy} como

$$\widehat{Q}_{xx} = \begin{bmatrix} \widehat{Q}_{11} & \widehat{Q}_{12} \\ \widehat{Q}_{21} & \widehat{Q}_{22} \end{bmatrix} = \begin{bmatrix} \frac{1}{n} (X_1' X_1) & \frac{1}{n} (X_1' X_2) \\ \frac{1}{n} (X_2' X_1) & \frac{1}{n} (X_2' X_2) \end{bmatrix}$$
(59)

e

$$\widehat{\boldsymbol{Q}}_{xy} = \begin{bmatrix} \widehat{\boldsymbol{Q}}_{1y} \\ \widehat{\boldsymbol{Q}}_{2y} \end{bmatrix} = \begin{bmatrix} \frac{1}{n} (\boldsymbol{X}_1' \boldsymbol{y}) \\ \frac{1}{n} (\boldsymbol{X}_2' \boldsymbol{y}) \end{bmatrix}$$
(60)

 \bullet Calculando a matriz inversa para $\widehat{\boldsymbol{Q}}_{xx}$

$$\hat{Q}_{xx}^{-1} = \begin{bmatrix} \hat{Q}_{11} & \hat{Q}_{12} \\ \hat{Q}_{21} & \hat{Q}_{22} \end{bmatrix}^{-1} \stackrel{def}{=} \begin{bmatrix} \hat{Q}^{11} & \hat{Q}^{12} \\ \hat{Q}^{21} & \hat{Q}^{22} \end{bmatrix} \\
= \begin{bmatrix} \hat{Q}_{11.2}^{-1} & -\hat{Q}_{11.2}^{-1} \hat{Q}_{12} \hat{Q}_{22}^{-1} \\ -\hat{Q}_{22.1}^{-1} \hat{Q}_{21} \hat{Q}_{11}^{-1} & \hat{Q}_{22.1}^{-1} \end{bmatrix}$$
(61)

em que
$$\hat{Q}_{11.2} = \hat{Q}_{11} - \hat{Q}_{12} \hat{Q}_{22}^{-1} \hat{Q}_{21}$$
 e $\hat{Q}_{22.1} = \hat{Q}_{22} - \hat{Q}_{21} \hat{Q}_{11}^{-1} \hat{Q}_{12}$.

• Assim,

$$\hat{\beta} = \begin{pmatrix} \hat{\beta}_{1} \\ \hat{\beta}_{2} \end{pmatrix}
\hat{\beta} = \begin{bmatrix} \hat{Q}_{11.2}^{-1} & -\hat{Q}_{11.2}^{-1} \hat{Q}_{12} \hat{Q}_{22}^{-1} \\ -\hat{Q}_{22.1}^{-1} \hat{Q}_{21} \hat{Q}_{11}^{-1} & \hat{Q}_{22.1}^{-1} \end{bmatrix} \times \begin{bmatrix} \hat{Q}_{1y} \\ \hat{Q}_{2y} \end{bmatrix}
\hat{\beta} = \begin{pmatrix} \hat{Q}_{11.2}^{-1} \hat{Q}_{1y.2} \\ \hat{Q}_{22.1}^{-1} \hat{Q}_{2y.1} \end{pmatrix}$$
(62)

Agora

$$\hat{Q}_{11.2} = \hat{Q}_{11} - \hat{Q}_{12} \hat{Q}_{22}^{-1} \hat{Q}_{21}
= \frac{1}{n} X_1' X_1 - \frac{1}{n} X_1' X_2 \left(\frac{1}{n} X_2' X_2 \right)^{-1} \frac{1}{n} \left(X_2' X_1 \right)
= \frac{1}{n} X_1' M_2 X_1$$
(63)

• Em que

$$\boldsymbol{M}_2 = \boldsymbol{I}_n - \left(\boldsymbol{X}_2 \boldsymbol{X}_2' \boldsymbol{X}\right)^{-1} \boldsymbol{X}_2 \tag{64}$$

é a matriz de projeção ortogonal para X_2 .

• De forma similar $\hat{Q}_{22.1} = \frac{1}{n} X_2' M_1 X_2$, em que

$$\boldsymbol{M}_1 = \boldsymbol{I}_n - \left(\boldsymbol{X}_1 \boldsymbol{X}_1' \boldsymbol{X}\right)^{-1} \boldsymbol{X}_1 \tag{65}$$

é a matriz de projeção ortogonal para X_1 .

Ainda

$$\widehat{\boldsymbol{Q}}_{1y.2} = \widehat{\boldsymbol{Q}}_{1y} - \widehat{\boldsymbol{Q}}_{12} \widehat{\boldsymbol{Q}}_{22}^{-1} \widehat{\boldsymbol{Q}}_{2y}$$

$$= \frac{1}{n} \boldsymbol{X}_1' \boldsymbol{y} - \frac{1}{n} \boldsymbol{X}_1' \boldsymbol{X}_2 \left(\frac{1}{n} \boldsymbol{X}_2' \boldsymbol{X}_2 \right)^{-1} \frac{1}{n} \boldsymbol{X}_2' \boldsymbol{y}$$

$$= \frac{1}{n} \boldsymbol{X}_1' \boldsymbol{M}_2 \boldsymbol{y}$$
(66)

- $\bullet \ \mathrm{E} \ \widehat{\boldsymbol{Q}}_{2y.1} = \frac{1}{n} \boldsymbol{X}_1' \boldsymbol{M}_2 \boldsymbol{y}.$
- Portanto,

$$\widehat{\boldsymbol{\beta}}_1 = \left(\boldsymbol{X}_1' \boldsymbol{M}_2 \boldsymbol{X}_1 \right)^{-1} \left(\boldsymbol{X}_1' \boldsymbol{M}_2 \boldsymbol{y} \right) \tag{67}$$

е

$$\hat{\boldsymbol{\beta}}_2 = (\boldsymbol{X}_2' \boldsymbol{M}_1 \boldsymbol{X}_2)^{-1} (\boldsymbol{X}_2' \boldsymbol{M}_1 \boldsymbol{y})$$
 (68)

• Estes são as expressões algébricas para as estimativas da equação particionada.

- Como mostrou Frisch e Waugh (1933), as expressões dadas pelas eqs. (67) e (68) podem ser utilizadas para mostrar que o estimadores de Mínimos Quadrados $\hat{\beta}_1$ e $\hat{\beta}_2$ podem ser obtidos por um procedimento de regressão em dois passos.
- Considere a eq. (68). Como M_1 é idempotente, $M_1 = M_1 M_1$ e assim

$$\widehat{\boldsymbol{\beta}}_{2} = (\boldsymbol{X}_{2}'\boldsymbol{M}_{1}\boldsymbol{X}_{2})^{-1} (\boldsymbol{X}_{2}'\boldsymbol{M}_{1}\boldsymbol{y})$$

$$= (\boldsymbol{X}_{2}'\boldsymbol{M}_{1}\boldsymbol{M}_{1}\boldsymbol{X}_{2})^{-1} (\boldsymbol{X}_{2}'\boldsymbol{M}_{1}\boldsymbol{M}_{1}\boldsymbol{y})$$

$$= (\tilde{\boldsymbol{X}}_{2}'\tilde{\boldsymbol{X}}_{2})^{-1} (\tilde{\boldsymbol{X}}_{2}'\tilde{\boldsymbol{e}}_{1})$$
(69)

em que $ilde{m{X}}_2 = m{M}_1 m{X}_2$ e $ilde{m{e}}_1 = m{M}_1 m{y}$.

• Vamos começar pelo configuração mais simples: modelo somente com intercepto.

$$y_i = \mu + e_i \tag{70}$$

$$\mathbb{E}[e] = 0 \tag{71}$$

- Esse modelo é equivalente a um modelo de regressão com k=1 e $x_i=1$. No modelo somente com intercepto, $\mu=\overline{y}$ é a média de y_i .
- O estimador de mínimos quadrados $\hat{\mu} = \overline{y}$ iguala a média amostral.
- Vamos calcular a esperança e a variância do estimador \overline{y} . Como a a média amostral é uma função das observações, sua esperança é simples de calcular:

$$\mathbb{E}[\overline{y}] = \mathbb{E}\left(\frac{1}{n}\sum_{i=1}^{n}y_i\right) \tag{72}$$

• Assim,

$$\mathbb{E}[\overline{y}] = \mathbb{E}\left(\frac{1}{n}\sum_{i=1}^{n}y_i\right) = \frac{1}{n}\sum_{i=1}^{n}\mathbb{E}[\overline{y}_i] = \mu \tag{73}$$

- Temos que o valor esperado do estimador de mínimos quadrados (média amostral) iguala o coeficiente de projeção (média populacional).
- Um estimador com a propriedade de que sua esperança é igual ao parâmetro que ele está estimando é conhecido como estimador não viesado.

Definição

Um estimador $\hat{\theta}$ para θ é **não viesado** se $\mathbb{E}[\hat{\theta}] = \theta$.

42/45 42/45

Variância amostral



• Vamos calcular a variância do estimador \overline{y} considerando a definição acima. Usando $y_i = \mu + e_i$, temos:

$$\overline{y} - \mu = \frac{1}{n} \sum_{i=1}^{n} e_i \tag{74}$$

• Assim,

$$\operatorname{var}[\overline{y}] = \mathbb{E} (\overline{y} - \mu)^{2}$$

$$= \mathbb{E} \left(\frac{1}{n} \sum_{i=1}^{n} e_{i} \right) \left(\frac{1}{n} \sum_{j=1}^{n} e_{j} \right)$$

$$= \frac{1}{n^{2}} \sum_{i=1}^{n} \sum_{j=1}^{n} \mathbb{E}[e_{i}e_{j}]$$
(75)

43/45 43/45 • Logo,

$$\operatorname{var}[\overline{y}] = \frac{1}{n^2} \sum_{i=1}^{n} \sigma^2$$

$$= \frac{1}{n} \sigma^2 \tag{76}$$

• Nota: $\mathbb{E}[e_i e_j] = \sigma^2$ para i = j, $\mathbb{E}[e_i e_j] = 0$ para $i \neq j$ em virtude da independência.

Econometria I Álgebra dos Mínimos Quadrados

Victor Oliveira

Núcleo de Economia Internacional e Desenvolvimento Econômico

PPGDE - 2023