

# ECONOMETRIA I

## ÁLGEBRA DOS MÍNIMOS QUADRADOS

Victor Oliveira

Núcleo de Economia Internacional e Desenvolvimento Econômico

PPGDE – 2024

# Sumário

- 1 Amostra Aleatória
- 2 Mínimos Quadrados Ordinários
- 3 Método dos Momentos
- 4 Resíduos dos Mínimos Quadrados Ordinários
- 5 Notação Matricial
- 6 Matriz de Projeção
- 7 Projeção Ortogonal
- 8 Estimação da Variância do Erro
- 9 Análise da Variância
- 10 Componentes da Regressão
- 11 Resíduos da Regressão
- 12 Regressão de Mínimos Quadrados

# Amostra Aleatória

- O melhor preditor de  $y$  dado  $\mathbf{x}$  para um par de variáveis aleatórias  $(y, \mathbf{x}) \in \mathbb{R} \times \mathbb{R}^k$  é o modelo de projeção linear.
- Agora estamos interessados em **estimar** os parâmetros desse modelo, em particular o **coeficiente de projeção**

$$\beta = [\mathbb{E}(\mathbf{x}\mathbf{x}')]^{-1} \mathbb{E}(\mathbf{x}y) \quad (1)$$

- Podemos estimar  $\beta$  usando amostras que incluem medidas conjunta de  $(y, \mathbf{x})$ .
- Vamos diferenciar *observações (realizações)* das variáveis aleatórias.
- Variáveis aleatórias são  $(y, \mathbf{x})$ , enquanto as observações são  $(y_i, \mathbf{x}_i)$ .
- Do ponto de vista do pesquisador, os últimos são números. Do ponto de vista da teoria estatística elas são realizações de variáveis aleatórias.

- **Notação:** Para observações individuais, vamos usar um subscrito  $i$  que vai de 1 a  $n$ , portanto, a  $i$ -ésima observação é  $(y_i, \mathbf{x}_i)$ . O número  $n$  é o tamanho da amostra.
- **Definição:** Uma amostra aleatória é dada pelas observações

$$\{(y_1, x_1), (y_2, x_2), \dots, (y_i, x_i), \dots, (y_n, x_n)\} \quad (2)$$

- De forma mais simplificada temos  $\{(y_i, x_i) : i = 1, \dots, n\}$ .
- As observações individuais podem ser extraídas de uma distribuição comum (homogênea) ou podem ser extraídas de distribuições heterogêneas. A abordagem mais simples é assumir a homogeneidade – que as observações são realizações de uma população subjacente idêntica.

## Pressuposto

*As variáveis  $\{(\mathbf{y}_1, \mathbf{x}_1), (\mathbf{y}_2, \mathbf{x}_2), \dots, (\mathbf{y}_i, \mathbf{x}_i), \dots, (\mathbf{y}_n, \mathbf{x}_n)\}$  são identicamente distribuídas e são retirados de uma distribuição comum  $F$ .*

- Vamos nos referir à distribuição comum  $F$  como sendo a **população**.
- O **modelo de projeção linear** se aplica as variáveis aleatórias  $(y, \mathbf{x})$ . É o modelo de probabilidade que descrevemos anteriormente como o melhor preditor linear.

## Critério de Otimização

- O análogo empírico da esperança do erro ao quadrado é o **erro quadrático médio amostral**:

$$\begin{aligned} S_n(\beta) &= \frac{1}{n} \sum_{i=1}^n (y_i - \mathbf{x}'_i \beta)^2 \\ &= \frac{1}{n} SQE_n(\beta) \end{aligned} \quad (3)$$

em que  $SQE_n(\beta) = \sum_{i=1}^n (y_i - \mathbf{x}'_i \beta)$  é chamada de **função da soma dos quadrados dos erros**. Um **estimador** para  $\beta$  é obtido pela minimização da função  $S_n(\beta)$ :

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^k} S_n(\beta) \quad (4)$$

# Estimador de MQO

- O  $\hat{\beta}$  é conhecido como o estimador de **Mínimos Quadrados Ordinários** (MQO) de  $\beta$ .
- **Distinção:** o parâmetro populacional  $\beta$  é **fixo na população**, enquanto o estimador  $\hat{\beta}$  **varia entre as amostras**.

# Caso Univariado

- Considere o caso de  $k = 1$  tal que o coeficiente de  $\beta$  é um escalar.
- Assim, a SQE é dada por:

$$\begin{aligned} SQE_n(\beta) &= \sum_{i=1}^n (y_i - x_i\beta)^2 \\ &= \left( \sum_{i=1}^n y_i^2 \right) - 2\beta \left( \sum_{i=1}^n y_i x_i \right) + \beta^2 \left( \sum_{i=1}^n x_i^2 \right) \end{aligned} \quad (5)$$

- O estimador de MQO minimiza esta função.



- Assim, o resultado da minimização do  $SQE_n(\beta)$  é:

$$\hat{\beta} = \frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2} \quad (6)$$

- O modelo com apenas o intercepto é um caso especial de  $x_i = 1$ . Neste caso encontramos:

$$\hat{\beta} = \frac{\sum_{i=1}^n y_i}{\sum_{i=1}^n 1} = \frac{1}{n} \sum_{i=1}^n y_i = \bar{y} \quad (7)$$

que é a média de  $y_i$ .

- Por esse resultado, **o estimador de MQO num modelo com apenas o intercepto é a média amostral.**
- O estimador  $\hat{\beta}$  existe apenas se o **denominador é não-zero.** Por ser uma soma dos quadrados, necessariamente é não-negativo. Portanto,  $\hat{\beta}$  existe se  $\sum_{i=1}^n x_i^2 > 0$ .

## Caso Multivariado

- Considere o caso de  $k > 1$  tal que o coeficiente de  $\beta$  agora é um vetor.
- Assim, a SQE é dada por:

$$SQE_n(\beta) = \left( \sum_{i=1}^n y_i^2 \right) - 2\beta' \left( \sum_{i=1}^n y_i \mathbf{x}_i \right) + \beta' \left( \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' \right) \beta \quad (8)$$

- A CPO para minimização de  $SQE_n(\beta)$  é:

$$\frac{\partial}{\partial \beta} SQE_n(\hat{\beta}) = \mathbf{0} \quad \Longleftrightarrow \quad = -2 \sum_{i=1}^n \mathbf{x}_i y_i + 2 \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' \hat{\beta} \quad (9)$$

- Por essa expressão temos um sistema de  $k$  equações com  $k$  elementos desconhecidos  $\hat{\beta}$ .

## Condições Necessárias e Suficientes

- Resolvendo esse sistema encontramos uma fórmula explícita para o estimador de MQO:

$$\hat{\beta} = \left( \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \left( \sum_{i=1}^n \mathbf{x}_i y_i \right) \quad (10)$$

- Este é um estimador natural do coeficiente de  $\beta$  da melhor projeção linear e também é conhecido como **estimador da projeção linear**.
- Obtendo a segunda derivada da eq. (9), temos:

$$\frac{\partial^2}{\partial \beta \partial \beta'} S Q E_n \beta = 2 \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' > 0 \quad (11)$$

que é uma matriz definida positiva. Logo,  $\hat{\beta}$  é o único que minimiza a função  $S Q E_n$ .

# Estimador dos Momentos

- Podemos escrever o coeficiente de projeção  $\beta$  como uma função explícita dos momentos populacionais  $Q_{xy}$  e  $Q_{xx}$ . O estimador dos momentos são os momentos amostrais:

$$\hat{Q}_{xy} = \frac{1}{n} \sum_{i=1}^n x_i y_i \quad (12)$$

$$\hat{Q}_{xx} = \frac{1}{n} \sum_{i=1}^n x_i x_i' \quad (13)$$

- O estimador dos momentos de  $\beta$  substitui o momento populacional pelos momentos amostrais:

$$\hat{\beta} = \hat{Q}_{xx}^{-1} \hat{Q}_{xy} = \left( \sum_{i=1}^n x_i x_i' \right)^{-1} \left( \sum_{i=1}^n x_i y_i \right) \quad (14)$$

## Definição

O estimador de mínimos quadrados  $\hat{\beta}$  é

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^k} S_n(\beta) \quad (15)$$

em que

$$S_n(\beta) = \frac{1}{n} \sum_{i=1}^n (y_i - \mathbf{x}_i' \beta)^2 \quad (16)$$

E tem como solução

$$\hat{\beta} = \left( \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \left( \sum_{i=1}^n \mathbf{x}_i y_i \right) \quad (17)$$

## Teorema

Se  $\sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' > 0$ , o estimador de Mínimos Quadrados é único e igual a

$$\hat{\beta} = \left( \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \left( \sum_{i=1}^n \mathbf{x}_i y_i \right) \quad (18)$$

# Resíduos

- Como um subproduto da estimação, definimos o valor ajustado

$$\hat{y}_i = \mathbf{x}'_i \hat{\boldsymbol{\beta}} \quad (19)$$

e os resíduos

$$\hat{e}_i = y_i - \hat{y}_i = y_i - \mathbf{x}'_i \hat{\boldsymbol{\beta}} \quad (20)$$

- Note que

$$y_i = \mathbf{x}'_i \hat{\boldsymbol{\beta}} + \hat{e}_i \quad (21)$$

- **Distinção:** O termo  $e_i$  é não observável enquanto o resíduo  $\hat{e}_i$  é um subproduto da estimação.



- A eq (20) implica que:

$$\sum_{i=1}^n \mathbf{x}_i \hat{e}_i = \mathbf{0} \quad (22)$$

- Podemos demonstrar isso como:

$$\begin{aligned} \sum_{i=1}^n \mathbf{x}_i \hat{e}_i &= \sum_{i=1}^n \mathbf{x}_i (y_i - \mathbf{x}_i' \hat{\beta}) \\ &= \sum_{i=1}^n \mathbf{x}_i y_i - \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' \hat{\beta} \\ &= \sum_{i=1}^n \mathbf{x}_i y_i - \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' \left( \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \left( \sum_{i=1}^n \mathbf{x}_i y_i \right) \\ &= \sum_{i=1}^n \mathbf{x}_i y_i - \sum_{i=1}^n \mathbf{x}_i y_i \\ &= \mathbf{0} \end{aligned}$$

- Quando  $\mathbf{x}_i$  contém uma constante, uma implicação é:

$$\frac{1}{n} \sum_{i=1}^n \hat{e}_i = 0 \quad (23)$$

- Os resíduos tem média amostral zero e a correlação amostral entre os regressores e o resíduo é zero.
- Estes são resultados algébricos e se mantem verdadeiros para todas estimativas da regressão linear.

# Formato Matricial

- As  $n$  equações lineares  $y = \mathbf{x}'\boldsymbol{\beta} + e$  formam um sistema de  $n$  equações. Podemos empilhar estas  $n$  equações juntas como:

$$y_1 = \mathbf{x}'_1\boldsymbol{\beta} + e_1$$

$$y_2 = \mathbf{x}'_2\boldsymbol{\beta} + e_2$$

$$\vdots$$

$$y_n = \mathbf{x}'_n\boldsymbol{\beta} + e_n$$

- Agora defina  $\mathbf{y}_{n \times 1} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$ ,  $\mathbf{X}_{n \times k} = \begin{pmatrix} \mathbf{x}'_1 \\ \mathbf{x}'_2 \\ \vdots \\ \mathbf{x}'_n \end{pmatrix}$ ,  $\mathbf{e}_{n \times 1} = \begin{pmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{pmatrix}$

- O sistema de  $n$  equações pode ser compactado em uma única equação

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + e \quad (24)$$

- Somas de amostras pode ser escritas em notação matricial. Por exemplo

$$\sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' = \mathbf{X}'\mathbf{X} \quad (25)$$

$$\sum_{i=1}^n \mathbf{x}_i y_i = \mathbf{X}'\mathbf{y} \quad (26)$$

- E o estimador de mínimos quadrados pode ser escrito como:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1} (\mathbf{X}'\mathbf{y}) \quad (27)$$

- As versões matriciais se tornam

$$\mathbf{y} = \mathbf{X}\hat{\boldsymbol{\beta}} + \hat{\mathbf{e}} \quad (28)$$

ou equivalente ao vetor de resíduos

$$\hat{\mathbf{e}} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}} \quad (29)$$

- Usando o vetor de resíduos podemos escrever

$$\mathbf{X}'\hat{\mathbf{e}} = \mathbf{0} \quad (30)$$

# Propriedades

- Vamos definir a matriz:

$$P = X (X'X)^{-1} X \quad (31)$$

- Observe que

$$PX = X (X'X)^{-1} X'X = X \quad (32)$$

- Esta é uma propriedade da **matriz de projeção**. Para qualquer matriz  $Z$  que pode ser escrita como  $Z = X\Gamma$  para qualquer  $\Gamma$ , então

$$PZ = X\Gamma = X (X'X)^{-1} X'X\Gamma = X\Gamma = Z$$

- A matriz  $P$  é **simétrica** e **idempotente**. Podemos ver isso

$$\begin{aligned}
 P' &= \left( X (X'X)^{-1} X' \right)' \\
 &= (X')' ((X'X))^{-1} X' \\
 &= X \left( (X'X)' \right)^{-1} X' \\
 &= X \left( (X)' (X')' \right)^{-1} X' \\
 &= P
 \end{aligned} \tag{33}$$

- Para ver que a matriz é idempotente, o fato que  $PX = X$  implica que

$$\begin{aligned}
 PP &= PX (X'X)^{-1} X' \\
 &= X (X'X)^{-1} X' \\
 &= P
 \end{aligned} \tag{34}$$

- O traço da matriz  $\mathbf{P}$  é:

$$\begin{aligned}\text{tr } \mathbf{P} &= \text{tr} \left( \mathbf{X} (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \right) \\ &= \text{tr} \left( (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{X} \right) \\ &= \text{tr} (\mathbf{I}_k) \\ &= k\end{aligned}\tag{35}$$

- A matriz  $\mathbf{P}$  tem uma propriedade de gerar os valores ajustados na regressão de mínimos quadrados:

$$\mathbf{P}\mathbf{y} = \mathbf{X} (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{y} = \mathbf{X}' \hat{\boldsymbol{\beta}} = \hat{\mathbf{y}}\tag{36}$$



## Teorema

A matriz de projeção  $\mathbf{P} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}$  para qualquer  $\mathbf{X}$  de dimensão  $n \times k$  com  $n \geq k$  tem as seguintes propriedades algébricas:

- ①  $\mathbf{P}$  é simétrica ( $\mathbf{P}' = \mathbf{P}$ ).
- ②  $\mathbf{P}$  é idempotente ( $\mathbf{P}\mathbf{P} = \mathbf{P}$ ).
- ③  $\text{tr } \mathbf{P} = k$ .
- ④ os autovalores de  $\mathbf{P}$  são 1 e zero. Existem  $k$  autovalores igualando a 1 e  $n - k$  igualando a zero.
- ⑤  $\text{rank}(\mathbf{P}) = k$

# Propriedades

- Vamos definir

$$\begin{aligned} M &= I_n - P \\ &= I_n - X (X'X)^{-1} X' \end{aligned} \quad (37)$$

em que  $I_n$  é uma matriz identidade  $n \times n$ .

- Note que

$$\begin{aligned} MX &= (I_n - P) X \\ &= X - PX = X - X = 0 \end{aligned} \quad (38)$$

- Então  $M$  e  $X$  são ortogonais. Chamamos  $M$  de **matriz de projeção ortogonal**.

- A matriz de projeção ortogonal  $\mathbf{M}$  é simétrica ( $\mathbf{M}' = \mathbf{M}$ ) e idempotente ( $\mathbf{M}\mathbf{M} = \mathbf{M}$ ). Podemos calcular que

$$\text{tr } \mathbf{M} = n - k \quad (39)$$

- Enquanto  $\mathbf{P}$  gera os valores ajustados,  $\mathbf{M}$  gera os resíduos:

$$\mathbf{M}\mathbf{y} = \mathbf{y} - \mathbf{P}\mathbf{y} = \mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}} = \hat{\mathbf{e}} \quad (40)$$

- Podemos usar (40) para escrever uma expressão alternativa para vetor de resíduos. Substituindo  $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}$  para dentro  $\hat{\mathbf{e}} = \mathbf{M}\mathbf{y}$  e usando  $\mathbf{M}\mathbf{X} = \mathbf{0}$  encontramos

$$\hat{\mathbf{e}} = \mathbf{M}\mathbf{y} = \mathbf{M}(\mathbf{X}\boldsymbol{\beta} + \mathbf{e}) = \mathbf{M}\mathbf{e} \quad (41)$$

## Projeção e Variância

- A variância do erro  $\sigma^2 = \mathbb{E} [e_i^2]$  é um momento, assim um estimador natural é o estimador de momentos. Se  $e_i^2$  fosse observado estimaríamos  $\sigma^2$  por

$$\tilde{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n e_i^2 \quad (42)$$

- Contudo  $e_i$  não é observado. Por isso é comum considerar uma estimação em dois passos. No primeiro passo os  $\hat{e}_i$  são calculados. No segundo passo, substituímos  $\hat{e}_i$  na eq. (42) para obter um estimador factível.

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \hat{e}_i^2 \quad (43)$$

- Considerando a notação matricial, podemos escrever eq. (42) e (43) como

$$\tilde{\sigma}^2 = n^{-1} \mathbf{e}' \mathbf{e} \quad (44)$$

e

$$\hat{\sigma}^2 = n^{-1} \hat{\mathbf{e}}' \hat{\mathbf{e}} \quad (45)$$

- Lembrando que a expressão  $\hat{\mathbf{e}} = \mathbf{M}\mathbf{y} = \mathbf{M}\mathbf{e}$  e de (40) e (41) aplicado na eq (45) encontramos

$$\begin{aligned} \hat{\sigma}^2 &= n^{-1} \hat{\mathbf{e}}' \hat{\mathbf{e}} \\ &= n^{-1} \mathbf{y}' \mathbf{M} \mathbf{M} \mathbf{y} \\ &= n^{-1} \mathbf{y}' \mathbf{M} \mathbf{y} \\ &= n^{-1} \mathbf{e}' \mathbf{M} \mathbf{e} \end{aligned} \quad (46)$$

- Uma aplicação interessante é

$$\begin{aligned}\tilde{\sigma}^2 - \hat{\sigma}^2 &= n^{-1} \mathbf{e}' \mathbf{e} - n^{-1} \mathbf{e}' \mathbf{M} \mathbf{e} \\ &= n^{-1} \mathbf{e}' \mathbf{P} \mathbf{e} \\ &\geq 0\end{aligned}\tag{47}$$

- A desigualdade final mantém porque  $\mathbf{P}$  é positiva semi-definida e  $\mathbf{e}' \mathbf{P} \mathbf{e}$  é uma forma quadrática.
- Este resultado mostra que o estimador de  $\hat{\sigma}^2$  é numericamente menor do que o estimador idealizado pela eq (42).

# Decomposição

- Outra forma de escrever a eq (40) é

$$\mathbf{y} = \mathbf{P}\mathbf{y} + \mathbf{M}\mathbf{y} = \hat{\mathbf{y}} + \hat{\mathbf{e}} \quad (48)$$

- Esta decomposição é **ortogonal**, isto é:

$$\hat{\mathbf{y}}'\hat{\mathbf{e}} = (\mathbf{P}\mathbf{y})'(\mathbf{M}\mathbf{y}) = \mathbf{y}'\mathbf{P}\mathbf{M}\mathbf{y} = 0 \quad (49)$$

- Segue que

$$\mathbf{y}'\mathbf{y} = \hat{\mathbf{y}}'\hat{\mathbf{y}} + 2\hat{\mathbf{y}}'\hat{\mathbf{e}} + \hat{\mathbf{e}}'\hat{\mathbf{e}} = \hat{\mathbf{y}}'\hat{\mathbf{y}} + \hat{\mathbf{e}}'\hat{\mathbf{e}} \quad (50)$$

ou

$$\sum_{i=1}^n y_i^2 = \sum_{i=1}^n \hat{y}_i^2 + \sum_{i=1}^n \hat{e}_i^2 \quad (51)$$

- Vamos subtrair  $\bar{y}$  de ambos os lados da eq (48) obtemos

$$\mathbf{y} - \mathbf{1}\bar{y} = \hat{\mathbf{y}} - \mathbf{1}\bar{y} + \hat{\mathbf{e}} \quad (52)$$

- Esta decomposição é também ortogonal quando  $\mathbf{X}$  contém uma constante, como

$$(\hat{\mathbf{y}} - \mathbf{1}\bar{y})'\hat{\mathbf{e}} = \hat{\mathbf{y}}'\hat{\mathbf{e}} - \bar{y}\mathbf{1}'\hat{\mathbf{e}} = 0 \quad (53)$$

$$\text{sob } \frac{1}{n} \sum_{i=1}^n \hat{e}_i^2 = 0.$$

- Segue que

$$(\mathbf{y} - \mathbf{1}\bar{y})'(\mathbf{y} - \mathbf{1}\bar{y}) = (\hat{\mathbf{y}} - \mathbf{1}\bar{y})'(\hat{\mathbf{y}} - \mathbf{1}\bar{y}) + \hat{\mathbf{e}}'\hat{\mathbf{e}} \quad (54)$$

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n \hat{e}_i^2 \quad (55)$$



## Variância e Ajuste do Modelo

- As eq. (54) e (55) são chamadas de fórmula da análise da variância para regressão de mínimos quadrados.
- Uma medida de ajuste da regressão é o coeficiente de determinação ou  $R^2$ :

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{\sum_{i=1}^n \hat{e}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (56)$$

- O  $R^2$  é frequentemente descrito como a fração da variância amostral de  $y_i$  que é explicada pelo ajuste dos mínimos quadrados.
- **Atenção:** Uma restrição/crítica ao  $R^2$  é que ele aumenta quando incluímos mais regressores na regressão.

- Considere a partição  $\mathbf{X} = [\mathbf{X}_1 \mathbf{X}_2]$  e  $\boldsymbol{\beta} = \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix}$ .
- Assim, o modelo de regressão pode ser reescrito como

$$\mathbf{y} = \mathbf{X}\hat{\boldsymbol{\beta}} + \hat{\mathbf{e}} \quad (57)$$

- O estimador de MQO de  $\boldsymbol{\beta} = (\beta_1', \beta_2')'$  é obtido pela regressão de  $\mathbf{y}$  em  $\mathbf{X} = [\mathbf{X}_1 \mathbf{X}_2]$  e pode ser escrito como

$$\mathbf{y} = \mathbf{X}\hat{\boldsymbol{\beta}} + \hat{\mathbf{e}} = \mathbf{X}_1\hat{\boldsymbol{\beta}}_1 + \mathbf{X}_2\hat{\boldsymbol{\beta}}_2 + \hat{\mathbf{e}} \quad (58)$$

- Estamos interessados na expressão algébrica para  $\hat{\boldsymbol{\beta}}_1$  e  $\hat{\boldsymbol{\beta}}_2$ .

- A álgebra aqui é idêntica a que fizemos anteriormente para os coeficientes da população.
- Particionar  $\hat{Q}_{xx}$  e  $\hat{Q}_{xy}$  como

$$\hat{Q}_{xx} = \begin{bmatrix} \hat{Q}_{11} & \hat{Q}_{12} \\ \hat{Q}_{21} & \hat{Q}_{22} \end{bmatrix} = \begin{bmatrix} \frac{1}{n}(\mathbf{X}'_1 \mathbf{X}_1) & \frac{1}{n}(\mathbf{X}'_1 \mathbf{X}_2) \\ \frac{1}{n}(\mathbf{X}'_2 \mathbf{X}_1) & \frac{1}{n}(\mathbf{X}'_2 \mathbf{X}_2) \end{bmatrix} \quad (59)$$

e

$$\hat{Q}_{xy} = \begin{bmatrix} \hat{Q}_{1y} \\ \hat{Q}_{2y} \end{bmatrix} = \begin{bmatrix} \frac{1}{n}(\mathbf{X}'_1 \mathbf{y}) \\ \frac{1}{n}(\mathbf{X}'_2 \mathbf{y}) \end{bmatrix} \quad (60)$$

- Calculando a matriz inversa para  $\hat{Q}_{xx}$

$$\begin{aligned}\hat{Q}_{xx}^{-1} &= \begin{bmatrix} \hat{Q}_{11} & \hat{Q}_{12} \\ \hat{Q}_{21} & \hat{Q}_{22} \end{bmatrix}^{-1} \stackrel{def}{=} \begin{bmatrix} \hat{Q}^{11} & \hat{Q}^{12} \\ \hat{Q}^{21} & \hat{Q}^{22} \end{bmatrix} \\ &= \begin{bmatrix} \hat{Q}_{11.2}^{-1} & -\hat{Q}_{11.2}^{-1} \hat{Q}_{12} \hat{Q}_{22}^{-1} \\ -\hat{Q}_{22.1}^{-1} \hat{Q}_{21} \hat{Q}_{11}^{-1} & \hat{Q}_{22.1}^{-1} \end{bmatrix} \quad (61)\end{aligned}$$

em que  $\hat{Q}_{11.2} = \hat{Q}_{11} - \hat{Q}_{12} \hat{Q}_{22}^{-1} \hat{Q}_{21}$  e  $\hat{Q}_{22.1} = \hat{Q}_{22} - \hat{Q}_{21} \hat{Q}_{11}^{-1} \hat{Q}_{12}$ .

- Assim,

$$\begin{aligned}
 \hat{\beta} &= \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} \\
 \hat{\beta} &= \begin{bmatrix} \hat{Q}_{11.2}^{-1} & -\hat{Q}_{11.2}^{-1} \hat{Q}_{12} \hat{Q}_{22}^{-1} \\ -\hat{Q}_{22.1}^{-1} \hat{Q}_{21} \hat{Q}_{11}^{-1} & \hat{Q}_{22.1}^{-1} \end{bmatrix} \times \begin{bmatrix} \hat{Q}_{1y} \\ \hat{Q}_{2y} \end{bmatrix} \\
 \hat{\beta} &= \begin{pmatrix} \hat{Q}_{11.2}^{-1} \hat{Q}_{1y.2} \\ \hat{Q}_{22.1}^{-1} \hat{Q}_{2y.1} \end{pmatrix} \tag{62}
 \end{aligned}$$

- Agora

$$\begin{aligned}
 \hat{Q}_{11.2} &= \hat{Q}_{11} - \hat{Q}_{12} \hat{Q}_{22}^{-1} \hat{Q}_{21} \\
 &= \frac{1}{n} \mathbf{X}'_1 \mathbf{X}_1 - \frac{1}{n} \mathbf{X}'_1 \mathbf{X}_2 \left( \frac{1}{n} \mathbf{X}'_2 \mathbf{X}_2 \right)^{-1} \frac{1}{n} (\mathbf{X}'_2 \mathbf{X}_1) \\
 &= \frac{1}{n} \mathbf{X}'_1 \mathbf{M}_2 \mathbf{X}_1 \tag{63}
 \end{aligned}$$

- Em que

$$\mathbf{M}_2 = \mathbf{I}_n - (\mathbf{X}_2 \mathbf{X}_2' \mathbf{X})^{-1} \mathbf{X}_2 \quad (64)$$

é a matriz de projeção ortogonal para  $\mathbf{X}_2$ .

- De forma similar  $\hat{\mathbf{Q}}_{22.1} = \frac{1}{n} \mathbf{X}_2' \mathbf{M}_1 \mathbf{X}_2$ , em que

$$\mathbf{M}_1 = \mathbf{I}_n - (\mathbf{X}_1 \mathbf{X}_1' \mathbf{X})^{-1} \mathbf{X}_1 \quad (65)$$

é a matriz de projeção ortogonal para  $\mathbf{X}_1$ .

- Ainda

$$\begin{aligned} \hat{\mathbf{Q}}_{1y.2} &= \hat{\mathbf{Q}}_{1y} - \hat{\mathbf{Q}}_{12} \hat{\mathbf{Q}}_{22}^{-1} \hat{\mathbf{Q}}_{2y} \\ &= \frac{1}{n} \mathbf{X}_1' \mathbf{y} - \frac{1}{n} \mathbf{X}_1' \mathbf{X}_2 \left( \frac{1}{n} \mathbf{X}_2' \mathbf{X}_2 \right)^{-1} \frac{1}{n} \mathbf{X}_2' \mathbf{y} \\ &= \frac{1}{n} \mathbf{X}_1' \mathbf{M}_2 \mathbf{y} \end{aligned} \quad (66)$$

- E  $\hat{Q}_{2y.1} = \frac{1}{n} \mathbf{X}'_1 \mathbf{M}_2 \mathbf{y}$ .
- Portanto,

$$\hat{\beta}_1 = (\mathbf{X}'_1 \mathbf{M}_2 \mathbf{X}_1)^{-1} (\mathbf{X}'_1 \mathbf{M}_2 \mathbf{y}) \quad (67)$$

e

$$\hat{\beta}_2 = (\mathbf{X}'_2 \mathbf{M}_1 \mathbf{X}_2)^{-1} (\mathbf{X}'_2 \mathbf{M}_1 \mathbf{y}) \quad (68)$$

- Estes são as expressões algébricas para as estimativas da equação particionada.

- Como mostrou Frisch e Waugh (1933), as expressões dadas pelas eqs. (67) e (68) podem ser utilizadas para mostrar que o estimadores de Mínimos Quadrados  $\hat{\beta}_1$  e  $\hat{\beta}_2$  podem ser obtidos por um procedimento de regressão em dois passos.
- Considere a eq. (68). Como  $M_1$  é idempotente,  $M_1 = M_1 M_1$  e assim

$$\begin{aligned}
 \hat{\beta}_2 &= (X_2' M_1 X_2)^{-1} (X_2' M_1 y) \\
 &= (X_2' M_1 M_1 X_2)^{-1} (X_2' M_1 M_1 y) \\
 &= (\tilde{X}_2' \tilde{X}_2)^{-1} (\tilde{X}_2' \tilde{e}_1)
 \end{aligned} \tag{69}$$

em que  $\tilde{X}_2 = M_1 X_2$  e  $\tilde{e}_1 = M_1 y$ .



- Vamos começar pela configuração mais simples: modelo somente com intercepto.

$$y_i = \mu + e_i \quad (70)$$

$$\mathbb{E}[e] = 0 \quad (71)$$

- Esse modelo é equivalente a um modelo de regressão com  $k = 1$  e  $x_i = 1$ . No modelo somente com intercepto,  $\mu = \bar{y}$  é a média de  $y_i$ .
- O estimador de mínimos quadrados  $\hat{\mu} = \bar{y}$  iguala a média amostral.
- Vamos calcular a esperança e a variância do estimador  $\bar{y}$ . Como a média amostral é uma função das observações, sua esperança é simples de calcular:

$$\mathbb{E}[\bar{y}] = \mathbb{E} \left( \frac{1}{n} \sum_{i=1}^n y_i \right) \quad (72)$$

- Assim,

$$\mathbb{E}[\bar{y}] = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n y_i\right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[\bar{y}_i] = \mu \quad (73)$$

- Temos que o valor esperado do estimador de mínimos quadrados (média amostral) iguala o coeficiente de projeção (média populacional).
- Um estimador com a propriedade de que sua esperança é igual ao parâmetro que ele está estimando é conhecido como **estimador não viesado**.

### Definição

Um estimador  $\hat{\theta}$  para  $\theta$  é **não viesado** se  $\mathbb{E}[\hat{\theta}] = \theta$ .

## Variância amostral

- Vamos calcular a variância do estimador  $\bar{y}$  considerando a definição acima. Usando  $y_i = \mu + e_i$ , temos:

$$\bar{y} - \mu = \frac{1}{n} \sum_{i=1}^n e_i \quad (74)$$

- Assim,

$$\begin{aligned} \text{var}[\bar{y}] &= \mathbb{E} (\bar{y} - \mu)^2 \\ &= \mathbb{E} \left( \frac{1}{n} \sum_{i=1}^n e_i \right) \left( \frac{1}{n} \sum_{j=1}^n e_j \right) \\ &= \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n \mathbb{E}[e_i e_j] \end{aligned} \quad (75)$$

- Logo,

$$\begin{aligned}\text{var}[\bar{y}] &= \frac{1}{n^2} \sum_{i=1}^n \sigma^2 \\ &= \frac{1}{n} \sigma^2\end{aligned}\tag{76}$$

- **Nota:**  $\mathbb{E}[e_i e_j] = \sigma^2$  para  $i = j$ ,  $\mathbb{E}[e_i e_j] = 0$  para  $i \neq j$  em virtude da independência.

# ECONOMETRIA I

## ÁLGEBRA DOS MÍNIMOS QUADRADOS

Victor Oliveira

Núcleo de Economia Internacional e Desenvolvimento Econômico

PPGDE – 2024