

ECONOMETRIA I

REGRESSÃO DE MÍNIMOS QUADRADOS

Victor Oliveira

Núcleo de Economia Internacional e Desenvolvimento Econômico

PPGDE – 2023

- 1 Modelo de Regressão Linear
- 2 Mínimos Quadrados Generalizados
- 3 Medidas de Ajuste
- 4 Multicolinearidade
- 5 Perspectiva Alternativa
 - Minimização do Erro
 - Ortogonalização
- 6 Consistência

Modelo de Regressão Linear

- Vamos mostrar que o estimador de MQO é não viesado no modelo de regressão linear.
- Sabemos que

$$\mathbb{E}(y_i|\mathbf{X}) = \mathbb{E}(y_i|\mathbf{x}_i) = \mathbf{x}_i'\boldsymbol{\beta} \quad (1)$$

- **Nota:** a *primeira igualdade* estabelece que a esperança condicional de y_i dado $\{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ depende apenas de \mathbf{x}_i dado que as observações são independentes entre i . A *segunda igualdade* é o pressuposto de uma média condicional linear.

- Assim,

$$\mathbb{E}(\mathbf{y}|\mathbf{X}) = \begin{pmatrix} \vdots \\ \mathbb{E}(y_i|\mathbf{X}) \\ \vdots \end{pmatrix} = \begin{pmatrix} \vdots \\ \mathbf{x}_i'\boldsymbol{\beta} \\ \vdots \end{pmatrix} = \mathbf{X}\boldsymbol{\beta} \quad (2)$$

- De forma similar

$$\mathbb{E}(\mathbf{e}|\mathbf{X}) = \begin{pmatrix} \vdots \\ \mathbb{E}(e_i|\mathbf{X}) \\ \vdots \end{pmatrix} = \begin{pmatrix} \vdots \\ \mathbb{E}(e_i|\mathbf{x}_i) \\ \vdots \end{pmatrix} = \mathbf{0} \quad (3)$$

Estimador de MQO

- Usando a definição de que $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\mathbf{y})$, o teorema do condicionamento e as propriedades de matriz inversa, temos:

$$\begin{aligned}\mathbb{E}(\hat{\beta}|\mathbf{X}) &= \left(\mathbb{E}(\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\mathbf{y})|\mathbf{X}\right) \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbb{E}(\mathbf{y}|\mathbf{X}) \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\beta \\ &= \beta\end{aligned}\tag{4}$$

Estimador de MQO

- Outra forma de obter o mesmo resultado é inserindo $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}$ em $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\mathbf{y})$:

$$\begin{aligned}\hat{\boldsymbol{\beta}} &= (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'(\mathbf{X}\boldsymbol{\beta} + \mathbf{e})) \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\mathbf{e}) \\ &= \boldsymbol{\beta} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{e}\end{aligned}\tag{5}$$

- Essa decomposição para $\hat{\boldsymbol{\beta}}$ tem o verdadeiro parâmetro $\boldsymbol{\beta}$ e o componente estocástico $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{e}$.

- Podemos calcular que

$$\begin{aligned}\mathbb{E}(\hat{\beta} - \beta | \mathbf{X}) &= \mathbb{E}((\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{e} | \mathbf{X}) \\ &= (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbb{E}(\mathbf{e} | \mathbf{X}) \\ &= \mathbf{0}\end{aligned}\tag{6}$$

- Independente do método temos que $\mathbb{E}(\hat{\beta} | \mathbf{X}) = \beta$. Usando a lei das expectativas iteradas temos:

$$\mathbb{E}(\hat{\beta}) = \mathbb{E}(\mathbb{E}(\hat{\beta} | \mathbf{X})) = \beta\tag{7}$$

Teorema (Esperança do Estimador de Mínimos Quadrados)

Em um modelo de regressão linear

$$\mathbb{E}(\hat{\beta}|\mathbf{X}) = \beta \quad (8)$$

e

$$\mathbb{E}(\hat{\beta}) = \beta \quad (9)$$

- Eq. (9) diz que o estimador $\mathbb{E}(\hat{\beta})$ é não visado para β , indicando que a distribuição de $\mathbb{E}(\hat{\beta})$ está centrada em β .
- Eq. (8) diz que o estimador condicional é não viesado. **Esse é um resultado mais forte!** Ele indica que $\mathbb{E}(\hat{\beta})$ é não viesado para qualquer realização da matriz de regressores \mathbf{X} .

Variância do Estimador de MQO

- Vamos calcular a variância condicional do estimador de MQO.
- Para qualquer vetor aleatório \mathbf{Z} definimos uma matriz de covariância $r \times r$

$$\begin{aligned}\text{var}(\mathbf{Z}) &= \mathbb{E}(\mathbf{Z} - \mathbb{E}[\mathbf{Z}])(\mathbf{Z} - \mathbb{E}[\mathbf{Z}])' \\ &= \mathbb{E}(\mathbf{Z}\mathbf{Z}') - (\mathbb{E}\mathbf{Z})(\mathbb{E}\mathbf{Z})'\end{aligned}\quad (10)$$

e para qualquer par (\mathbf{Z}, \mathbf{X}) definimos a matriz de variância condicional

$$\text{var}(\mathbf{Z}|\mathbf{X}) = \mathbb{E}[(\mathbf{Z} - \mathbb{E}[\mathbf{Z}|\mathbf{X}])(\mathbf{Z} - \mathbb{E}[\mathbf{Z}|\mathbf{X}])'] \quad (11)$$

- Definimos $\mathbf{V}_{\hat{\beta}} \stackrel{\text{def}}{=} \text{var}[\hat{\beta}|\mathbf{X}]$ como a matriz de covariância condicional dos estimadores dos coeficientes de regressão.

- A matriz de covariância condicional $n \times 1$ do erro de regressão e é a matriz $n \times n$

$$\text{var}[e|\mathbf{X}] = \mathbb{E}[ee'|\mathbf{X}] \stackrel{\text{def}}{=} \mathbf{D} \quad (12)$$

- O i -ésimo elemento da diagonal de \mathbf{D} é

$$\mathbb{E}(e_i^2|\mathbf{X}) = \mathbb{E}(e_i^2|\mathbf{x}_i) = \sigma_i^2 \quad (13)$$

enquanto o j -ésimo elemento fora da diagonal principal de \mathbf{D} é

$$\mathbb{E}(e_i e_j|\mathbf{X}) = \mathbb{E}(e_i|\mathbf{x}_i)\mathbb{E}(e_j|\mathbf{x}_j) = 0. \quad (14)$$

em que a primeira igualdade usa a independência das observações e a segunda sai do fato de que $\mathbb{E}(e|\mathbf{X}) = 0$.

- Então \mathbf{D} é uma matriz diagonal com o i -ésimo elemento da diagonal σ_i^2 :

$$\mathbf{D} = \text{diag}(\sigma_1^2, \dots, \sigma_n^2) = \begin{pmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_n^2 \end{pmatrix} \quad (15)$$

- No caso especial do modelo de regressão linear homocedástico, temos:

$$\mathbb{E}(e_i^2 | \mathbf{x}_i) = \mathbb{E}(e_i^2) = \sigma^2 \quad (16)$$

- Simplificando $\mathbf{D} = \mathbf{I}_n \sigma^2$.
- No modelo de regressão linear homocedástico, $\mathbf{D} = \mathbf{I}_n \sigma^2$, então $\mathbf{X}'\mathbf{D}\mathbf{X} = \mathbf{X}'\mathbf{X}\sigma^2$, e a matriz de covariância é simplificada para $\widehat{V}_{\hat{\beta}} = \mathbf{X}'\mathbf{X}\sigma^2$.

Teorema (Estimador da Variância dos Mínimos Quadrados)

Em um modelo de regressão linear com amostra i.i.d.

$$V_{\hat{\beta}} = \text{var}[\hat{\beta}|\mathbf{X}] = (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\mathbf{D}\mathbf{X})(\mathbf{X}'\mathbf{X})^{-1} \quad (17)$$

em que \mathbf{D} é definida pela eq. (15). Se o termo de erro é homocedástico, então a eq. (17) é simplificada para

$$V_{\hat{\beta}} = \sigma^2(\mathbf{X}'\mathbf{X})^{-1} \quad (18)$$

Teorema de Gauss-Markov

- Considere a classe de estimadores de β que são funções lineares do vetor \mathbf{y} e que pode ser escrito como

$$\tilde{\beta} = \mathbf{A}'\mathbf{y} \quad (19)$$

em que \mathbf{A} é uma matriz $n \times k$ função de \mathbf{X} .

- O estimador de MQO é um caso especial fazendo $\mathbf{A} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}$.
- **Questão:** qual é a melhor escolha de \mathbf{A} ?
- *Pelo Teorema de Gauss-Markov, o estimador de mínimos quadrados é a melhor escolha entre os estimadores lineares não viesados porque possui a menor variância entre todos os estimadores lineares não viesados.*

- Como $\mathbb{E}[\mathbf{y}|\mathbf{X}] = \mathbf{X}\boldsymbol{\beta}$, então para qualquer estimador linear $\tilde{\boldsymbol{\beta}} = \mathbf{A}'\mathbf{y}$, temos

$$\mathbb{E}[\tilde{\boldsymbol{\beta}}|\mathbf{X}] = \mathbf{A}'\mathbb{E}[\mathbf{y}|\mathbf{X}] = \mathbf{A}'\mathbf{X}\boldsymbol{\beta} \quad (20)$$

- Assim, $\tilde{\boldsymbol{\beta}}$ é não viesado se e apenas se $\mathbf{A}'\mathbf{X} = \mathbf{I}_k$ e

$$\text{var}[\tilde{\boldsymbol{\beta}}|\mathbf{X}] = \text{var}[\mathbf{A}'\mathbf{y}|\mathbf{X}] = \mathbf{A}'\mathbf{D}\mathbf{A} = \mathbf{A}'\mathbf{A}\sigma^2 \quad (21)$$

a última igualdade vem do pressuposto de homocedasticidade $\mathbf{D} = \mathbf{I}_n\sigma^2$.

- O **melhor** estimador linear não viesado é obtido encontrando a matriz \mathbf{A}_0 que satisfaz a condição $\mathbf{A}_0'\mathbf{X} = \mathbf{I}_k$ tal que $\mathbf{A}_0'\mathbf{A}_0$ é minimizado no sentido positivo definido, o que significa que para qualquer outra matriz \mathbf{A} que satisfaz $\mathbf{A}'\mathbf{X} = \mathbf{I}_k$ então $\mathbf{A}'\mathbf{A} - \mathbf{A}_0'\mathbf{A}_0$ é positiva semi-definida.

Teorema (Gauss-Markov)

Em um modelo de regressão linear homocedástico com amostra i.i.d., se $\tilde{\beta}$ é um estimador linear não viesado de β , então

$$\text{var} [\tilde{\beta}|\mathbf{x}] \geq \sigma^2(\mathbf{X}'\mathbf{X})^{-1} \quad (22)$$

Intuição: o teorema Gauss-Markov fornece um limite inferior na matriz de covariância de estimadores lineares não viesados sob a suposição de homocedasticidade. Por esse teorema, nenhum estimador linear não viesado pode ter uma matriz de variância menor (no sentido positivo definido) do que $\sigma^2(\mathbf{X}'\mathbf{X})^{-1}$.

Ausência de Viés

- Seja A ser uma função $n \times k$ de X tal que $A'X = I_k$.
- O estimador $A'y$ é não viesado para β e tem variância $A'A\sigma^2$.
- Como o estimador de mínimos quadrados é não viesado e tem variância $(X'X)^{-1}\sigma^2$, é suficiente para mostrar que a diferença nas duas matrizes de variância é positiva semi-definida, ou:

$$A'A \geq (X'X)^{-1} \quad (23)$$

- Seja $C = A - X(X'X)^{-1}$.
- Note que $X'C = 0$.

- Podemos calcular que:

$$\begin{aligned}
 \mathbf{A}'\mathbf{A} - (\mathbf{X}'\mathbf{X})^{-1} &= \left(\mathbf{C} + \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\right)' \left(\mathbf{C} + \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\right) \\
 &\quad - (\mathbf{X}'\mathbf{X})^{-1} \\
 &= \mathbf{C}'\mathbf{C} + \mathbf{C}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{C} \\
 &\quad + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} - (\mathbf{X}'\mathbf{X})^{-1} \\
 &= \mathbf{C}'\mathbf{C} \geq 0.
 \end{aligned} \tag{24}$$

- A desigualdade final estabelece que a matriz $\mathbf{C}'\mathbf{C}$ é positiva semi-definida que é uma propriedade das formas quadráticas. Com isso demostramos a eq. (23).

Resíduos

- Vamos olhar as propriedades dos resíduos, $\hat{e}_i = y_i - \mathbf{x}_i'\hat{\boldsymbol{\beta}}$, e dos erros de previsão $\tilde{e}_i = y_i - \mathbf{x}_i'\hat{\boldsymbol{\beta}}_{(-i)}$. Podemos escrever os resíduos como:

$$\hat{\mathbf{e}} = \mathbf{M}\mathbf{e} \quad (25)$$

em que $\mathbf{M} = \mathbf{I}_n - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ é a matriz de projeção ortogonal.

- Usando as propriedades da esperança condicional

$$\begin{aligned} \mathbb{E}(\hat{\mathbf{e}}|\mathbf{X}) &= \mathbb{E}(\mathbf{M}\mathbf{e}|\mathbf{X}) \\ &= \mathbf{M}\mathbb{E}(\mathbf{e}|\mathbf{X}) = \mathbf{0} \end{aligned} \quad (26)$$

e

$$\begin{aligned} \text{var}(\hat{\mathbf{e}}|\mathbf{X}) &= \text{var}(\mathbf{M}\mathbf{e}|\mathbf{X}) \\ &= \mathbf{M} \text{var}(\mathbf{e}|\mathbf{X}) \mathbf{M} = \mathbf{M}\mathbf{D}\mathbf{M} \end{aligned} \quad (27) \quad 18/80$$

- Podemos simplificar essa expressão sob o pressuposto de homocedasticidade condicional: $\mathbb{E}(e^2|\mathbf{x}_i) = \sigma^2$. Neste caso, a eq. (27) é simplificada para

$$\text{var}(\hat{\mathbf{e}}|\mathbf{X}) = \mathbf{M}\sigma^2$$

- Para uma única observação i , podemos encontrar a variância de \hat{e}_i considerando o i -ésimo elemento da diagonal de $\text{var}(\hat{\mathbf{e}}|\mathbf{X}) = \mathbf{M}\sigma^2$. Assim temos:

$$\text{var}(\hat{e}_i|\mathbf{X}) = \mathbb{E}(\hat{e}_i^2|\mathbf{X}) = (1 - h_{ii})\sigma^2 \quad (28)$$

em que $h_{ii} = \mathbf{X}_i'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}_i$. Como esta variância é uma função de h_{ii} e, portanto, \mathbf{x}_i , os resíduos \hat{e}_i são heterocedásticos mesmo se os erros e_i são homocedásticos. Observe que eq. (28) implica \hat{e}_i^2 é um estimador viesado de σ^2 .

Erros de Previsão

- Vamos escrever os erros de previsão $\tilde{e}_i = (1 - h_{ii})^{-1} \hat{e}_i$ em notação vetorial como $\tilde{\mathbf{e}} = \mathbf{M}^* \hat{\mathbf{e}}$ em que \mathbf{M}^* é a matriz diagonal com i -ésimo elemento $(1 - h_{ii})^{-1}$. Então $\tilde{\mathbf{e}} = \mathbf{M}^* \mathbf{M} \mathbf{e}$ pode ser calculada como

$$\mathbb{E}(\tilde{\mathbf{e}}|\mathbf{X}) = \mathbf{M}^* \mathbf{M} \mathbb{E}(\mathbf{e}|\mathbf{X}) = \mathbf{0} \quad (29)$$

e

$$\begin{aligned} \text{var}(\tilde{\mathbf{e}}|\mathbf{X}) &= \mathbf{M}^* \mathbf{M} \text{var}(\mathbf{e}|\mathbf{X}) \mathbf{M} \mathbf{M}^* \\ &= \mathbf{M}^* \mathbf{M} \mathbf{D} \mathbf{M} \mathbf{M}^* \end{aligned} \quad (30)$$

- Que simplifica sob homocedasticidade para

$$\begin{aligned} \text{var}(\tilde{\mathbf{e}}|\mathbf{X}) &= \mathbf{M}^* \mathbf{M} \mathbf{M} \mathbf{M}^* \sigma^2 \\ &= \mathbf{M}^* \mathbf{M} \mathbf{M}^* \sigma^2 \end{aligned} \quad (31)$$

- A variância do *i*-ésimo erro de previsão é então dada por:

$$\begin{aligned}\text{var}(\tilde{e}|\mathbf{X}) &= \mathbb{E}(\tilde{e}_i^2|\mathbf{X}) \\ &= (1 - h_{ii})^{-1}(1 - h_{ii})(1 - h_{ii})^{-1}\sigma^2 \\ &= (1 - h_{ii})^{-1}\sigma^2\end{aligned}\tag{32}$$

Erros Padronizados

- Um resíduo com variância condicional constante pode ser obtido reescalando. Os **resíduos padronizados** são:

$$\bar{e}_i = (1 - h_{ii})^{-1/2} \hat{e}_i^2 \quad (33)$$

- Em notação vetorial

$$\bar{\mathbf{e}} = (\bar{e}_1, \dots, \bar{e}_n)' = (\mathbf{M}^*)^{1/2} \mathbf{M} \mathbf{e} \quad (34)$$

- Pelos cálculos anteriores, sob homocedasticidade temos

$$\text{var}(\bar{\mathbf{e}}|\mathbf{X}) = (\mathbf{M}^*)^{1/2} \mathbf{M} (\mathbf{M}^*)^{1/2} \sigma^2 \quad (35)$$

e

$$\text{var}(\bar{e}_i|\mathbf{X}) = \mathbb{E}(\bar{e}_i^2|\mathbf{X}) = \sigma^2 \quad (36)$$

- Estes resíduos padronizados possuem o mesmo viés e variância como os erros originais quando os últimos são homocedásticos.

Estimação da Variância do Erro

- A variância do erro $\sigma^2 = \mathbb{E}(e_i^2)$ mensura a variação na parte “*não explicada*” da regressão.
- O seu estimador do método dos momentos é a média amostral dos resíduos ao quadrado:

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \hat{e}_i^2 \quad (37)$$

- No modelo de regressão linear podemos calcular a média de $\hat{\sigma}^2$. Usando as propriedades das matrizes de projeção e o operador do traço, observe que:

$$\begin{aligned} \hat{\sigma}^2 &= \frac{1}{n} \hat{\mathbf{e}}' \hat{\mathbf{e}} = \frac{1}{n} \mathbf{e}' \mathbf{M} \mathbf{M} \mathbf{e} = \frac{1}{n} (\mathbf{e}' \mathbf{M} \mathbf{e}) \\ &= \frac{1}{n} \text{tr}(\mathbf{e}' \mathbf{M} \mathbf{e}) = \frac{1}{n} \text{tr}(\mathbf{M} \mathbf{e}' \mathbf{e}) \end{aligned} \quad (38)$$

- Então,

$$\begin{aligned}\mathbb{E}(\hat{\sigma}^2|\mathbf{X}) &= \frac{1}{n} \operatorname{tr}(\mathbb{E}(\mathbf{M}\mathbf{e}\mathbf{e}')|\mathbf{X}) \\ &= \frac{1}{n} \operatorname{tr}(\mathbf{M}\mathbb{E}(\mathbf{e}\mathbf{e}')|\mathbf{X}) \\ &= \frac{1}{n} \operatorname{tr}(\mathbf{M}\mathbf{D})\end{aligned}\tag{39}$$

- Inserindo o pressuposto de homocedasticidade $\mathbb{E}(e_i^2|\mathbf{x}_i) = \sigma^2$, então $\mathbf{D} = \mathbf{I}_n\sigma^2$.
- Assim, a eq. (39) é simplificada para

$$\begin{aligned}\mathbb{E}(\hat{\sigma}^2|\mathbf{X}) &= \frac{1}{n} \text{tr}(\mathbf{M}\sigma^2) \\ &= \frac{\sigma^2}{n} \text{tr}(\mathbf{M}) \\ &= \frac{\sigma^2}{n} \text{tr}(\mathbf{I}_n - \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}') \\ &= \frac{\sigma^2}{n} \text{tr}(\mathbf{I}_n - \mathbf{I}_k) \\ &= \sigma^2 \left(\frac{n-k}{n} \right)\end{aligned}\tag{40}$$

- Esse resultado mostra que a σ^2 é viesada para zero. A ordem do viés depende de $\frac{k}{n}$, a razão do número de coeficientes estimados para o tamanho da amostra. Como o viés toma a forma escalar, um método clássico para obter um estimador não viesado é reescalando o estimador. Defina

$$s^2 = \frac{1}{n - k} \sum_{i=1}^n e_i^2 \quad (41)$$

- Pelas contas anteriores temos

$$\mathbb{E} \left(s^2 | \mathbf{X} \right) = \hat{\sigma}^2 \quad (42)$$


- Assim,

$$\mathbb{E} \left(s^2 \right) = \sigma^2 \quad (43)$$

- O estimador s^2 é não viesado para σ^2 .

Estimação da Matriz de Covariância sob Homocedasticidade

Figura 1: Caso Homocedástico



- Para fazer inferência necessitamos estimar a matriz de covariância $V_{\hat{\beta}}$ do estimador de mínimos quadrados. Vamos considerar o modelo de regressão linear.
- Sob homocedasticidade, a matriz de covariância toma uma forma relativamente simples

$$V_{\hat{\beta}} = \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \sigma^2 \quad (44)$$

que é conhecida para o desconhecido escalar σ^2 . O estimador mais comum utilizado para σ^2 é s^2 , levando ao estimador clássico da matriz de covariância

$$\widehat{V}_{\hat{\beta}}^0 = \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} s^2 \quad (45)$$

- Como s^2 é condicionalmente não viesado para σ^2 , é fácil calcular que $\widehat{\mathbf{V}}_{\widehat{\beta}}^0$ é condicionalmente não viesada para $\mathbf{V}_{\widehat{\beta}}$ sob o pressuposto de homocedasticidade:

$$\begin{aligned}
 \mathbb{E} \left(\widehat{\mathbf{V}}_{\widehat{\beta}}^0 \middle| \mathbf{X} \right) &= \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \mathbb{E} \left(s^2 \middle| \mathbf{X} \right) \\
 &= \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \sigma^2 \\
 &= \mathbf{V}_{\widehat{\beta}}
 \end{aligned} \tag{46}$$


- Este estimador era o estimador de matriz de covariância dominante em econometria aplicada nos últimos tempos, e ainda é *default* na maioria dos *softwares* de regressão.

- Se o estimador dado pela eq. (45) é utilizado, mas o erro da regressão é **heterocedástico**, é possível que $\widehat{\mathbf{V}}_{\hat{\beta}}^0$ seja totalmente viesado para a matriz de covariância correta:

$$\mathbf{V}_{\hat{\beta}} = \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \left(\frac{1}{n} \mathbf{X}' \mathbf{D} \mathbf{X} \right) \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \quad (47)$$

Estimação da Matriz de Covariância sob Heterocedasticidade

Figura 2: Caso Heterocedástico



- Para qualquer matriz $n \times r$ $\mathbf{A} = \mathbf{A}(\mathbf{X})$,

$$\text{var}(\mathbf{A}'\mathbf{y}|\mathbf{X}) = \text{var}(\mathbf{A}'\mathbf{e}|\mathbf{X}) = \mathbf{A}'\mathbf{D}\mathbf{A} \quad (48)$$

- Em particular, podemos escrever $\hat{\boldsymbol{\beta}} = \mathbf{A}'\mathbf{y}$ onde $\mathbf{A} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}$ e assim

$$\text{var}(\hat{\boldsymbol{\beta}}|\mathbf{X}) = \mathbf{A}'\mathbf{D}\mathbf{A} = (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\mathbf{D}\mathbf{X})(\mathbf{X}'\mathbf{X})^{-1} \quad (49)$$

- É útil notar que

$$(\mathbf{X}'\mathbf{D}\mathbf{X}) = \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' \sigma_i^2 \quad (50)$$

é uma versão ponderada de $\mathbf{X}'\mathbf{X}$.

- Se a hipótese de variância constante, homocedasticidade, não se verificar, o estimador da matriz de variância pode ser altamente viesado.
- A forma geral da matriz de covariância é dada por:

$$\mathbf{V}_{\hat{\beta}} = \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \left(\frac{1}{n} \mathbf{X}' \mathbf{D} \mathbf{X} \right) \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \quad (51)$$

- Como pode ser observado, essa matriz depende de \mathbf{D} que é uma matriz desconhecida e que pode ser escrita como:

$$\mathbf{D} = \text{diag} \left\{ \sigma_1^2, \dots, \sigma_n^2 \right\} = \mathbb{E}(\mathbf{e} \mathbf{e}' | \mathbf{X}) = \mathbb{E}(\mathbf{D}_0 | \mathbf{X}) \quad (52)$$

em que $\mathbf{D}_0 = \text{diag}(e_1^2, \dots, e_n^2)$. Assim, \mathbf{D}_0 é um estimador não viesado para \mathbf{D} .

Matriz de Variância Ótima

- Se os erros ao quadrado e_i^2 fossem observados, poderíamos construir um estimador não viesado dado por

$$\begin{aligned}
 \widehat{\mathbf{V}}_{\widehat{\beta}}^{ideal} &= \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \left(\frac{1}{n} \mathbf{X}' \mathbf{D}_0 \mathbf{X} \right) \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \\
 &= \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' e_i^2 \right) \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \quad (53)
 \end{aligned}$$

- Usando o operador de esperança condicional, temos:

$$\begin{aligned}
 \mathbb{E} \left(\widehat{\mathbf{V}}_{\widehat{\beta}}^{ideal} | \mathbf{X} \right) &= \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \left(\frac{1}{n} \mathbf{X}' \mathbf{D}_0 \mathbf{X} \right) \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \\
 &= \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' \mathbb{E} \left(e_i^2 \right) \middle| \mathbf{X} \right) \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \\
 &= \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' \sigma_i^2 \right) \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \\
 &= \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \left(\frac{1}{n} \mathbf{X}' \mathbf{D} \mathbf{X} \right) \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \\
 &= \mathbf{V}_{\widehat{\beta}}
 \end{aligned} \tag{54}$$

- Mostrando que $\mathbb{E} \left(\widehat{\mathbf{V}}_{\widehat{\beta}}^{ideal} | \mathbf{X} \right)$ é não viesado para $\mathbf{V}_{\widehat{\beta}}$.
- Como e_i^2 não são observados, $\mathbb{E} \left(\widehat{\mathbf{V}}_{\widehat{\beta}}^{ideal} | \mathbf{X} \right)$ **não é um estimador factível**.
- **Qual é a alternativa?** Podemos usar os resíduos ao quadrado, \widehat{e}_i^2 , os erros de previsão, \widetilde{e}_i^2 ou os resíduos padronizados, \bar{e}_i^2 , para construir um estimador factível.

- Seja

$$\widehat{\mathbf{D}} = \text{diag} \left(\widehat{e}_i^2, \dots, \widehat{e}_n^2 \right), \quad (55)$$

$$\widetilde{\mathbf{D}} = \text{diag} \left(\widetilde{e}_i^2, \dots, \widetilde{e}_n^2 \right), \quad (56)$$

$$\overline{\mathbf{D}} = \text{diag} \left(\overline{e}_i^2, \dots, \overline{e}_n^2 \right) \quad (57)$$

- Obtemos os estimadores substituindo essas matrizes na eq. (51) para $\mathbf{V}_{\widehat{\beta}}$. Assim,

$$\begin{aligned} \widehat{\mathbf{V}}_{\widehat{\beta}}^{HC0} &= \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \left(\frac{1}{n} \mathbf{X}' \widehat{\mathbf{D}} \mathbf{X} \right) \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \\ &= \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' \widehat{e}_i^2 \right) \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \end{aligned} \quad (58)$$

em que o rótulo HC0 se refere a ser estimador *baseline* da matriz de covariância consistente a heterocedasticidade (White, 1980, Econometrica).

- Como \hat{e}_i^2 é viesado para zero, para estimar a σ^2 o estimador não viesado s^2 pode ajustar o estimador de momentos $\hat{\sigma}^2$ pelos graus de liberdade $\left(\frac{n}{n-k}\right)$.
- O estimador HC1 é recomendado em relação ao HC0.

$$\widehat{\mathbf{V}}_{\hat{\beta}}^{HC1} = \left(\frac{n}{n-k}\right) \left(\frac{1}{n} \mathbf{X}' \mathbf{X}\right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' \hat{e}_i^2\right) \left(\frac{1}{n} \mathbf{X}' \mathbf{X}\right)^{-1} \quad (59)$$

- Uma alternativa é ajustar pela matriz de projeção P (MacKinnon and White, 1985):

$$\begin{aligned}
 \overline{\mathbf{V}}_{\hat{\beta}}^{HC2} &= \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \left(\frac{1}{n} \mathbf{X}' \overline{\mathbf{D}} \mathbf{X} \right) \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \\
 &= \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' \bar{e}_i^2 \right) \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \\
 &= \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n (1 - h_{ii})^{-1} \mathbf{x}_i \mathbf{x}_i' \hat{e}_i^2 \right) \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1}
 \end{aligned} \tag{60}$$

- Por fim, temos uma variação do HC2 (Davidson and MacKinnon, 1993):

$$\begin{aligned}
 \widetilde{\mathbf{V}}_{\widehat{\beta}}^{HC3} &= \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \left(\frac{1}{n} \mathbf{X}' \widetilde{\mathbf{D}} \mathbf{X} \right) \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \\
 &= \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' \widehat{e}_i^2 \right) \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \\
 &= \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n (1 - h_{ii})^{-2} \mathbf{x}_i \mathbf{x}_i' \widehat{e}_i^2 \right) \left(\frac{1}{n} \mathbf{X}' \mathbf{X} \right)^{-1}
 \end{aligned} \tag{61}$$

- Os estimadores HC0, HC1, HC2 e HC3 são chamados de estimadores da matriz de variância robusto ou robusto à heterocedasticidade.
- **HC0** é o estimador da matriz de variância de White; **HC1** é o estimador da matriz de variância robusto ajustado pelos graus de liberdade.

- **Resumindo:** temos cinco estimadores da matriz de variância, incluindo o estimador homocedástico \widehat{V}_{β}^0 e os quatro estimadores HC.
- **Qual deveríamos utilizar?**
 - ① A escolha do estimador \widehat{V}_{β}^0 é pobre na medida em que ele é válido apenas sobre a improvável restrição de homocedasticidade.
 - ② Dos estimadores robustos HC, o HC1 é o mais usado é *default* em programas como o Stata. Mas os estimadores HC2 e HC3 são preferíveis.
- O estimador HC2 é não viesado sob homocedasticidade e o estimador HC3 é conservador para qualquer \mathbf{X} . Na maioria das aplicações HC1, HC2 e HC3 serão similares.

Erro Padrão

- O estimador da variância tal como $n^{-1}\widehat{\mathbf{V}}_{\widehat{\beta}}$ é um estimador da variância da distribuição de $\widehat{\beta}$. Uma medida facilmente interpretável do risco é sua raiz quadrada – desvio-padrão.

Definição

Um **erro padrão** $s(\widehat{\beta})$ para um estimador β com valor real é uma estimativa do desvio-padrão da distribuição de $\widehat{\beta}$. Isto é

$$s(\widehat{\beta}_j) = \sqrt{n^{-1}\widehat{\mathbf{V}}_{\widehat{\beta}_j}} = n^{-1/2} \sqrt{\left[\widehat{\mathbf{V}}_{\widehat{\beta}_{jj}}\right]} \quad (62)$$

Mínimos Quadrados Generalizados

- Considere o modelo de regressão linear:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e} \quad (63)$$

- Considere uma situação onde as observações dos **erros são heterocedásticos**. Suponha que

$$\mathbb{E}[\mathbf{e}|\mathbf{X}] = \mathbf{0} \quad (64)$$

$$\text{var}[\mathbf{e}|\mathbf{X}] = \boldsymbol{\Omega} \quad (65)$$

- A matriz de variância $\boldsymbol{\Omega}$ possui dimensão $n \times n$ e é possivelmente uma função de \mathbf{X} . A estrutura da amostra é *i.i.d.* em que $\boldsymbol{\Omega} = \mathbf{D}$, permitindo matrizes de covariâncias não diagonais também. A matriz $\boldsymbol{\Omega}$ é simétrica e positiva semi-definida.

- Considerando esses pressupostos, podemos calcular a média e a variância do estimador de mínimos quadrados:

$$\mathbb{E} [\hat{\beta} | \mathbf{X}] = \beta \quad (66)$$

$$\text{var} [\hat{\beta} | \mathbf{X}] = (\mathbf{X}' \mathbf{X})^{-1} (\mathbf{X}' \Omega \mathbf{X}) (\mathbf{X}' \mathbf{X})^{-1} \quad (67)$$

- Considere que a matriz Ω seja conhecida. Suponha que ela tenha a forma $\Omega = c^2 \Sigma$ em que $c^2 > 0$ é um numero real e Σ é conhecida e tem dimensão $n \times n$.
- Pré-multiplique o modelo linear $\mathbf{y} = \mathbf{X}\beta + \mathbf{e}$ por $\Sigma^{-1/2}$. Isto irá gerar a equação

$$\tilde{\mathbf{y}} = \tilde{\mathbf{X}}\beta + \tilde{\mathbf{e}} \quad (68)$$

em que $\tilde{\mathbf{y}} = \Sigma^{-1/2} \mathbf{y}$, $\tilde{\mathbf{X}} = \Sigma^{-1/2} \mathbf{X}$ e $\tilde{\mathbf{e}} = \Sigma^{-1/2} \mathbf{e}$.

- O estimador de mínimos quadrados de β nesta equação é dado por:

$$\begin{aligned}
 \tilde{\beta}_{MQG} &= \left(\tilde{\mathbf{X}}' \tilde{\mathbf{X}} \right)^{-1} \tilde{\mathbf{X}}' \tilde{\mathbf{y}} \\
 &= \left(\left(\Sigma^{-1/2} \mathbf{X} \right)' \left(\Sigma^{-1/2} \mathbf{X} \right)^{-1} \right) \mathbf{X}' \mathbf{y} \\
 &= \left(\mathbf{X}' \Sigma^{-1} \mathbf{X} \right) \mathbf{X}' \Sigma^{-1} \mathbf{y}
 \end{aligned} \tag{69}$$

- Este é o estimador de **Mínimos Quadrados Generalizados (MQG)** de β . Podemos calcular:

$$\mathbb{E} \left[\tilde{\beta}_{MQG} | \mathbf{X} \right] = \beta \tag{70}$$

$$\text{var} \left[\tilde{\beta}_{MQG} | \mathbf{X} \right] = \left(\mathbf{X}' \Omega^{-1} \mathbf{X} \right)^{-1} \tag{71}$$

- Isto mostra que o estimador de MQG é não viesado e possui uma matriz de variância que é igual ao limite inferior do Teorema de Gauss-Markov Generalizado.

- Isso mostra que o limite inferior é nítido quando Σ é conhecido. **MQG, portanto, é eficiente na classe dos estimadores lineares não viesados.**

Teorema (Gauss-Markov Generalizado)

No modelo de regressão linear e $\Sigma > 0$, se $\tilde{\beta}$ é um estimador linear não viesado de β , então

$$\text{var} [\tilde{\beta} | \mathbf{X}] \geq (\mathbf{X}' \Omega^{-1} \mathbf{X})^{-1} \quad (72)$$

- **Intuição:** o teorema fornece um limite inferior na matriz de variância dos estimadores lineares não viesados.
- O limite é diferente da matriz de variância do estimador de mínimos quadrados exceto quando $\Sigma = \mathbf{I}_n \sigma^2$.

- No modelo de regressão linear com observações independentes e matriz variância condicional conhecida, tal que $\Omega = \Sigma = \mathbf{D} = \text{diag}(\sigma_1^2, \dots, \sigma_n^2)$, o estimador de MQG toma a forma:

$$\begin{aligned}\tilde{\beta}_{MQG} &= \left(\mathbf{X}'\mathbf{D}^{-1}\mathbf{X}\right)^{-1}\mathbf{X}'\mathbf{D}^{-1}\mathbf{y} \\ &= \left(\sum_{i=1}^n \sigma_i^{-2}\mathbf{x}_i\mathbf{x}_i'\right)^{-1}\left(\sum_{i=1}^n \sigma_i^{-2}\mathbf{x}_i\mathbf{y}_i\right)\end{aligned}\quad (73)$$

- O pressuposto $\Omega > 0$ neste caso se reduz para $\sigma_i^2 > 0$ para $i = 1, \dots, n$.
- **Nota:** na prática, a matriz de variância Ω é não conhecida e, assim, o estimador factível como descrito aqui não é factível.

Medidas de Ajuste


- A medida mais comum reportada do ajuste da regressão é o R^2 definido como

$$R^2 = 1 - \frac{\sum_{i=1}^n \hat{e}_i^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{\hat{\sigma}_y^2}{\sigma_y^2} \quad (74)$$

em que $\hat{\sigma}_y^2 = n^{-1} \sum_{i=1}^n (y_i - \bar{y})^2$. O R^2 pode ser visto como um estimador do parâmetro populacional

$$\rho^2 = \frac{\text{var}(\mathbf{x}'_i \boldsymbol{\beta})}{\text{var}(y_i)} = 1 - \frac{\sigma^2}{\sigma_y^2} \quad (75)$$

- Contudo, $\hat{\sigma}^2$ e $\hat{\sigma}_y^2$ são estimadores viesados.

Figura 3: Geometria do R^2 

- Theil (1961) propôs substituir estes pela versão não viesada s^2 e $\tilde{\sigma}_y^2 = (n-1)^{-1} \sum_{i=1}^n (y_i - \bar{y})^2$ gerando o R^2 ajustado (\overline{R}^2):

$$\begin{aligned}\overline{R}^2 &= 1 - \frac{s^2}{\tilde{\sigma}_y^2} \\ &= 1 - \frac{(n-1)^{-1} \sum_{i=1}^n \hat{e}_i^2}{(n-k)^{-1} \sum_{i=1}^n (y_i - \bar{y})^2}\end{aligned}\tag{76}$$

- **Caso 1:** Considere a matriz a seguir

$$\mathbf{X} = \begin{bmatrix} 2 & 1 & 1 \\ 5 & 2 & 3 \\ -3 & 1 & -4 \end{bmatrix} \text{ e } (\mathbf{X}'\mathbf{X}) = \begin{bmatrix} 2 & 5 & -3 \\ 1 & 2 & 1 \\ 1 & 3 & -4 \end{bmatrix}' \times \begin{bmatrix} 2 & 1 & 1 \\ 5 & 2 & 3 \\ -3 & 1 & -4 \end{bmatrix}$$

- Na matriz \mathbf{X} a coluna 1 é uma combinação linear das colunas 2 e 3. Isso faz com que a matriz $\mathbf{X}'\mathbf{X}$ seja singular. Por isso, $(\mathbf{X}'\mathbf{X})^{-1}$ e $\hat{\beta}$ não são definidos.

- **Caso 2:** Considere a matriz

$$\mathbf{X} = \begin{bmatrix} 2 & 1 & 1 \\ 5 & 2 & 3 \\ -3 & 1 & -6 \end{bmatrix} \text{ e } (\mathbf{X}'\mathbf{X}) = \begin{bmatrix} 2 & 5 & -3 \\ 1 & 2 & 1 \\ 1 & 3 & -6 \end{bmatrix}' \times \begin{bmatrix} 2 & 1 & 1 \\ 5 & 2 & 3 \\ -3 & 1 & -6 \end{bmatrix}$$

- Na matriz \mathbf{X} a coluna 1 é quase uma combinação linear das colunas 2 e 3. Isso faz com que a matriz $\mathbf{X}'\mathbf{X}$ seja quase singular. Mesmo assim, $(\mathbf{X}'\mathbf{X})^{-1}$ e $\hat{\beta}$ são definidos.

Caso 1 Pode ser definido como **estrita multicolinearidade** ou **perfeita multicolinearidade**.

- Ocorre quando as colunas de \mathbf{X} são linearmente dependentes, isto é, existe algum $\alpha \neq 0$ tal que $\mathbf{X}\alpha = \mathbf{0}$.
- Esse caso **ocorre quando um conjunto de regressores são incluídos que são identicamente relacionados**.
- **Por exemplo:** se \mathbf{X} inclui ambos o log de dois preços e o log dos preços relativos ($\log(p_1)$, $\log(p_2)$ e $\log(p_1/p_2)$), então $\mathbf{X}'\mathbf{X}$ necessariamente será singular.
- Não será possível calcular a $(\mathbf{X}'\mathbf{X})^{-1}$ e obter o $\hat{\beta}$.

Caso 2 Pode ser definido como **quase multicolinearidade** ou **multicolinearidade**.

- Esta situação ocorre quando os regressores são altamente correlacionados.
- Uma implicação da multicolinearidade é que as estimativas dos coeficientes individuais serão imprecisas. Não chega a ser um problema para análise econométrica se os erros-padrão reportados são precisos (eficientes).
- Porém, erros-padrão robustos pode ser sensíveis a pequenas alterações nos dados sob multicolinearidade. Isto leva a uma situação indesejável em que as estimativas são imprecisas, embora os erros-padrão sejam enganosamente pequenos.
- Não será possível calcular $(\mathbf{X}'\mathbf{X})^{-1}$ e obter o $\hat{\beta}$.

- Vamos olhar esse último caso mais detalhadamente. Considere um modelo de regressão linear com apenas dois regressores:

$$y_i = x_{1i}\beta_1 + x_{2i}\beta_2 + e_i \quad (77)$$

e

$$\frac{1}{n}\mathbf{X}'\mathbf{X} = \begin{bmatrix} 1 & \rho \\ \rho & 1 \end{bmatrix} \quad (78)$$



- Neste caso temos:

$$\text{var}(\hat{\beta}|\mathbf{X}) = \frac{\sigma^2}{n} (\mathbf{X}'\mathbf{X})^{-1} = \frac{\sigma^2}{n(1-\rho^2)} \begin{bmatrix} 1 & -\rho \\ -\rho & 1 \end{bmatrix} \quad (79)$$

- A correlação ρ indexa a colinearidade. **Quando ρ aproxima de 1, a matriz se torna singular.**

- E a precisão das estimativas dos coeficientes? Para ver o efeito da multicolinearidade na precisão das estimativas, podemos observar a variância de uma estimativa dos coeficientes.
- Quando ρ se aproxima de 1, o termo $\sigma^2[n(1 - \rho^2)]^{-1}$ se aproxima do infinito. **Por isso, quanto mais “colinear” são os regressores, pior é a precisão das estimativas dos coeficientes individuais.**
- O que está acontecendo é que, quando os regressores são altamente dependentes, é estatisticamente difícil separar o impacto de β_1 de β_2 . Como consequência, a precisão das estimativas individuais são reduzidas.

Figura 4: Exemplo Geométrico da Multicolinearidade



Perspectiva Alternativa

- Vamos utilizar o modelo linear $\mathbf{y} = \mathbf{X}\beta + e$, onde e é o erro aleatório, \mathbf{X} é o regressor e y é o regressando. Às vezes \mathbf{X} vai ser um único regressando, às vezes X vai ser uma matriz de variáveis.
- Teremos n observações e p variáveis – então X é a matriz $n \times p$.
- No curso de econometria I da graduação, aprendemos que o estimador de mínimos quadrados para o caso univariado é:

$$\hat{\beta}_{MQO} = \frac{\sum_{i=1}^n (y_i - \bar{y})(x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2} \quad (80)$$

sendo \bar{x} a média de x e \bar{y} a média de y .

- A versão da pós do estimador de mínimos quadrados é:

$$\hat{\beta}_{MQO} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y} \quad (81)$$

- Isso é exatamente a mesma coisa que a versão acima, mas como agora tem mais de uma variável nós usamos matrizes.
- $\mathbf{X}'\mathbf{X}$ é a variância de \mathbf{X} e $\mathbf{X}'\mathbf{y}$ a covariância entre \mathbf{X} e \mathbf{y} .
- Para essa fórmula funcionar, $\mathbf{X}'\mathbf{X}$ tem que ser inversível, e portanto tem que ter *rank* completo. Nós usualmente pensamos isso como X não podendo ter duas variáveis que são funções afim uma da outra.

- Existem várias maneiras de introduzir o estimador de mínimos quadrados. A primeira advém da condição de momentos $\mathbb{E}[\mathbf{e}|\mathbf{X}] = 0$, ou mais fraco, a covariância entre \mathbf{X} e \mathbf{e} é zero.
- Outra maneira é pensar no problema de minimização:

$$\min_{\beta} \frac{1}{n} \sum_{i=1}^n (y_i - x'_i \beta)^2 \quad (82)$$

- Que pode ser escrito como

$$\|\mathbf{y} - \mathbf{X}\beta\|_2^2 = \sum_{i=1}^n (y_i - x'_i \beta)^2 \quad (83)$$

- Ainda existe outra maneira de motivar mínimos quadrados: suponha que y e x são dois vetores no \mathbb{R}^n .
- Vamos usar $\langle x, y \rangle$ como o produto interno $\left(\langle x, y \rangle = \sum_i x_i y_i \right)$.
- Como nós podemos transformar y de maneira que $\langle y - cx, x \rangle = 0$?
- Noutras palavras, nós queremos deixar os dois vetores ortogonais.

- No \mathbb{R}^2 , isso significa formar um ângulo reto:

$$\begin{aligned}\langle y - cx, x \rangle &= 0 \therefore \sum_i (y_i - cx_i)x_i = \sum_i y_i x_i - c \sum_i x_i^2 = 0 \\ \sum_i x_i y_i &= c \sum_i x_i^2 \\ c &= \frac{\sum_i x_i y_i}{\sum_i x_i^2}\end{aligned}\tag{84}$$


- Isso é exatamente a primeira expressão que escrevemos.

Prova da Consistência

- ❶ Para variáveis subgaussianas vale a seguinte desigualdade

$$P(|X| > t) \leq e^{-\frac{t^2}{2\sigma^2}} \quad (85)$$

- Cotar a probabilidade do máximo delas ser maior que um valor t é importante por alguns motivos, entre eles:
 - Nós frequentemente trabalhamos com estimadores que minimizam ou maximizam alguma função: mínimos quadrados, máxima verossimilhança. É natural que estes estimadores dependam do máximo de uma variável aleatória.
 - Se você está trabalhando com algum processo aleatório, muitas vezes o máximo pode ser mortal: qual é o máximo que um ativo pode perder se a distribuição dos retornos é subgaussiana, por exemplo?



- ② Seja a definição de norma euclidiana¹:

$$\|X\|_2^2 = X'X = \sum_i x_i^2 \quad (86)$$

Nós vamos usar o formato de multiplicação de matriz ($X'X$) para facilitar as contas.

- ③ Se uma matriz é de rank completo, então nenhum autovalor é zero.
- ④ Seja λ_{\min} o menor autovalor da matriz $\frac{X'X}{n}$. Então:

$$\lambda_{\min} \leq \frac{\frac{1}{n} \|Xv\|_2^2}{\|v\|_2^2} \quad (87)$$

para qualquer v .

¹A norma euclidiana associa um número real a cada matriz X , e podemos interpretar $\|X\|_2^2$ como o valor singular máximo de X ($\|X\|_2 = (\lambda_{\max}(X'X))^{1/2}$). 66/80

⑤ Seja $x \in \mathbb{R}^n$, então a norma p é representada por $\|x\|_p$ e

$$\|x\|_p = \left(\sum_i |x_i|^p \right)^{1/p} \quad (88)$$

- Veja que nós podemos pensar a norma do vetor x como a distância entre o vetor x e a origem. A norma euclidiana é o caso $p = 2$.
- Em particular, nós definimos a “norma sup” como o máximo do módulo do vetor e representamos por $\|x\|_\infty$:

$$\|X\|_\infty = \max_{i=1,\dots,n} |x_i| \quad (89)$$

- ⑥ Nós vamos usar a desigualdade de Hölder, que diz que se p e q são tais que $\frac{1}{p} + \frac{1}{q} = 1$, então:

$$|\langle x, y \rangle| \leq \|x\|_p \|y\|_q \quad (90)$$

- Lembre que $\langle x, y \rangle$ representa o produto interno.
- A desigualdade de Hölder vale para $p = 1$ e $q = \infty$:

$$|\langle x, y \rangle| \leq \|x\|_1 \|y\|_\infty \quad (91)$$

- Um caso particular de Hölder é a desigualdade de Cauchy-Schwartz:

$$|\langle x, y \rangle| \leq \|x\|_2 \|y\|_2 \quad (92)$$

- Uma aplicação que vai ser útil de Cauchy-Schwartz é a seguinte desigualdade de normas

$$\|x\|_1 \leq \sqrt{n}\|x\|_2 \quad (93)$$

- Veja que $\|x\|_1 = \sum_i |x_i|$. Nós podemos representar o módulo como a multiplicação de x_i pela função sinal de x_i :

$$\text{sinal}(x_i) = \begin{cases} 1, & \text{se } x_i \geq 0 \\ -1, & \text{se } x_i < 0 \end{cases} \quad (94)$$

- Se x_i é positivo, então $\text{sinal}(x_i) = 1$; se x_i é negativo, $\text{sinal}(x_i) = -x_i$.

- Logo:

$$\|x\|_1 = \langle \text{sinal}(x), x \rangle \leq \|\text{sinal}(x)\|_2 \|x\|_2 \quad (95)$$

em que $\text{sinal}(x)$ é só um vetor $(\text{sinal}(x_1), \dots, \text{sinal}(x_n))$.

- Agora use a definição de $\|\cdot\|_2$:

$$\|\text{sinal}(x)\|_2 = \left(\sum_{i=1}^n (\text{sinal}(x_i))^2 \right)^{1/2} \quad (96)$$

- Como o sinal é sempre 1 ou -1 , então o quadrado é sempre 1 e nós temos:

$$\|\text{sinal}(x)\|_2 = \left(\sum_{i=1}^n (\text{sinal}(x_i))^2 \right)^{1/2} = \left(\sum_{i=1}^n 1 \right)^{1/2} = (n)^{1/2} \quad (97)$$

- Sejam y e X os dados. Vamos supor que o ruído e é subgaussiano com parâmetro σ . Basicamente, estamos exigindo que a cauda da distribuição caia tão rápido quanto a gaussiana. Distribuições que atendem a esse requisito são chamadas de subgaussianas.
- Daqui por diante, nós representamos o estimador de Mínimos Quadrados por $\hat{\beta}$.
- Como o estimador de mínimos quadrados resolve um problema de minimização de $\sum_i (y_i - X\beta)^2$ (que representamos como $\|Y - X\beta\|_2^2$), então para qualquer outro vetor β :

$$\frac{1}{n} \|Y - X\beta\|_2^2 \leq \frac{1}{n} \|Y - X\hat{\beta}\|_2^2 \quad (98)$$

- Como isso é verdade para qualquer outro vetor β , isso também é verdade para o vetor β_0 , de parâmetros verdadeiros:

$$\frac{1}{n} \|Y - X\hat{\beta}\|_2^2 \leq \frac{1}{n} \|Y - X\beta_0\|_2^2 \quad (99)$$

- Nós sabemos que $Y = X\beta_0 + e$. Vamos substituir isso no resultado acima:

$$\begin{aligned} \frac{1}{n} \|X\beta_0 + e - X\hat{\beta}\|_2^2 &\leq \frac{1}{n} \|X\beta_0 + e - X\beta_0\|_2^2 \\ \therefore \frac{1}{n} \|X(\beta_0 - \hat{\beta}) + e\|_2^2 &\leq \frac{1}{n} \|e\|_2^2 \end{aligned} \quad (100)$$

- Usando o ponto 2 acima no termo $\|X(\beta_0 - \hat{\beta}) + e\|_2^2$, temos:

$$\begin{aligned}
 \|X(\beta_0 - \hat{\beta}) + e\|_2^2 &= (X(\beta_0 - \hat{\beta}) + e)'(X(\beta_0 - \hat{\beta}) + e) \\
 &= ((\beta_0 - \hat{\beta})'X' + e')(X(\beta_0 - \hat{\beta}) + e) \\
 &= (\beta_0 - \hat{\beta})'X'X(\beta_0 - \hat{\beta}) + (\beta_0 - \hat{\beta})'X'e + e'X(\beta_0 - \hat{\beta}) + e'e \\
 &= \|X(\beta_0 - \hat{\beta})\|_2^2 + 2e'X(\beta_0 - \hat{\beta}) + \|e\|_2^2 \tag{101}
 \end{aligned}$$

- Sabendo que $e'X(\beta_0 - \hat{\beta}) = (\beta_0 - \hat{\beta})'X'e$, encontramos:

$$\frac{1}{n}\|X(\beta_0 - \hat{\beta})\|_2^2 + \frac{2}{n}e'X(\beta_0 - \hat{\beta}) + \frac{1}{n}\|e\|_2^2 \leq \frac{1}{n}\|e\|_2^2 \tag{102}$$

- Podemos cancelar $\frac{1}{n}\|e\|_2^2$:

$$\begin{aligned}\frac{1}{n}\|X(\beta_0 - \hat{\beta})\|_2^2 + \frac{2}{n}e'X(\beta_0 - \hat{\beta}) &\leq 0 \\ \frac{1}{n}\|X(\beta_0 - \hat{\beta})\|_2^2 &\leq \frac{2}{n}e'X(\hat{\beta} - \beta_0)\end{aligned}\tag{103}$$

- Agora, $e'X(\hat{\beta} - \beta_0)$ é um escalar e nós podemos ver isso como o produto interno de e e $X(\hat{\beta} - \beta_0)$. Nós podemos usar Hölder:

$$\frac{1}{n}\langle e'X, (\hat{\beta} - \beta_0) \rangle \leq \frac{1}{n} \left| \langle e'X, (\hat{\beta} - \beta_0) \rangle \right| \leq \|e'X\|_\infty \|\hat{\beta} - \beta_0\|_1\tag{104}$$

- Vamos sair pela tangente aqui para tratar de $\|e'X\|_\infty$.
- Veja que isso é a norma de uma variável aleatória (já que e é aleatório). Pelo ponto 1 acima e fazendo X_i representar a i -ésima coluna de X :

$$\mathbb{P} \left(\max_{i=1,\dots,p} \frac{|e'x_i|}{n} > t \right) \leq p \exp \left(-\frac{t^2}{2\sigma^2/n^2} \right) \quad (105)$$

- Para $t = \frac{\sigma}{n} \sqrt{2(\log(p) + \delta)}$, com $\delta > 0$, temos:

$$\begin{aligned} P \left(\max_{i=1,\dots,p} \frac{|e'x_i|}{n} > t \right) &\leq p \exp \left(-\frac{\frac{2\sigma^2}{n^2} (\log(p) + \delta)}{\frac{2\sigma^2}{n^2}} \right) \\ &= p \exp(-\log(p) - \delta) \\ &= \exp(-\delta) \end{aligned} \quad (106)$$

- Com alta probabilidade, $\frac{\sigma}{n}\sqrt{2(\log(p) + \delta)}$ é maior que o máximo. Vamos substituir esse valor na nossa cota:

$$\begin{aligned}\langle e'X, (\hat{\beta} - \beta_0) \rangle &\leq \left| \langle e'X, (\hat{\beta} - \beta_0) \rangle \right| \leq \|e'X\|_{\infty} \|\hat{\beta} - \beta_0\|_1 \\ \langle e'X, (\hat{\beta} - \beta_0) \rangle &\leq \frac{\sigma}{n} \sqrt{2(\log(p) + \delta)} \|\hat{\beta} - \beta_0\|_1\end{aligned}\tag{107}$$

- Argumentamos que $\|x\|_1 \leq \sqrt{n}\|x\|_2$ (ponto 6). Vamos usar isso agora com $\|\hat{\beta} - \beta_0\|_1$.

$$\begin{aligned}\langle e'X, (\hat{\beta} - \beta_0) \rangle &\leq \frac{\sigma}{n} \sqrt{2(\log(p) + \delta)} \|\hat{\beta} - \beta_0\|_1 \\ &\leq \frac{\sigma}{n} \sqrt{2(\log(p) + \delta)} \sqrt{n} \|\hat{\beta} - \beta_0\|_2\end{aligned}\tag{108}$$

- Vamos jogar isso de volta na equação (103):

$$\frac{1}{n} \|X(\hat{\beta} - \beta_0)\|_2^2 \leq 2\sigma \sqrt{\frac{2(\log(p) + \delta)}{n}} \|\hat{\beta} - \beta_0\|_2 \quad (109)$$

- Multiplique e divida o lado direito por $\|\hat{\beta} - \beta_0\|_2$:

$$\frac{1}{n} \|X(\hat{\beta} - \beta_0)\|_2^2 \leq 2\sigma \sqrt{\frac{2(\log(p) + \delta)}{n}} \frac{\|\hat{\beta} - \beta_0\|_2^2}{\|\hat{\beta} - \beta_0\|_2} \quad (110)$$

- Reorganizando:

$$\frac{1}{n} \frac{\|X(\hat{\beta} - \beta_0)\|_2^2}{\|\hat{\beta} - \beta_0\|_2^2} \leq 2\sigma \sqrt{\frac{2(\log(p) + \delta)}{n}} \frac{1}{\|\hat{\beta} - \beta_0\|_2} \quad (111)$$

- Uma boa hora para usar o nosso resultado 4, sobre o autovalor da matriz:

$$\lambda_{\min} \leq \frac{1}{n} \frac{\|X(\hat{\beta} - \beta_0)\|_2^2}{\|\hat{\beta} - \beta_0\|_2^2} \leq 2\sigma \sqrt{\frac{2(\log(p) + \delta)}{n}} \frac{1}{\|\hat{\beta} - \beta_0\|_2} \quad (112)$$

- Reorganizando a expressão acima:

$$\|\hat{\beta} - \beta_0\|_2 \leq \frac{2\sigma}{\lambda_{\min}} \sqrt{\frac{2(\log(p) + \delta)}{n}} \quad (113)$$

Isso é bem legal, porque nos diz várias coisas:

- Conforme n cresce, a diferença entre a estimativa de MQO e o vetor verdadeiro cai para zero. Isso é consistência.
- Quanto mais variáveis nós temos, pior a nossa vida em termos de consistência. Mas veja que o termo em cima piora com a raiz quadrada do log de p . Isso é extremamente benevolente.
- Veja que se X for uma matriz de variáveis descorrelacionadas, então o menor autovalor de $X'X$ é a menor variância das variáveis do lado direito da equação.
- Veja que na verdade podemos fazer todas as contas sem a hipótese de ortogonalidade entre X e e . Foi necessário cotar a covariância entre x e e .

ECONOMETRIA I

REGRESSÃO DE MÍNIMOS QUADRADOS

Victor Oliveira

Núcleo de Economia Internacional e Desenvolvimento Econômico

PPGDE – 2023