

ECONOMETRIA I

PROPRIEDADES DE CONVERGÊNCIA FRACA PARA FUNÇÕES DE GRANDES AMOSTRAS: O CASO DOS MÍNIMOS QUADRADOS

Victor Oliveira

Núcleo de Economia Internacional e Desenvolvimento Econômico

PPGDE – 2024

Sumário I

- 1 Teoria Assintótica
- 2 Limite Assintótico
- 3 Convergência em Probabilidade
- 4 Convergência em Distribuição
- 5 Teorema Central do Limite
- 6 Teorema do Mapeamento Contínuo
- 7 Consistência da Estimação de Mínimos Quadrados

Definição

- A distribuição amostral de $\hat{\beta}$ é uma função da distribuição conjunta de (y_i, x_i) e do tamanho da amostra n . Na prática, esta função é extremamente complicada e assim não é fácil analiticamente calcular a distribuição exata de $\hat{\beta}$. Por isso, tipicamente partimos para os métodos de aproximação.
- *O método mais conhecido é a teoria assintótica que aproxima uma distribuição amostral tomando o limite da distribuição amostral finita quando o tamanho da amostra n tende para infinito.*
- As ferramentas básicas da teoria assintótica são a Lei Fraca dos Grandes Números (LFGN), o Teorema Central do Limite (TCL) e o Teorema do Mapeamento Contínuo (TMP). Com essas ferramentas podemos aproximar a distribuição amostral da maior parte dos estimadores econométricos.

- **Análise assintótica** é um método de aproximação obtido tomando o limite adequado.
- Existe mais de um método para tomar o limite, porém o **método mais comum em estatística e econometria é aproximar distribuições amostrais tomando o limite quando o tamanho da amostra tende para mais infinito**, isto é, $n \rightarrow +\infty$.
- O primeiro passo na análise assintótica é conhecer o conceito de limite de uma sequência.

Definição (Limite (informal))

Se f é alguma função, então

$$\lim_{x \rightarrow a} f(x) = L, \quad (1)$$

é lido “o limite de $f(x)$ quando x se aproxima de a é L ”. Isso significa que se você escolher valores de x próximos, mas não iguais a a , então $f(x)$ estará próximo do valor L ; além disso, $f(x)$ se aproxima cada vez mais de L quando x se aproxima mais e mais de a .

A seguinte notação alternativa é usada às vezes:

$$f(x) \rightarrow L \text{ quando } x \rightarrow a. \quad (2)$$

Se $f(x) = x + 3$, então $\lim_{x \rightarrow 4} f(x) = 7$ é verdade, porque se você substituir números de x perto de 4 em $f(x) = x + 3$, o resultado será próximo de 7.

Definição (Limite (formal))

Dizemos que L é o limite de $f(x)$ quando $x \rightarrow a$ se:

- ① $f(x)$ não precisa ser definido em $x = a$, mas deve ser definido para todos os outros valores de x em algum intervalo que contenha a .
- ② para todo $\varepsilon > 0$ pode-se encontrar um $\delta > 0$ tal que para todo x no domínio de f tem-se que

$$|x - a| < \delta \text{ implica } |f(x) - L| < \varepsilon. \quad (3)$$

Graficamente, a noção de limite pode ser vista como segue:

Figura 1: Noção Gráfica de Limites





Figura 2: Noção Gráfica de Limites




Para algum x neste intervalo $f(x)$

não está entre $L - \varepsilon$ e $L + \varepsilon$.

Portanto, δ é muito grande para o
 ε dado.

Figura 3: Noção Gráfica de Limites



Se escolhermos x neste intervalo $f(x)$
estará entre $L - \varepsilon$ e $L + \varepsilon$.

Portanto, δ é pequeno o suficiente para o
 ε dado.

- Por que os valores absolutos? A quantidade $|x - a|$ é a distância entre os pontos x e a na reta e pode-se medir quão próximo x é de a calculando-se $|x - a|$. A desigualdade $|x - a| < \delta$ diz que a distância entre x e a é menor que δ ou que x e a estão próximos que δ é muito pequeno.
- O que são ε e δ ? A quantidade ε é quão próximo você gostaria que $f(x)$ estivesse de seu limite L ; a quantidade δ é o quão perto você tem que escolher x para conseguir isso. Para provar que $\lim_{x \rightarrow a} f(x) = L$, você deve assumir que alguém lhe deu um valor desconhecido $\varepsilon > 0$ e, em seguida, encontrar um $\delta > 0$ pelo qual (3) é verdadeiro. O valor de δ encontrado dependerá de ε . Por isso, muitas vezes é escrito como $\delta(\varepsilon)$.

- Dizer que o número real a é o limite da sequência (x_n) significa afirmar que, para valores muito grandes de n , os termos x_n tornam-se e se mantêm tão próximos de a quanto se deseje.
- Especificamente, estipulando-se um erro por meio de um número real $\varepsilon > 0$, existe um índice n_0 tal que todos os termos x_n da sequência que têm índice n maior do que n_0 são valores aproximados de a com erro inferior a ε .
- O índice n_0 deve depender de ε , sendo de se esperar que, para valores cada vez menores de ε , necessita-se tomar n_0 cada vez maior. Com isso, temos a seguinte definição.


Definição (Limite de uma sequência)

Diz-se que o número real a é limite da sequência (x_n) de números reais, e escreve-se $a = \lim x_n$, ou $a = \lim_n x_n$, ou $a = \lim_{n \rightarrow \infty} x_n$, quando para cada número real $\varepsilon > 0$, dado arbitrariamente, for possível obter um inteiro $n_0 \in \mathbb{N}$ tal que $|x_n - a| < \varepsilon$, sempre que $n > n_0$. Isto é,

$$\lim x_n = a. \equiv . \forall \varepsilon > 0 \ \exists n_0 \in \mathbb{N}; n > n_0 \Rightarrow |x_n - a| < \varepsilon. \quad (4)$$

- Assim, a definição acima significa que, para todo número real $\varepsilon > 0$, existe um número natural n_0 tal que $n > n_0$ implica $|x_n - a| < \varepsilon$. Observamos que se $\lim x_n = a$ então qualquer intervalo $(a - \varepsilon, a + \varepsilon)$, de centro a e raio $\varepsilon > 0$, contém todos os termos x_n da sequência, com exceção no máximo de um número finito de índices n . Com efeito, dado o intervalo $(a - \varepsilon, a + \varepsilon)$, como $\lim x_n = a$, obtemos $n_0 \in \mathbb{N}$ tal que $n > n_0 \Rightarrow |x_n - a| < \varepsilon$. Ou seja, $n > n_0 \Rightarrow x_n \in (a - \varepsilon, a + \varepsilon)$.
- Graficamente, temos a seguinte situação.

Figura 4: Noção Geométrica de Limite



Convergência em Probabilidade

- Considere a média amostral $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$ para uma dada amostra aleatória com n observações. Quando n aumenta, a distribuição de \bar{y} muda.
- Em que sentido podemos descrever o “limite” de \bar{y} ? Em que sentido ele converge?
- **Como \bar{y} é uma variável aleatória, não podemos aplicar o conceito determinístico de uma sequência de números. Vamos requerer a definição de convergência que é adequada para variáveis aleatórias.**
- A definição mais comum utilizada é chamada de convergência em probabilidade, também conhecida como convergência fraca.

Definição (Convergência em Probabilidade)

Uma variável aleatória $z_n \in \mathbb{R}$ converge em probabilidade para z quando $n \rightarrow \infty$, denotado por $z_n \xrightarrow{p} z$, ou alternativamente quando $\underset{n \rightarrow \infty}{\text{plim}} z_n = z$, se para todo $\delta > 0$,

$$\lim_{n \rightarrow \infty} \Pr(|z_n - z| \leq \delta) = 1 \quad (5)$$

podemos chamar z o **limite em probabilidade** ou (**plim**) de z .

- Essa definição formaliza o conceito de uma sequência de variáveis aleatórias que se concentram em um ponto.
- Para qualquer $\delta > 0$, o evento $\{|z_n - z| \leq \delta\}$ ocorre quando z_n está dentro de δ a partir do ponto z . $\Pr(|z_n - z| \leq \delta)$ é a probabilidade desse evento.


- A eq. (5) afirma que essa probabilidade se aproxima de 1 à medida que o tamanho da amostra n aumenta. A definição requer que isso seja válido para qualquer δ . Portanto, para qualquer intervalo pequeno sobre z , a distribuição de z_n concentra-se nesse intervalo para n grande.
- Note que a definição diz respeito a distribuição das variáveis aleatória z_n , não de suas realizações.

Exemplo

- Se S_n é o número de sucessos em n tentativas (binomial) com probabilidade de sucesso p , seja $Y_n = \frac{S_n}{n}$ e $z = p$. Então,

$$\mathbb{E} \left[\frac{S_n}{n} - p \right]^2 = \text{Var} \left[\frac{S_n}{n} \right] = \frac{npq}{n^2} \rightarrow 0 \quad (6)$$

quando $n \rightarrow \infty$. Disso segue que $\frac{S_n}{n} \xrightarrow{p} p$.



LFGN

- A LFGN é o primeiro passo, mas ela não dá uma aproximação para a distribuição de um estimador. Uma aproximação assintótica pode ser obtida usando o conceito de convergência em distribuição.

Definição

Seja \mathbf{z}_n um vetor aleatório com distribuição $F_n(\mathbf{u}) = \Pr(\mathbf{z}_n < \mathbf{u})$. Dizemos que \mathbf{z}_n converge em distribuição para \mathbf{z} quando $n \rightarrow \infty$, denotado por $\mathbf{z}_n \xrightarrow{d} \mathbf{z}$, se para todo \mathbf{u} em qual $F(\mathbf{u}) = \Pr(\mathbf{z} \leq \mathbf{u})$ é contínua, $F_n(\mathbf{u}) \rightarrow F(\mathbf{u})$ quando $n \rightarrow \infty$.

- Quando $\mathbf{z}_n \xrightarrow{d} \mathbf{z}$, é comum se referir a \mathbf{z} como a **distribuição assintótica** ou **distribuição limite** de \mathbf{z} .

Exemplo

- Seja X_i variáveis aleatórias iid com média μ e seja $A = \frac{X_1 + \dots + X_n}{n}$.
- Quando $n \rightarrow \infty$, a média amostral é igual a média populacional μ de cada variável,

$$\bar{A} = \frac{X_1 + \dots + X_n}{n} = \frac{n}{n}\mu = \mu \quad (7)$$

- Além disso,

$$\begin{aligned}
 \text{var}(A) &= \text{var}\left(\frac{X_1 + \dots + X_n}{n}\right) \\
 &= \text{var}\left(\frac{X_1}{n}\right) + \dots + \text{var}\left(\frac{X_n}{n}\right) \\
 &= \frac{\sigma^2}{n^2} + \dots + \frac{\sigma^2}{n^2} = \frac{\sigma^2}{n}
 \end{aligned} \quad (8)$$

- Por Chebyshev,

$$P(|X - \mu| \geq \delta) \leq \frac{\text{var}(X)}{\delta^2} = \frac{\sigma^2}{n\delta^2} \quad (9)$$

- Quando $n \rightarrow \infty$, temos que

$$\lim_{n \rightarrow \infty} P(|X - \mu| \geq \delta) \rightarrow 0 \quad (10)$$

Definição

Se y_i é i.i.d. e $\mathbb{E}|y| < \infty$, então quando $n \rightarrow \infty$,

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i \xrightarrow{p} \mathbb{E}(y) \quad (11)$$

- A LFGN mostra que o estimador \bar{y} converge em probabilidade para a verdadeira média populacional μ . Em geral, um estimador que converge em probabilidade para o valor populacional é chamado de **consistente**.

Definição

Um estimador $\hat{\theta}$ de um parâmetro θ é consistente se $\hat{\theta} \xrightarrow{p} \theta$.

- Consistência é uma boa propriedade para um estimador. Significa que para qualquer distribuição de dados, existe um tamanho de amostra n suficientemente grande tal que o estimador $\hat{\theta}$ será arbitrariamente próximo do verdadeiro valor θ com alta probabilidade.

Teorema

Se y_i são i.i.d e $\mathbb{E}|y| < \infty$, então $\hat{\mu} = \bar{y}$ é consistente para a média populacional μ .

Teorema Central do Limite

- A forma típica de estabelecer a convergência em distribuição é através do Teorema Central do Limite (TCL), que estabelece que uma média amostral padronizada converge em distribuição para um vetor aleatório normal.

Teorema

Se $y_i \in \mathbb{R}^k$ é i.i.d. e $\mathbb{E}\|\mathbf{y}\|^2 < \infty$, então quando $n \rightarrow \infty$

$$\sqrt{n}(\bar{\mathbf{y}} - \boldsymbol{\mu}) \xrightarrow{d} N(\mathbf{0}, \mathbf{V}) \quad (12)$$

em que $\boldsymbol{\mu} = \mathbb{E}\mathbf{y}$ e $\mathbf{V} = \mathbb{E}((\mathbf{y} - \boldsymbol{\mu})(\mathbf{y} - \boldsymbol{\mu})')$.

- O TCL mostra que a distribuição da média amostral é aproximadamente normal em grandes amostras. Para alguma aplicação deve ser útil observar que o teorema não impõe qualquer restrição sobre V além do que os elementos são finitos.
- O teorema central do limite (TCL) não é um teorema único, mas abrange uma variedade de resultados relacionados com a soma de um grande número de variáveis aleatórias que, adequadamente normalizadas, têm uma distribuição limite normal.

- Uma coisa interessante sobre o TCL é que não importa qual seja a distribuição dos X_i 's. Os X_i podem ser variáveis aleatórias discretas, contínuas ou mistas.
- Para ter uma ideia do TCL, vejamos alguns exemplos. Vamos supor que os X_i sejam Bernoulli(p).
- Então $\mathbb{E}[X_i] = p$ e $\text{var}(X_i) = p(1 - p)$. Além disso, $Y_n = X_1 + X_2 + \dots + X_n$ tem distribuição Binomial(n, p).
- Portanto,

$$Z_n = \frac{Y_n - np}{\sqrt{np(1 - p)}} \tag{13}$$

Exemplo

- Suponha que X_1, X_2, \dots, X_n seguem uma Bernoulli com parâmetro p .
- Assim,

$$Z_n = \frac{X_1 + X_2 + \dots + X_n - np}{\sqrt{np(1-p)}} \quad (14)$$

- Escolhemos $p = \frac{1}{2}$.






Figura 5: Binomial ($p = 0,5$)

Figura 6: Poisson ($\lambda = 2$)**Tamanho Amostral = 1****Tamanho Amostral = 10****Tamanho Amostral = 30****Tamanho Amostral = 1000**

Exemplo

- Um caixa de banco atende os clientes que estão na fila, um por um. Suponha que o tempo de atendimento X_i para o cliente i tenha média $\mathbb{E}[X_i] = 2$ (minutos) e $\text{Var}(X_i) = 1$. Assumimos que os tempos de atendimento para diferentes clientes do banco são independentes. Seja Y o tempo total que o caixa do banco gasta atendendo 50 clientes. Encontre $P(90 < Y < 110)$.

$$\begin{aligned}
 P(90 < Y \leq 110) &= P\left(\frac{90 - n\mu}{\sqrt{n}\sigma} < \frac{Y - n\mu}{\sqrt{n}\sigma} < \frac{110 - n\mu}{\sqrt{n}\sigma}\right) \\
 &= P\left(\frac{90 - 100}{\sqrt{50}} < \frac{Y - n\mu}{\sqrt{n}\sigma} < \frac{110 - 100}{\sqrt{50}}\right) \\
 &= P\left(-\sqrt{2} < \frac{Y - n\mu}{\sqrt{n}\sigma} < \sqrt{2}\right) \\
 &\approx \Phi(\sqrt{2}) - \Phi(-\sqrt{2}) = 0.8427
 \end{aligned} \tag{15}$$

Exemplo

- Seja X_i uma variável aleatória indicadora do i -ésimo erro no pacote estatístico. Ou seja, $X_i = 1$ se há um erro e $X_i = 0$ caso contrário. Então X_i é i.i.d. e $X_i \sim \text{Bernoulli}(p)$. Se Y é o número total de erros no pacote, com $n = 1000$, temos:

$$Y = X_1 + \dots + X_n \tag{16}$$

- Se $X_i \sim \text{Bernoulli}(0, 1)$, então

$$\mathbb{E}[X_i] = 0.1 \tag{17}$$

$$\text{var}(X_i) = \sigma^2 = p(1 - p) = 0.09 \tag{18}$$

- Assim, qual o valor de $P(Y > 120)$?

$$\begin{aligned} P(Y > 120) &= P\left(\frac{Y - n\mu}{\sqrt{n}\sigma} > \frac{120 - n\mu}{\sqrt{n}\sigma}\right) \\ &= P\left(\frac{Y - n\mu}{\sqrt{n}\sigma} > \frac{120 - 100}{\sqrt{90}}\right) \\ &\approx 1 - \Phi\left(\frac{20}{\sqrt{90}}\right) \\ &= 0.0175 \end{aligned} \tag{19}$$

Exemplo

- Há 100 homens em um avião. Seja X_i o peso do i -ésimo homem no avião. Suponha que X_i é i.i.d., e $\mathbb{E}X_i = \mu = 70$ e $\sigma(X_i) = \sigma = 30$. Encontre a probabilidade de que o peso total dos homens no avião exceda 8000 kg.
- Se W é o peso total, então $W = X_1 + \dots + X_n$, em que $n = 100$. Então,

$$\begin{aligned}\mathbb{E}[W] &= n\mu \\ &= (100)(70) \\ &= 7000,\end{aligned}\tag{20}$$

$$\begin{aligned}\text{var}(W) &= 100\text{var}(X_i) \\ &= (100)(30)^2 \\ &= 90000\end{aligned}\tag{21}$$

- Assim,

$$\begin{aligned} P(W > 18000) &= P\left(\frac{W - 7000}{300} > \frac{8000 - 7000}{300}\right) \\ &= P\left(\frac{W - 7000}{300} > \frac{10}{3}\right) \\ &= 1 - \Phi\left(\frac{10}{3}\right) \\ &\approx 4.3 \times 10^{-4} \end{aligned} \tag{22}$$

Teorema (Teorema do Mapeamento Contínuo)

Seja $\mathbf{z}_n \in \mathbb{R}^k$ e $g(u): \mathbb{R}^k \rightarrow \mathbb{R}^q$. Se $\mathbf{z}_n \xrightarrow{p} c$ quando $n \rightarrow \infty$ e $g(u)$ é contínua em c então $g(\mathbf{z}_n) \xrightarrow{p} g(c)$ quando $n \rightarrow \infty$.

Consistência da Estimação de MQO

- A teoria assintótica da estimação de mínimos quadrados se aplica igualmente ao modelo de projeção e ao modelo CEF linear. Vamos considerar aqui os resultados para o modelo de projeção mais amplo. Recorde que o modelo é dado por

$$y_i = \mathbf{x}'_i \boldsymbol{\beta} + e_i \quad (23)$$

para $i = 1, \dots, n$ em que a projeção linear de $\boldsymbol{\beta}$ é dada por

$$\boldsymbol{\beta} = (\mathbb{E}(\mathbf{x}_i \mathbf{x}'_i))^{-1} \mathbf{E}(\mathbf{x}_i y_i) \quad (24)$$

- Vamos precisar de alguns pressupostos estabelecidos anteriormente.

- Muitos dos resultados a seguir se mantém sobre o pressuposto de **amostra aleatória** e o pressuposto de **segundo momento finitos**.

Pressuposto

- ① As observações (y_i, \mathbf{x}_i) , $i = 1, \dots, n$ são independentes e identicamente distribuídos.
- ② $\mathbb{E}y^2 < \infty$.
- ③ $\mathbb{E}\|\mathbf{x}\|^2 < \infty$.
- ④ $\mathbf{Q}_{\mathbf{x}\mathbf{x}'}$ é positiva definida.
- ⑤ $\mathbb{E}y^4 < \infty$ e $\mathbb{E}\|\mathbf{x}_i\|^4 < \infty$.

- Para mostrar que o estimador de mínimos quadrados $\hat{\beta}$ é consistente para o coeficiente de projeção β , vamos usar a Lei Fraca dos Grandes Números (**LFGN**) e o Teorema do Mapeamento Contínuo (**TMP**).
- A derivação é baseada em três etapas:
 - ① *O estimador de MQO pode ser escrito como uma função contínua de um conjunto de momentos amostrais.*
 - ② *A LFGN mostra que os momentos amostrais convergem probabilidade para os momentos populacionais.*
 - ③ *O TMP estabelece que as funções contínuas preservam a convergência em probabilidade.*

- Observe que o estimador de MQO é uma função dos momentos amostrais $\hat{Q}_{xx} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i'$ e $\hat{Q}_{xy} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i y_i$, isto é,

$$\begin{aligned}\hat{\beta} &= \left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i y_i \right) \\ &= \hat{Q}_{xx}^{-1} \hat{Q}_{xy}\end{aligned}\tag{25}$$

- Pela aplicação da LFGN estes momentos converge em probabilidade para momentos populacionais.
- Como (y_i, \mathbf{x}_i) são mutuamente **i.i.d.**, qualquer função de (y_i, \mathbf{x}_i) é **i.i.d.**, incluindo $\mathbf{x}\mathbf{x}'_i$ e $\mathbf{x}\mathbf{y}_i$. Vale lembrar que essas variáveis tem esperança finitas.
- Assim,

$$\hat{\mathbf{Q}}_{xx} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}'_i \xrightarrow{p} \mathbb{E}(\mathbf{x}_i \mathbf{x}'_i) = \mathbf{Q}_{xx} \quad (26)$$

e

$$\hat{\mathbf{Q}}_{xy} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{y}_i \xrightarrow{p} \mathbb{E}(\mathbf{x}_i \mathbf{y}_i) = \mathbf{Q}_{xy} \quad (27)$$

- O TMC permite combinar estas equações para mostrar que o $\hat{\beta}$ converge em probabilidade para β . Especificamente, quando $n \rightarrow \infty$,

$$\begin{aligned}\hat{\beta} &= \hat{Q}_{xx}^{-1} \hat{Q}_{xy} \\ &\xrightarrow{p} Q_{xx}^{-1} Q_{xy} \\ &= \beta\end{aligned}\tag{28}$$

- Dessa forma, temos que $\hat{\beta} \xrightarrow{p} \beta$ quando $n \rightarrow \infty$.

- Esse mesmo resultado ser obtido de uma forma alternativa. Considerando que

$$\hat{\beta} - \beta = \hat{Q}_{xx}^{-1} \hat{Q}_{xe} \quad (29)$$

em que

$$\hat{Q}_{xe} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i e_i \quad (30)$$


- Pela LFGN e $\mathbb{E}(\mathbf{x}_i e_i) = 0$, temos:

$$\hat{Q}_{xe} \xrightarrow{p} Q_{xe} \quad (31)$$

- Como $\hat{Q}_{xe} \xrightarrow{p} \mathbb{E}(\mathbf{x}_i e_i) = 0$, temos que

$$\begin{aligned} \hat{\beta} - \beta &= \hat{Q}_{xx}^{-1} \hat{Q}_{xe} \\ &\xrightarrow{p} \hat{Q}_{xx}^{-1} \mathbf{0} = \mathbf{0} \end{aligned} \quad (32) \quad 42/45$$

- Vamos ilustrar esse resultado da consistência da estimação de Mínimos Quadrados com o gráfico a seguir considerando a estimação da equação de salários, onde iremos plotar o coeficiente associado a escolaridade obtido para diferentes tamanhos da amostra.

Figura 7: $\hat{\beta}_1$ como Função do Tamanho da Amostra

ECONOMETRIA I

PROPRIEDADES DE CONVERGÊNCIA FRACA PARA FUNÇÕES DE GRANDES AMOSTRAS: O CASO DOS MÍNIMOS QUADRADOS

Victor Oliveira

Núcleo de Economia Internacional e Desenvolvimento Econômico

PPGDE – 2024