

## ECONOMETRIA I

# PROPRIEDADES DE CONVERGÊNCIA FRACA PARA FUNÇÕES DE GRANDES AMOSTRAS: O CASO DOS MÍNIMOS QUADRADOS

Victor Oliveira

Núcleo de Economia Internacional e Desenvolvimento Econômico

PPGDE – 2023

- 1 Teoria Assintótica
- 2 Limite Assintótico
- 3 Convergência em Probabilidade
- 4 Convergência em Distribuição
- 5 Teorema Central do Limite
- 6 Teorema do Mapeamento Contínuo
- 7 Consistência da Estimação de Mínimos Quadrados

# Definição

- A distribuição amostral de  $\hat{\beta}$  é uma função da distribuição conjunta de  $(y_i, x_i)$  e do tamanho da amostra  $n$ . Na prática, esta função é extremamente complicada e assim não é fácil analiticamente calcular a distribuição exata de  $\hat{\beta}$ . Por isso, tipicamente partimos para os métodos de aproximação.
- *O método mais conhecido é a teoria assintótica que aproxima uma distribuição amostral tomando o limite da distribuição amostral finita quando o tamanho da amostra  $n$  tende para infinito.*
- As ferramentas básicas da teoria assintótica são a Lei Fraca dos Grandes Números (LFGN), o Teorema Central do Limite (TCL) e o Teorema do Mapeamento Contínuo (TMP). Com essas ferramentas podemos aproximar a distribuição amostral da maior parte dos estimadores econométricos.

- **Análise assintótica** é um método de aproximação obtido tomando o limite adequado.
- Existe mais de um método para tomar o limite, porém o **método mais comum em estatística e econometria é aproximar distribuições amostrais tomando o limite quando o tamanho da amostra tende para mais infinito**, isto é,  $n \rightarrow +\infty$ .
- O primeiro passo na análise assintótica é conhecer o conceito de limite de uma sequência.

## Definição (Limite (informal))

Se  $f$  é alguma função, então

$$\lim_{x \rightarrow a} f(x) = L, \quad (1)$$

é lido “o limite de  $f(x)$  quando  $x$  se aproxima de  $a$  é  $L$ ”. Isso significa que se você escolher valores de  $x$  próximos, mas não iguais a  $a$ , então  $f(x)$  estará próximo do valor  $L$ ; além disso,  $f(x)$  se aproxima cada vez mais de  $L$  quando  $x$  se aproxima mais e mais de  $a$ .

A seguinte notação alternativa é usada às vezes:

$$f(x) \rightarrow L \text{ quando } x \rightarrow a. \quad (2)$$

Se  $f(x) = x + 3$ , então  $\lim_{x \rightarrow 4} f(x) = 7$  é verdade, porque se você substituir números de  $x$  perto de 4 em  $f(x) = x + 3$ , o resultado será próximo de 7.

## Definição (Limite (formal))

Dizemos que  $L$  é o limite de  $f(x)$  quando  $x \rightarrow a$  se:

- ①  $f(x)$  não precisa ser definido em  $x = a$ , mas deve ser definido para todos os outros valores de  $x$  em algum intervalo que contenha  $a$ .
- ② para todo  $\varepsilon > 0$  pode-se encontrar um  $\delta > 0$  tal que para todo  $x$  no domínio de  $f$  tem-se que

$$|x - a| < \delta \text{ implica } |f(x) - L| < \varepsilon. \quad (3)$$

Graficamente, a noção de limite pode ser vista como segue:

Figura 1: Noção Gráfica de Limites






Figura 2: Noção Gráfica de Limites



Para algum  $x$  neste intervalo  $f(x)$   
não está entre  $L - \varepsilon$  e  $L + \varepsilon$ .  
Portanto,  $\delta$  é muito grande para o  
 $\varepsilon$  dado.

Figura 3: Noção Gráfica de Limites



Se escolhermos  $x$  neste intervalo  $f(x)$   
estará entre  $L - \varepsilon$  e  $L + \varepsilon$ .

Portanto,  $\delta$  é pequeno o suficiente para o  
 $\varepsilon$  dado.

- Por que os valores absolutos? A quantidade  $|x - a|$  é a distância entre os pontos  $x$  e  $a$  na reta e pode-se medir quão próximo  $x$  é de  $a$  calculando-se  $|x - a|$ . A desigualdade  $|x - a| < \delta$  diz que a distância entre  $x$  e  $a$  é menor que  $\delta$  ou que  $x$  e  $a$  estão próximos que  $\delta$  é muito pequeno.
- O que são  $\varepsilon$  e  $\delta$ ? A quantidade  $\varepsilon$  é quão próximo você gostaria que  $f(x)$  estivesse de seu limite  $L$ ; a quantidade  $\delta$  é o quão perto você tem que escolher  $x$  para conseguir isso. Para provar que  $\lim_{x \rightarrow a} f(x) = L$ , você deve assumir que alguém lhe deu um valor desconhecido  $\varepsilon > 0$  e, em seguida, encontrar um  $\delta > 0$  pelo qual (3) é verdadeiro. O valor de  $\delta$  encontrado dependerá de  $\varepsilon$ . Por isso, muitas vezes é escrito como  $\delta(\varepsilon)$ .

- Dizer que o número real  $a$  é o limite da sequência  $(x_n)$  significa afirmar que, para valores muito grandes de  $n$ , os termos  $x_n$  tornam-se e se mantêm tão próximos de  $a$  quanto se deseje.
- Especificamente, estipulando-se um erro por meio de um número real  $\varepsilon > 0$ , existe um índice  $n_0$  tal que todos os termos  $x_n$  da sequência que têm índice  $n$  maior do que  $n_0$  são valores aproximados de  $a$  com erro inferior a  $\varepsilon$ .
- O índice  $n_0$  deve depender de  $\varepsilon$ , sendo de se esperar que, para valores cada vez menores de  $\varepsilon$ , necessita-se tomar  $n_0$  cada vez maior. Com isso, temos a seguinte definição.


## Definição (Limite de uma sequência)

Diz-se que o número real  $a$  é limite da sequência  $(x_n)$  de números reais, e escreve-se  $a = \lim x_n$ , ou  $a = \lim_n x_n$ , ou  $a = \lim_{n \rightarrow \infty} x_n$ , quando para cada número real  $\varepsilon > 0$ , dado arbitrariamente, for possível obter um inteiro  $n_0 \in \mathbb{N}$  tal que  $|x_n - a| < \varepsilon$ , sempre que  $n > n_0$ . Isto é,

$$\lim x_n = a. \equiv . \forall \varepsilon > 0 \ \exists n_0 \in \mathbb{N}; n > n_0 \Rightarrow |x_n - a| < \varepsilon. \quad (4)$$

- Assim, a definição acima significa que, para todo número real  $\varepsilon > 0$ , existe um número natural  $n_0$  tal que  $n > n_0$  implica  $|x_n - a| < \varepsilon$ . Observamos que se  $\lim x_n = a$  então qualquer intervalo  $(a - \varepsilon, a + \varepsilon)$ , de centro  $a$  e raio  $\varepsilon > 0$ , contém todos os termos  $x_n$  da sequência, com exceção no máximo de um número finito de índices  $n$ . Com efeito, dado o intervalo  $(a - \varepsilon, a + \varepsilon)$ , como  $\lim x_n = a$ , obtemos  $n_0 \in \mathbb{N}$  tal que  $n > n_0 \Rightarrow |x_n - a| < \varepsilon$ . Ou seja,  $n > n_0 \Rightarrow x_n \in (a - \varepsilon, a + \varepsilon)$ .
- Graficamente, temos a seguinte situação.

Figura 4: Noção Geométrica de Limite



# Convergência em Probabilidade

- Considere a média amostral  $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$  para uma dada amostra aleatória com  $n$  observações. Quando  $n$  aumenta, a distribuição de  $\bar{y}$  muda.
- Em que sentido podemos descrever o “limite” de  $\bar{y}$ ? Em que sentido ele converge?
- **Como  $\bar{y}$  é uma variável aleatória, não podemos aplicar o conceito determinístico de uma sequência de números. Vamos requerer a definição de convergência que é adequada para variáveis aleatórias.**
- A definição mais comum utilizada é chamada de convergência em probabilidade, também conhecida como convergência fraca.

## Definição (Convergência em Probabilidade)

Uma variável aleatória  $z_n \in \mathbb{R}$  converge em probabilidade para  $z$  quando  $n \rightarrow \infty$ , denotado por  $z_n \xrightarrow{p} z$ , ou alternativamente quando  $\underset{n \rightarrow \infty}{\text{plim}} z_n = z$ , se para todo  $\delta > 0$ ,

$$\lim_{n \rightarrow \infty} \Pr(|z_n - z| \leq \delta) = 1 \quad (5)$$

podemos chamar  $z$  o **limite em probabilidade** ou (**plim**) de  $z$ .

- Essa definição formaliza o conceito de uma sequência de variáveis aleatórias que se concentram em um ponto.
- Para qualquer  $\delta > 0$ , o evento  $\{|z_n - z| \leq \delta\}$  ocorre quando  $z_n$  está dentro de  $\delta$  a partir do ponto  $z$ .  $\Pr(|z_n - z| \leq \delta)$  é a probabilidade desse evento.


- A eq. (5) afirma que essa probabilidade se aproxima de 1 à medida que o tamanho da amostra  $n$  aumenta. A definição requer que isso seja válido para qualquer  $\delta$ . Portanto, para qualquer intervalo pequeno sobre  $z$ , a distribuição de  $z_n$  concentra-se nesse intervalo para  $n$  grande.
- Note que a definição diz respeito a distribuição das variáveis aleatória  $z_n$ , não de suas realizações.

# Exemplo

- Se  $S_n$  é o número de sucessos em  $n$  tentativas (binomial) com probabilidade de sucesso  $p$ , seja  $Y_n = \frac{S_n}{n}$  e  $z = p$ . Então,

$$\mathbb{E} \left[ \frac{S_n}{n} - p \right]^2 = \text{Var} \left[ \frac{S_n}{n} \right] = \frac{npq}{n^2} \rightarrow 0 \quad (6)$$

quando  $n \rightarrow \infty$ . Disso segue que  $\frac{S_n}{n} \xrightarrow{p} p$ .



- A LFGN é o primeiro passo, mas ela não dá uma aproximação para a distribuição de um estimador. Uma aproximação assintótica pode ser obtida usando o conceito de convergência em distribuição.

### Definição

Seja  $\mathbf{z}_n$  um vetor aleatório com distribuição  $F_n(\mathbf{u}) = \Pr(\mathbf{z}_n < \mathbf{u})$ . Dizemos que  $\mathbf{z}_n$  converge em distribuição para  $\mathbf{z}$  quando  $n \rightarrow \infty$ , denotado por  $\mathbf{z}_n \xrightarrow{d} \mathbf{z}$ , se para todo  $\mathbf{u}$  em qual  $F(\mathbf{u}) = \Pr(\mathbf{z} \leq \mathbf{u})$  é contínua,  $F_n(\mathbf{u}) \rightarrow F(\mathbf{u})$  quando  $n \rightarrow \infty$ .

- Quando  $\mathbf{z}_n \xrightarrow{d} \mathbf{z}$ , é comum se referir a  $\mathbf{z}$  como a **distribuição assintótica** ou **distribuição limite** de  $\mathbf{z}$ .

# Exemplo

- Seja  $X_i$  variáveis aleatórias iid com média  $\mu$  e seja  $A = \frac{X_1 + \dots + X_n}{n}$ .
- Quando  $n \rightarrow \infty$ , a média amostral é igual a média populacional  $\mu$  de cada variável,

$$\bar{A} = \frac{X_1 + \dots + X_n}{n} = \frac{n}{n}\mu = \mu \quad (7)$$

- Além disso,

$$\begin{aligned}
 \text{var}(A) &= \text{var}\left(\frac{X_1 + \dots + X_n}{n}\right) \\
 &= \text{var}\left(\frac{X_1}{n}\right) + \dots + \text{var}\left(\frac{X_n}{n}\right) \\
 &= \frac{\sigma^2}{n^2} + \dots + \frac{\sigma^2}{n^2} = \frac{\sigma^2}{n}
 \end{aligned} \quad (8)$$

- Por Chebyshev,

$$P(|X - \mu| \geq \delta) \leq \frac{\text{var}(X)}{\delta^2} = \frac{\sigma^2}{n\delta^2} \quad (9)$$

- Quando  $n \rightarrow \infty$ , temos que

$$\lim_{n \rightarrow \infty} P(|X - \mu| \geq \delta) \rightarrow 0 \quad (10)$$

## Definição

Se  $y_i$  é i.i.d. e  $\mathbb{E}|y| < \infty$ , então quando  $n \rightarrow \infty$ ,

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i \xrightarrow{p} \mathbb{E}(y) \quad (11)$$

- A LFGN mostra que o estimador  $\bar{y}$  converge em probabilidade para a verdadeira média populacional  $\mu$ . Em geral, um estimador que converge em probabilidade para o valor populacional é chamado de **consistente**.

## Definição

Um estimador  $\hat{\theta}$  de um parâmetro  $\theta$  é consistente se  $\hat{\theta} \xrightarrow{p} \theta$ .

- Consistência é uma boa propriedade para um estimador. Significa que para qualquer distribuição de dados, existe um tamanho de amostra  $n$  suficientemente grande tal que o estimador  $\hat{\theta}$  será arbitrariamente próximo do verdadeiro valor  $\theta$  com alta probabilidade.

### Teorema

*Se  $y_i$  são i.i.d e  $\mathbb{E}|y| < \infty$ , então  $\hat{\mu} = \bar{y}$  é consistente para a média populacional  $\mu$ .*

# Teorema Central do Limite

- A forma típica de estabelecer a convergência em distribuição é através do Teorema Central do Limite (TCL), que estabelece que uma média amostral padronizada converge em distribuição para um vetor aleatório normal.

## Teorema

Se  $y_i \in \mathbb{R}^k$  é i.i.d. e  $\mathbb{E}\|\mathbf{y}\|^2 < \infty$ , então quando  $n \rightarrow \infty$

$$\sqrt{n}(\bar{\mathbf{y}} - \boldsymbol{\mu}) \xrightarrow{d} N(\mathbf{0}, \mathbf{V}) \quad (12)$$

em que  $\boldsymbol{\mu} = \mathbb{E}\mathbf{y}$  e  $\mathbf{V} = \mathbb{E}((\mathbf{y} - \boldsymbol{\mu})(\mathbf{y} - \boldsymbol{\mu})')$ .

- O TCL mostra que a distribuição da média amostral é aproximadamente normal em grandes amostras. Para alguma aplicação deve ser útil observar que o teorema não impõe qualquer restrição sobre  $V$  além do que os elementos são finitos.
- O teorema central do limite (TCL) não é um teorema único, mas abrange uma variedade de resultados relacionados com a soma de um grande número de variáveis aleatórias que, adequadamente normalizadas, têm uma distribuição limite normal.

- Uma coisa interessante sobre o TCL é que não importa qual seja a distribuição dos  $X_i$ 's. Os  $X_i$  podem ser variáveis aleatórias discretas, contínuas ou mistas.
- Para ter uma ideia do TCL, vejamos alguns exemplos. Vamos supor que os  $X_i$  sejam Bernoulli( $p$ ).
- Então  $\mathbb{E}[X_i] = p$  e  $\text{var}(X_i) = p(1 - p)$ . Além disso,  $Y_n = X_1 + X_2 + \dots + X_n$  tem distribuição Binomial( $n, p$ ).
- Portanto,

$$Z_n = \frac{Y_n - np}{\sqrt{np(1 - p)}} \tag{13}$$

# Exemplo

- Suponha que  $X_1, X_2, \dots, X_n$  seguem uma Bernoulli com parâmetro  $p$ .
- Assim,

$$Z_n = \frac{X_1 + X_2 + \dots + X_n - np}{\sqrt{np(1-p)}} \quad (14)$$

- Escolhemos  $p = \frac{1}{2}$ .






Figura 5: Binomial ( $p = 0,5$ )

Figura 6: Poisson ( $\lambda = 2$ )**Tamanho Amostral = 1****Tamanho Amostral = 10****Tamanho Amostral = 30****Tamanho Amostral = 1000**

# Exemplo

- Um caixa de banco atende os clientes que estão na fila, um por um. Suponha que o tempo de atendimento  $X_i$  para o cliente  $i$  tenha média  $\mathbb{E}[X_i] = 2$  (minutos) e  $\text{Var}(X_i) = 1$ . Assumimos que os tempos de atendimento para diferentes clientes do banco são independentes. Seja  $Y$  o tempo total que o caixa do banco gasta atendendo 50 clientes. Encontre  $P(90 < Y < 110)$ .

$$\begin{aligned}
 P(90 < Y \leq 110) &= P\left(\frac{90 - n\mu}{\sqrt{n}\sigma} < \frac{Y - n\mu}{\sqrt{n}\sigma} < \frac{110 - n\mu}{\sqrt{n}\sigma}\right) \\
 &= P\left(\frac{90 - 100}{\sqrt{50}} < \frac{Y - n\mu}{\sqrt{n}\sigma} < \frac{110 - 100}{\sqrt{50}}\right) \\
 &= P\left(-\sqrt{2} < \frac{Y - n\mu}{\sqrt{n}\sigma} < \sqrt{2}\right) \\
 &\approx \Phi(\sqrt{2}) - \Phi(-\sqrt{2}) = 0.8427
 \end{aligned} \tag{15}$$

# Exemplo

- Seja  $X_i$  uma variável aleatória indicadora do  $i$ -ésimo erro no pacote estatístico. Ou seja,  $X_i = 1$  se há um erro e  $X_i = 0$  caso contrário. Então  $X_i$  é i.i.d. e  $X_i \sim \text{Bernoulli}(p)$ . Se  $Y$  é o número total de erros no pacote, com  $n = 1000$ , temos:

$$Y = X_1 + \dots + X_n \quad (16)$$

- Se  $X_i \sim \text{Bernoulli}(0, 1)$ , então

$$\mathbb{E}[X_i] = 0.1 \quad (17)$$

$$\text{var}(X_i) = \sigma^2 = p(1 - p) = 0.09 \quad (18)$$

- Assim, qual o valor de  $P(Y > 120)$ ?

$$\begin{aligned} P(Y > 120) &= P\left(\frac{Y - n\mu}{\sqrt{n}\sigma} > \frac{120 - n\mu}{\sqrt{n}\sigma}\right) \\ &= P\left(\frac{Y - n\mu}{\sqrt{n}\sigma} > \frac{120 - 100}{\sqrt{90}}\right) \\ &\approx 1 - \Phi\left(\frac{20}{\sqrt{90}}\right) \\ &= 0.0175 \end{aligned} \tag{19}$$

# Exemplo

- Há 100 homens em um avião. Seja  $X_i$  o peso do  $i$ -ésimo homem no avião. Suponha que  $X_i$  é i.i.d., e  $\mathbb{E}X_i = \mu = 70$  e  $\sigma(X_i) = \sigma = 30$ . Encontre a probabilidade de que o peso total dos homens no avião exceda 8000 kg.
- Se  $W$  é o peso total, então  $W = X_1 + \dots + X_n$ , em que  $n = 100$ . Então,

$$\begin{aligned}
 \mathbb{E}[W] &= n\mu \\
 &= (100)(70) \\
 &= 7000,
 \end{aligned} \tag{20}$$

$$\begin{aligned}
 \text{var}(W) &= 100\text{var}(X_i) \\
 &= (100)(30)^2 \\
 &= 90000
 \end{aligned} \tag{21}$$

- Assim,

$$\begin{aligned} P(W > 18000) &= P\left(\frac{W - 7000}{300} > \frac{8000 - 7000}{300}\right) \\ &= P\left(\frac{W - 7000}{300} > \frac{10}{3}\right) \\ &= 1 - \Phi\left(\frac{10}{3}\right) \\ &\approx 4.3 \times 10^{-4} \end{aligned} \tag{22}$$

## Teorema (Teorema do Mapeamento Contínuo)

Seja  $\mathbf{z}_n \in \mathbb{R}^k$  e  $g(u): \mathbb{R}^k \rightarrow \mathbb{R}^q$ . Se  $\mathbf{z}_n \xrightarrow{p} c$  quando  $n \rightarrow \infty$  e  $g(u)$  é contínua em  $c$  então  $g(\mathbf{z}_n) \xrightarrow{p} g(c)$  quando  $n \rightarrow \infty$ .

# Consistência da Estimação de MQO

- A teoria assintótica da estimação de mínimos quadrados se aplica igualmente ao modelo de projeção e ao modelo CEF linear. Vamos considerar aqui os resultados para o modelo de projeção mais amplo. Recorde que o modelo é dado por

$$y_i = \mathbf{x}_i' \boldsymbol{\beta} + e_i \quad (23)$$

para  $i = 1, \dots, n$  em que a projeção linear de  $\boldsymbol{\beta}$  é dada por

$$\boldsymbol{\beta} = (\mathbb{E}(\mathbf{x}_i \mathbf{x}_i'))^{-1} \mathbf{E}(\mathbf{x}_i y_i) \quad (24)$$

- Vamos precisar de alguns pressupostos estabelecidos anteriormente.

- Muitos dos resultados a seguir se mantém sobre o pressuposto de **amostra aleatória** e o pressuposto de **segundo momento finitos**.

### Pressuposto

- ① As observações  $(y_i, \mathbf{x}_i)$ ,  $i = 1, \dots, n$  são independentes e identicamente distribuídos.
- ②  $\mathbb{E}y^2 < \infty$ .
- ③  $\mathbb{E}\|\mathbf{x}\|^2 < \infty$ .
- ④  $\mathbf{Q}_{\mathbf{x}\mathbf{x}'}$  é positiva definida.
- ⑤  $\mathbb{E}y^4 < \infty$  e  $\mathbb{E}\|\mathbf{x}_i\|^4 < \infty$ .

- Para mostrar que o estimador de mínimos quadrados  $\hat{\beta}$  é consistente para o coeficiente de projeção  $\beta$ , vamos usar a Lei Fraca dos Grandes Números (**LFGN**) e o Teorema do Mapeamento Contínuo (**TMP**).
- A derivação é baseada em três etapas:
  - ① *O estimador de MQO pode ser escrito como uma função contínua de um conjunto de momentos amostrais.*
  - ② *A LFGN mostra que os momentos amostrais convergem probabilidade para os momentos populacionais.*
  - ③ *O TMP estabelece que as funções contínuas preservam a convergência em probabilidade.*

- Observe que o estimador de MQO é uma função dos momentos amostrais  $\hat{Q}_{xx} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i'$  e  $\hat{Q}_{xy} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i y_i$ , isto é,

$$\begin{aligned}\hat{\beta} &= \left( \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' \right)^{-1} \left( \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i y_i \right) \\ &= \hat{Q}_{xx}^{-1} \hat{Q}_{xy}\end{aligned}\tag{25}$$

- Pela aplicação da LFGN estes momentos converge em probabilidade para momentos populacionais.
- Como  $(y_i, \mathbf{x}_i)$  são mutuamente **i.i.d.**, qualquer função de  $(y_i, \mathbf{x}_i)$  é **i.i.d.**, incluindo  $\mathbf{x}\mathbf{x}'_i$  e  $\mathbf{x}\mathbf{y}_i$ . Vale lembrar que essas variáveis tem esperança finitas.
- Assim,

$$\hat{\mathbf{Q}}_{xx} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}'_i \xrightarrow{p} \mathbb{E}(\mathbf{x}_i \mathbf{x}'_i) = \mathbf{Q}_{xx} \quad (26)$$

e

$$\hat{\mathbf{Q}}_{xy} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{y}_i \xrightarrow{p} \mathbb{E}(\mathbf{x}_i \mathbf{y}_i) = \mathbf{Q}_{xy} \quad (27)$$

- O TMC permite combinar estas equações para mostrar que o  $\hat{\beta}$  converge em probabilidade para  $\beta$ . Especificamente, quando  $n \rightarrow \infty$ ,

$$\begin{aligned}\hat{\beta} &= \hat{Q}_{xx}^{-1} \hat{Q}_{xy} \\ &\xrightarrow{p} Q_{xx}^{-1} Q_{xy} \\ &= \beta\end{aligned}\tag{28}$$

- Dessa forma, temos que  $\hat{\beta} \xrightarrow{p} \beta$  quando  $n \rightarrow \infty$ .

- Esse mesmo resultado ser obtido de uma forma alternativa. Considerando que

$$\hat{\beta} - \beta = \hat{Q}_{xx}^{-1} \hat{Q}_{xe} \quad (29)$$

em que

$$\hat{Q}_{xe} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i e_i \quad (30)$$


- Pela LFGN e  $\mathbb{E}(\mathbf{x}_i e_i) = 0$ , temos:

$$\hat{Q}_{xe} \xrightarrow{p} Q_{xe} \quad (31)$$

- Como  $\hat{Q}_{xe} \xrightarrow{p} \mathbb{E}(\mathbf{x}_i e_i) = 0$ , temos que

$$\begin{aligned} \hat{\beta} - \beta &= \hat{Q}_{xx}^{-1} \hat{Q}_{xe} \\ &\xrightarrow{p} \hat{Q}_{xx}^{-1} \mathbf{0} = \mathbf{0} \end{aligned} \quad (32) \quad 42/45$$

- Vamos ilustrar esse resultado da consistência da estimação de Mínimos Quadrados com o gráfico a seguir considerando a estimação da equação de salários, onde iremos plotar o coeficiente associado a escolaridade obtido para diferentes tamanhos da amostra.

Figura 7:  $\hat{\beta}_1$  como Função do Tamanho da Amostra

## ECONOMETRIA I

# PROPRIEDADES DE CONVERGÊNCIA FRACA PARA FUNÇÕES DE GRANDES AMOSTRAS: O CASO DOS MÍNIMOS QUADRADOS

Victor Oliveira

Núcleo de Economia Internacional e Desenvolvimento Econômico

PPGDE – 2023