

# ECONOMETRIA I

## MÍNIMOS QUADRADOS RESTRITO

Victor Oliveira

Núcleo de Economia Internacional e Desenvolvimento Econômico

PPGDE – 2023

- 1 Motivação
- 2 Mínimos Quadrados Restrito
- 3 Restrição de Exclusão
- 4 Estimador de Mínimos Quadrados Restritos na Prática
- 5 Seleção de Modelos

# Demanda por Moeda

- Da revisão de diversas teorias sobre a demanda por moeda podemos sintetizar a seguinte modelo econométrico:

$$\frac{M^D}{P} = \beta_0 + \beta_1 \mathbf{y} + \beta_2 \mathbf{r} + \beta_3 \mathbf{P}^* + e_i \quad (1)$$

em que  $M^D$  é o valor nominal da quantidade demandada por moeda,  $P$  é o nível geral de preços (que é o índice geral de preços com base 1),  $\frac{DM}{P}$  é a demanda por saldos reais de moeda,  $r$  é a taxa de juros,  $y$  é o produto real e  $P^*$  é a taxa de inflação.

- Espera-se que  $\beta_1 > 0$ ,  $\beta_2 < 0$  e  $\beta_3 < 0$ .

## Restrições

- 1  $\beta_2 = 0$ : demanda por moeda para os clássicos – motivo transações e precaução

$$\frac{M^D}{P} = \beta_0 + \beta_1 \mathbf{y} + \beta_3 \mathbf{P}^* + e_i \quad (2)$$

- 2  $\beta_2 \neq 0$ : demanda por moeda para os keynesianos – motivo especulação

$$\frac{M^D}{P} = \beta_0 + \beta_1 \mathbf{y} + \beta_2 \mathbf{r} + \beta_3 \mathbf{P}^* + e_i \quad (3)$$

- Empiricamente podemos visualizar essas duas situações em momento em que a economia está passando por um período de inflação baixa e inflação elevada.

- No modelo de projeção linear

$$y_i = \mathbf{x}'_i \boldsymbol{\beta} + e_i \quad (4)$$

$$\mathbb{E}(\mathbf{x}_i e_i) = 0 \quad (5)$$

- Impor uma restrição sobre o vetor de coeficientes  $\boldsymbol{\beta}$  é um exercício comum.
- Podemos particionar  $\mathbf{x}'_i = (\mathbf{x}'_{1i}, \mathbf{x}'_{2i})$  e  $\boldsymbol{\beta}' = (\boldsymbol{\beta}'_1, \boldsymbol{\beta}'_2)$  e temos uma típica restrição de exclusão da forma  $\boldsymbol{\beta}_2 = 0$ .
- Neste caso o modelo é:

$$y_i = \mathbf{x}'_{1i} \boldsymbol{\beta}_1 + e_i \quad (6)$$

$$\mathbb{E}(\mathbf{x}_i e_i) = 0 \quad (7)$$

# Matriz de Restrições

- À primeira vista, esta última equação parecer ser a mesma como a do modelo de projeção linear, mas há uma importante diferença: **o termo de erro  $e_i$  é não correlacionado com o vetor de regressores  $x'_i = (x'_{1i}, x'_{2i})$  e não apenas o regressor incluído  $x'_{1i}$ .**
- De uma forma geral, o conjunto  $q$  de restrições lineares toma a forma de

$$\mathbf{R}'\boldsymbol{\beta} = \mathbf{c} \quad (8)$$

em que  $\mathbf{R}$  é uma matriz  $(k \times q)$ ,  $\text{rank}(\mathbf{R}) = q$  e  $\mathbf{c}$  é um vetor  $(q \times 1)$ . A matriz  $\mathbf{R}$  “codifica” as hipóteses a serem testadas. Cada linha corresponde a uma restrição linear sobre o vetor  $\boldsymbol{\beta}$ .

- O pressuposto de que  $\mathbf{R}$  tem *rank* completo significa que as restrições são linearmente independentes.

- A restrição  $\beta_2 = 0$  é um caso especial com

$$\mathbf{R} = \begin{bmatrix} \mathbf{0} \\ \mathbf{I} \end{bmatrix} \quad (9)$$

em que a matriz  $\mathbf{R}$  “codifica” as hipóteses a serem testadas e  $\mathbf{c} = \mathbf{0}$ .

- Outras restrições poderiam assumir a forma de  $\beta_1 + \beta_2 = 1$ . Esse é o caso de testarmos retornos de escala constante.
- Poderíamos ter restrições testando a igualdade de coeficiente:  $\beta_1 = \beta_2$  ou também uma restrição como  $\beta_1 = -\beta_2$ .
- Vamos ver alguns exemplos de restrições que podem ser implementadas no contexto de análise de regressão.

- Alguns exemplos de hipóteses que podemos testar:

$$H_0: \beta_2 = 0 \quad (10)$$

$$H_0: \beta_2 = -1 \quad (11)$$

$$H_0: \beta_2 + \beta_3 = 1 \quad (12)$$

$$H_0: \beta_2 = \beta_4 \quad (13)$$

$$H_0: \beta_2 - \beta_4 = 0 \quad (14)$$

$$H_0: \beta_2 = \beta_3 = \beta_4 = \cdots = \beta_k = 0 \quad (15)$$

$$H_0: \beta_2 = \beta_3 = 0 \quad (16)$$



- Teríamos as seguintes representações para  $\mathbf{R}$  e  $\mathbf{c}$ :

$$H_0: \beta_2 = 0 \implies \begin{bmatrix} 0 & 1 & 0 & \cdots & 0 \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_k \end{bmatrix} = 0 \quad (17)$$

$$H_0: \beta_2 = -1 \implies \begin{bmatrix} 0 & 1 & 0 & \cdots & 0 \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_k \end{bmatrix} = -1 \quad (18)$$

$$H_0: \beta_2 + \beta_3 = 1 \implies \begin{bmatrix} 0 & 1 & 1 & \cdots & 0 \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_k \end{bmatrix} = 1 \quad (19)$$

$$H_0: \beta_2 - \beta_3 = 0 \implies \begin{bmatrix} 0 & 1 & -1 & \cdots & 0 \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_k \end{bmatrix} = 0 \quad (20)$$

$$H_0: \beta_2 = \beta_3 = \cdots = \beta_k = 0 \implies \begin{bmatrix} 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ 0 & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & . & 0 \\ 0 & 0 & 0 & \cdots & 1 \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_k \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \quad (21)$$

- Por que impor uma restrição?
  - Acreditar ou ter a informação de que a restrição é verdadeira
  - Esperamos que melhore a eficiência da estimação
  - Obter estimativas consistentes com variância reduzida em relação ao estimador não restrito
- **Questões**
  - 1 Como deveríamos estimar o vetor de coeficientes  $\beta$  impondo a restrição linear?
  - 2 Ao impormos essa restrição, qual é a distribuição amostral do estimador resultante?
  - 3 Como calcular o desvio-padrão?

# Mínimos Quadrados Restrito

- Um método intuitivamente atraente para estimar uma projeção linear restrita é minimizar o critério de mínimos quadrados sujeito a restrição  $\mathbf{R}'\boldsymbol{\beta} = c$ . Este estimador é:

$$\tilde{\boldsymbol{\beta}} = \arg \min_{\mathbf{R}'\boldsymbol{\beta}=c} SQE_n(\boldsymbol{\beta}) \quad (22)$$

em que

$$SQE_n(\boldsymbol{\beta}) = \sum_{i=1}^n (y_i - \mathbf{x}_i'\boldsymbol{\beta})^2 = \mathbf{y}'\mathbf{y} - 2\mathbf{y}'\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\beta}'\mathbf{X}'\mathbf{X}\boldsymbol{\beta}. \quad (23)$$

- O estimador  $\tilde{\boldsymbol{\beta}}$  minimiza a soma dos erros ao quadrados sobre todos  $\boldsymbol{\beta}$  tal que a restrição (8) é mantida. Chamamos  $\tilde{\boldsymbol{\beta}}$  ou  $\tilde{\boldsymbol{\beta}}_{cls}$  de **estimador de mínimos quadrados restrito**.

- O método utilizado para encontrar a solução para a eq. (23) utiliza a técnica do Multiplicador de Lagrange. O problema (23) é semelhante a minimização do lagrangiano

$$L(\boldsymbol{\beta}, \boldsymbol{\lambda}) = \frac{1}{2}SQE_n(\boldsymbol{\beta}) + \boldsymbol{\lambda}'(\mathbf{R}'\boldsymbol{\beta} - \mathbf{c}) \quad (24)$$

sobre  $(\boldsymbol{\beta}, \boldsymbol{\lambda})$ , em que  $\boldsymbol{\lambda}$  é um vetor  $s \times 1$  do multiplicador de Lagrange.

- As CPOs para (24) são:

$$\frac{\partial}{\partial \boldsymbol{\beta}} L(\tilde{\boldsymbol{\beta}}, \tilde{\boldsymbol{\lambda}}) = 0 \quad \Longleftrightarrow \quad -\mathbf{X}'\mathbf{y} + \mathbf{X}'\mathbf{X}\tilde{\boldsymbol{\beta}} + \mathbf{R}\tilde{\boldsymbol{\lambda}} = \mathbf{0} \quad (25)$$

$$\frac{\partial}{\partial \boldsymbol{\lambda}} L(\tilde{\boldsymbol{\beta}}, \tilde{\boldsymbol{\lambda}}) = 0 \quad \Longleftrightarrow \quad \mathbf{R}'\tilde{\boldsymbol{\beta}} - \mathbf{c} = \mathbf{0} \quad (26)$$

- Se pré-multiplicarmos a eq. (25) por  $\mathbf{R}'(\mathbf{X}'\mathbf{X})^{-1}$ , obtemos

$$-\mathbf{R}'\hat{\boldsymbol{\beta}} + \mathbf{R}'\tilde{\boldsymbol{\beta}} + \mathbf{R}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}\tilde{\boldsymbol{\lambda}} = \mathbf{0} \quad (27)$$

em que  $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$  é o estimador de mínimos quadrados não restrito. Impondo  $\mathbf{R}'\tilde{\boldsymbol{\beta}} - \mathbf{c} = \mathbf{0}$  e resolvendo para  $\tilde{\boldsymbol{\lambda}}$  encontramos

$$\tilde{\boldsymbol{\lambda}} = \left[ \mathbf{R}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R} \right]^{-1} \left( \mathbf{R}'\hat{\boldsymbol{\beta}} - \mathbf{c} \right) \quad (28)$$

- Como  $(\mathbf{X}'\mathbf{X})^{-1} > 0$  e  $\mathbf{R}$  possui rank completo, temos que:  $\mathbf{R}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R} > 0$ . Substituindo essa expressão em (25) e resolvendo para  $\tilde{\boldsymbol{\beta}}$  encontramos a solução para o problema de minimização dada pela eq. (22)

$$\tilde{\boldsymbol{\beta}} = \hat{\boldsymbol{\beta}} - (\mathbf{X}'\mathbf{X})^{-1}\mathbf{R} \left[ \mathbf{R}'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R} \right]^{-1} \left( \mathbf{R}'\hat{\boldsymbol{\beta}} - \mathbf{c} \right) \quad (29)$$

- A eq. (29) é a fórmula geral para o estimador de mínimos quadrados restrito. Ela ainda pode ser escrita como

$$\tilde{\beta} = \hat{\beta} - \hat{Q}_{xx}^{-1} R \left[ R' \hat{Q}_{xx}^{-1} R \right]^{-1} \left( R' \hat{\beta} - c \right) \quad (30)$$

- Dado  $\tilde{\beta}$  os resíduos são:

$$\tilde{e}_i = y_i - x_i' \tilde{\beta} \quad (31)$$

- O estimador dos momentos de  $\sigma^2$  é:

$$\tilde{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \tilde{e}_i^2 \quad (32)$$



# Restrição de Exclusão

- A eq. (29) é a fórmula geral para o estimador de mínimos quadrados restrito. Na maioria dos casos pode ser obtido aplicando Mínimos Quadrados para uma equação reparametrizada. Para ver isso, considere o modelo não restrito

$$y_i = \mathbf{x}'_{1i}\boldsymbol{\beta}_1 + \mathbf{x}'_{2i}\boldsymbol{\beta}_2 + e_i \quad (33)$$

- A restrição de exclusão é  $\boldsymbol{\beta}_2 = \mathbf{0}$  e a equação restrita é:

$$y_i = \mathbf{x}'_{1i}\boldsymbol{\beta}_1 + e_i \quad (34)$$

- Neste cenário o estimador de mínimos quadrados restrito é o estimador de mínimos quadrados de  $y_i$  em  $x_{1i}$ . Assim,

$$\tilde{\boldsymbol{\beta}}_1 = \left( \sum_{i=1}^n \mathbf{x}_{1i} \mathbf{x}'_{1i} \right)^{-1} \left( \sum_{i=1}^n \mathbf{x}_{1i} y_i \right) \quad (35)$$

- O estimador de mínimos quadrados restrito do vetor inteiro  $\beta' = (\beta'_1, \beta'_2)$  é:

$$\tilde{\beta} = \begin{pmatrix} \tilde{\beta}_1 \\ \mathbf{0} \end{pmatrix} \quad (36)$$

- A eq. (30) e (36) são equivalentes. Para ver isso, seja

$$\tilde{\beta}_1 = (\mathbf{I} \quad \mathbf{0}) \left[ \hat{\beta} - \hat{Q}_{xx}^{-1} \begin{pmatrix} \mathbf{0} \\ \mathbf{I} \end{pmatrix} \left[ (\mathbf{I} \quad \mathbf{0}) \hat{Q}_{xx}^{-1} \begin{pmatrix} \mathbf{0} \\ \mathbf{I} \end{pmatrix} \right]^{-1} (\mathbf{I} \quad \mathbf{0}) \hat{\beta} \right] \quad (37)$$

- Usando

$$\begin{aligned} \hat{Q}_{xx}^{-1} &= \begin{pmatrix} \hat{Q}_{11} & \hat{Q}_{12} \\ \hat{Q}_{21} & \hat{Q}_{22} \end{pmatrix}^{-1} \stackrel{\text{def}}{=} \begin{pmatrix} \hat{Q}^{11} & \hat{Q}^{12} \\ \hat{Q}^{21} & \hat{Q}^{22} \end{pmatrix} \\ &= \begin{pmatrix} \hat{Q}_{11}^{-1} & -\hat{Q}_{11}^{-1} \hat{Q}_{12} \hat{Q}_{22}^{-1} \\ -\hat{Q}_{22}^{-1} \hat{Q}_{21} \hat{Q}_{11}^{-1} & \hat{Q}_{22}^{-1} \end{pmatrix} \end{aligned} \quad (38)$$

- Obtemos

$$\begin{aligned}
\tilde{\beta}_1 &= \hat{\beta}_1 - \hat{Q}^{12} \left( \hat{Q}^{22} \right)^{-1} \hat{\beta}_2 \\
&= \hat{\beta}_1 + \hat{Q}_{11.2}^{-1} \hat{Q}_{12} \hat{Q}_{22}^{-1} \hat{Q}_{22.1} \hat{\beta}_2 \\
&= \hat{Q}_{11.2}^{-1} (\hat{Q}_{1y} - \hat{Q}_{12} \hat{Q}_{22}^{-1} \hat{Q}_{2y}) \\
&\quad + \hat{Q}_{11.2}^{-1} \hat{Q}_{12} \hat{Q}_{22}^{-1} \hat{Q}_{22.1} \hat{Q}_{22.1}^{-1} (\hat{Q}_{2y} - \hat{Q}_{21} \hat{Q}_{11}^{-1} \hat{Q}_{1y}) \\
&= \hat{Q}_{11.2}^{-1} (\hat{Q}_{1y} - \hat{Q}_{12} \hat{Q}_{22}^{-1} \hat{Q}_{21} \hat{Q}_{11}^{-1} \hat{Q}_{1y}) \\
&= \hat{Q}_{11.2}^{-1} (\hat{Q}_{11} - \hat{Q}_{12} \hat{Q}_{22}^{-1} \hat{Q}_{21}) \hat{Q}_{11}^{-1} \hat{Q}_{1y} \\
&= \hat{Q}_{11}^{-1} \hat{Q}_{1y}
\end{aligned} \tag{39}$$

que é igual a eq. (36) como desejamos.

- Há duas abordagens para tratar de mínimos quadrados restrito.

## Abordagem (1)

- 1 *Estimam-se os parâmetros.*
- 2 *Verifica-se se tais estimativas estão muito longe de satisfazer determinadas restrições.*

## Abordagem (2)

- 1 *Impõem-se as restrições lineares diretamente, estimando-se uma **regressão restrita**.*
- 2 *Estima-se a **regressão não restrita (irrestrita)** usual.*
- 3 *Comparam-se os resultados das **regressões restrita e não restrita**, de modo a verificar se a perda de ajuste ocasionada pela imposição das restrições deve-se a amostragem ou realmente indica que as restrições não são válidas.*

- **Questão:** quais das duas abordagens deve prevalecer?
- As duas abordagens são equivalentes. A opção por uma ou outra dependerá da situação:
  - Para testar uma única restrição ou a “*significância global*” da regressão, a primeira abordagem é preferível.
  - Para testar várias restrições, a segunda abordagem é geralmente preferível.
- A estatística de teste a ser utilizada nas aplicações é:

$$F = \frac{\frac{(\tilde{\mathbf{e}}'\tilde{\mathbf{e}} - \hat{\mathbf{e}}'\hat{\mathbf{e}})}{q}}{\frac{(\hat{\mathbf{e}}'\hat{\mathbf{e}})}{(n-k)}} \sim F(q, n-k) \quad (40)$$

- Muitas vezes, o processo de identificação-estimação-diagnóstico conduz não a um, mas a uma lista de possíveis modelos.
- Para selecionar entre tais modelos, pode-se usar critérios de informação, que fornecem medidas de ajuste dos modelos que penalizam o aumento do número de regressores.
- Os critérios de informação mais populares são:
  - Critério de Akaike (AIC):  $AIC(k) = n \ln(SQR) + 2k$
  - Critério de Schwarz (SIC):  $n \ln(SQR) + k \ln(n)$

em que  $n$  é o número de observações,  $k$  é o número de parâmetros estimados e **SQR** é a soma dos quadrados dos resíduos.

- Deve-se escolher o modelo com os menores AIC e SIC.

- Considere os seguintes modelos de regressão:

$$\mathbf{y} = \mathbf{X}_1\beta_1 + \mathbf{X}_2\beta_2 + \mathbf{e} \quad (41)$$

$$\mathbf{y} = \mathbf{X}_1\beta_1 + \mathbf{e} \quad (42)$$

$$\mathbf{y} = \mathbf{X}_1\beta_1 + \mathbf{X}_3\beta_3 + \mathbf{e} \quad (43)$$

- Se  $\beta_2 = 0 \implies$  Modelo (2)
- Se  $\beta_3 = 0 \implies$  Modelo (2)
- A seleção dos modelos pode ser realizada por meio de um **teste de hipótese**.
- É o caso de 1 e de 2 a seguir:
  - Modelo (1) e (2) são *nested*
  - Modelo (3) e (2) são *nested*
  - Modelo (1) e (3) não são *nested*

- Considerando a situação dos modelos não *nested*, podemos adotar um modelo híbrido:

$$\mathbf{y} = \mathbf{X}_1\beta_1 + \mathbf{X}_2\beta_2 + \mathbf{X}_3\beta_3 + \mathbf{e} \quad (44)$$

- O modelo (43) é um caso especial do modelo (44).
- Às vezes não é possível fazer um modelo híbrido dado a forte correlação entre as variáveis explicativas.
- Para comparar os modelos (1) e (2) posso usar o  $\overline{R}^2$ .
- Para comparar os modelos (1) e (3) posso fazer uso dos critérios de informação.



**Questão:** Qual dos dois critérios utilizar?

- ① Ao comparar modelos, deve-se manter  $n$  fixo
- ② O SIC leva a modelos mais parcimoniosos
- ③ O SIC é “assintoticamente consistente”
- ④ O AIC é “assintoticamente viesado” (sobreparametrização)

# ECONOMETRIA I

## MÍNIMOS QUADRADOS RESTRITO

Victor Oliveira

Núcleo de Economia Internacional e Desenvolvimento Econômico

PPGDE – 2023