

# ECONOMETRIA I

## TESTE DE HIPÓTESES LINEARES

Victor Oliveira

Núcleo de Economia Internacional e Desenvolvimento Econômico

PPGDE – 2024

# Sumário I

- 1 Teste de Hipótese Lineares
- 2 Omissão de Variáveis Relevantes
- 3 Inclusão de Variáveis Irrelevantes
- 4 Uso de Variáveis **Proxy**
- 5 Variável *Proxy* Imperfeita

# Teste de Hipótese

- Dado o modelo

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e} \quad (1)$$

podemos estar interessados em testar várias hipóteses sobre os parâmetros  $\beta_1, \beta_2, \dots, \beta_k$ . Por exemplo:

$$H_0 : \beta_2 = 0$$

$$H_0 : \beta_2 = -1$$

$$H_0 : \beta_2 + \beta_3 = 1$$

$$H_0 : \beta_2 = \beta_4$$

$$H_0 : \beta_2 - \beta_4 = 0$$

$$H_0 : \beta_2 = \beta_3 = \beta_4 = \dots = \beta_k = 0$$

$$H_0 : \beta_2 = \beta_3 = 0$$

- Qualquer uma dessas hipóteses pode ser rescrita no formato matricial:

$$\mathbf{R}\boldsymbol{\beta} = \mathbf{c} \quad (2)$$

em que  $\mathbf{R}$  é uma matriz de dimensão  $q \times k$ ,  $\boldsymbol{\beta}$  é um vetor de coeficiente lineares de dimensão  $k \times 1$  e  $\mathbf{c}$  é um vetor de dimensão  $q \times 1$ .

- A matriz  $\mathbf{R}$  “codifica” as hipóteses a serem testadas. Cada linha corresponde a uma restrição linear sobre o vetor  $\boldsymbol{\beta}$ . Logo,  $q$  é o número de restrições a serem testadas.


- Assim, temos que um conjunto qualquer de hipóteses lineares é substituído por uma única hipótese matricial:

$$H_0: R\beta - c = 0 \quad (3)$$

- Questão:** o vetor  $(R\beta - c)$  tem um comprimento maior do que zero?
- Duas situações
  - Se esse comprimento é nulo, significa aceitar o conjunto das hipóteses codificadas em  $R$  e  $c$ .
  - Se o comprimento é maior do que zero, corresponde a rejeição de um ou mais das hipóteses conjuntas originais.
- Como  $\beta$  é não conhecido, temos que o vetor  $(R\beta - c)$  também será não conhecido. É por isso que vamos testar a hipótese nula através do estimador de mínimos quadrados. Assim, dado o estimador  $\hat{\beta}$ , podemos calcular o vetor  $(R\hat{\beta} - c)$ .

# Espaço Geométrico

Figura 1: Geometria do teste de hipótese



- Quanto mais longe o vetor  $(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c})$  estiver de  $\mathbf{0}$ , menos provável é que o vetor  $(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c})$  seja igual a zero. Com isso, tenderemos a rejeitar a hipótese nula.
- Como em qualquer teste de hipótese, a questão principal é se o desvio de  $(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c})$  em relação a  $\mathbf{0}$  pode ser atribuído a erro de amostragem, ou se é de fato significativo.
- Para testar  $H_0$ , vamos investigar a distribuição do quadrado do comprimento de  $(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c})$ , sob  $H_0$ .
- Esse vetor nada mais é do que uma transformação linear do vetor aleatório  $\hat{\boldsymbol{\beta}}$ , cuja distribuição é dada por:

$$\hat{\boldsymbol{\beta}} \sim N\left(\boldsymbol{\beta}, \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\right) \quad (4)$$

- Temos que:

$$\mathbb{E}(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c}) = \mathbb{E}(\mathbf{R}\boldsymbol{\beta} - \mathbf{c}) = 0 \quad (5)$$

sob a hipótese nula.

- E

$$\begin{aligned} \text{var}(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c}) &= \text{var}(\mathbf{R}\hat{\boldsymbol{\beta}}) = \mathbb{E}\left[(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{R}\boldsymbol{\beta})(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{R}\boldsymbol{\beta})'\right] \\ &= \mathbb{E}\left[\mathbf{R}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})'\mathbf{R}'\right] \\ &= \mathbf{R} \text{var}(\hat{\boldsymbol{\beta}}) \mathbf{R}' \\ &= \sigma^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}' \end{aligned} \quad (6)$$

- Assim,

$$(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c}) \sim N(\mathbf{0}, \sigma^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}') \quad (7)$$



- Se  $(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c})$  é uma normal multivariada com média  $\mathbf{0}$ , o seu comprimento ao quadrado, dado por  $(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c})(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c})'$  também será uma soma de quadrados de uma variáveis aleatórias normais.
- É uma variável aleatória não tabelada, mas com um forte “parentesco” com uma variável aleatória qui-quadrado.
- **Questão:** como torná-la uma qui-quadrado, com valores críticos conhecidos? Vamos usar um resultado para distribuições de formas quadráticas e mostrar que ela possui distribuição qui-quadrado.
- Se um vetor  $\mathbf{x}$  de dimensão  $q \times 1$  tem distribuição

$$\mathbf{x} \sim N(\mathbf{0}, \Sigma) \text{ então } \mathbf{x}'\Sigma^{-1}\mathbf{x} \sim \chi^2(q) \quad (8)$$

- Assim, chegamos a uma variável aleatória tabelada, sobre a qual poderíamos realizar testes de hipóteses:

$$\left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c}\right)' \left[\sigma^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}'\right]^{-1} \left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c}\right) \sim \chi^2(q) \quad (9)$$

- Essa expressão deve ser entendida como o quadrado do comprimento “padronizado” do vetor  $(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c})$ , isto é, medido em desvios padrões.
- O problema prático que surge com a aplicação acima é a presença de  $\sigma^2$ , que é um parâmetro desconhecido.
- Contudo, sabemos que

$$\frac{\mathbf{e}'\mathbf{e}}{\sigma^2} \sim \chi^2(n - k) \quad (10)$$

e que esta estatística tem distribuição independente de  $\hat{\boldsymbol{\beta}}$ .

# Distribuição do Teste de Hipótese

- Também sabemos que a razão entre duas variáveis qui-quadrado independentes, divididas pelos respectivos graus de liberdade  $n_1$  e  $n_2$ , gera uma variável com distribuição  $F(n_1, n_2)$ .
- Então podemos concluir que:

$$\frac{\frac{\left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c}\right)' \left[\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}'\right]^{-1} \left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c}\right)}{q}}{\frac{(\mathbf{e}'\mathbf{e})}{(n-k)}} \sim F(q, n-k) \quad (11)$$

- Usando a definição de  $s^2$ , obtemos:

$$\frac{\left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c}\right)' \left[s^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}'\right]^{-1} \left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c}\right)}{q} \sim F(q, n-k) \quad (12)$$

- A estatística dada pela eq. (12) pode ser usada para testar hipóteses lineares sobre o vetor  $\beta$ .
- A regra de decisão será: valores elevados da estatística apontam para a rejeição de  $H_0$ .
- **Observação:** a raiz quadrada de uma variável  $F(1, n)$  é uma variável  $t(n)$ .
- Assim, no caso de uma única restrição ( $q = 1$ ), a raiz quadrada da estatística  $F$ , eq. (12), equivale a uma estatística  $t$ .

## Exemplo 1

- Vamos testar a hipótese nula  $H_0: \beta_2 = 0$ .
- A hipótese escrita no formato geral se torna:  $\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c} = \hat{\beta}_2$ .
- Assim,  $\text{var}(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c}) = s^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}' = \text{var}(\hat{\beta}_2)$ . Usando a eq. (12), temos:

$$\frac{\hat{\beta}_2' [\text{var}(\hat{\beta}_2)]^{-1} \hat{\beta}_2}{1} = \frac{\hat{\beta}_2^2}{\text{var}(\hat{\beta}_2)} \sim F(1, n - k) \quad (13)$$

- Tirando a raiz quadrada, temos:

$$\frac{\hat{\beta}_2}{d.p.(\hat{\beta}_2)} \sim t(n - k) \quad (14)$$

## Exemplo 2

- Vamos testar a hipótese nula  $H_0: \beta_2 + \beta_3 = 1$ . Com isso,  $\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c} = \hat{\beta}_2 + \hat{\beta}_3 - 1$ .
- Assim,

$$s^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}' =$$

$$= s^2 \begin{bmatrix} 0 & 1 & 1 & 0 & \cdots & 0 \end{bmatrix} \begin{bmatrix} c_{11} & c_{21} & c_{31} & \cdots & c_{k1} \\ c_{12} & c_{22} & c_{32} & \cdots & c_{k2} \\ c_{13} & c_{23} & c_{33} & \cdots & c_{k3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ c_{1k} & c_{2k} & c_{3k} & \cdots & c_{kk} \end{bmatrix} \begin{bmatrix} 0 \\ 1 \\ 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \quad (15)$$

- Desse modo,

$$\begin{aligned}
 s^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}' &= s^2(c_{22} + c_{23} + c_{32} + c_{33}) \\
 &= s^2(c_{22} + 2c_{23} + c_{33}) \\
 &= \text{var}(\hat{\beta}_2) + 2\text{cov}(\hat{\beta}_2, \hat{\beta}_3) + \text{var}(\hat{\beta}_3) \\
 &= \text{var}(\hat{\beta}_2 + \hat{\beta}_3)
 \end{aligned} \tag{16}$$

- Logo,

$$\frac{(\hat{\beta}_2 + \hat{\beta}_3 - 1)' [\text{var}(\hat{\beta}_2 + \hat{\beta}_3)]^{-1} (\hat{\beta}_2 + \hat{\beta}_3 - 1)}{1} = \frac{(\hat{\beta}_2 + \hat{\beta}_3 - 1)^2}{\text{var}(\hat{\beta}_2 + \hat{\beta}_3)}$$

que segue  $\sim F(1, n - k)$ .

- Tirando a raiz quadrada, temos:

$$\frac{\hat{\beta}_2 + \hat{\beta}_3 - 1}{d.p.(\hat{\beta}_2 + \hat{\beta}_3)} \sim t(n - k) \quad (17)$$



# Caso Geral

- Generalizando, testamos a hipótese nula  $H_0: \beta_2 = \beta_3 = \dots = \beta_k = \mathbf{0}$ .
- Assim,

$$\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c} = \begin{bmatrix} \hat{\beta}_2 \\ \hat{\beta}_3 \\ \vdots \\ \hat{\beta}_k \end{bmatrix} = \hat{\boldsymbol{\beta}} \quad (18)$$

- Desse modo,

$$\begin{aligned}
 s^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}' &= \\
 &= s^2 \begin{bmatrix} 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{bmatrix} \begin{bmatrix} c_{11} & c_{21} & c_{31} & \cdots & c_{k1} \\ c_{12} & c_{22} & c_{32} & \cdots & c_{k2} \\ c_{13} & c_{23} & c_{33} & \cdots & c_{k3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ c_{1k} & c_{2k} & c_{3k} & \cdots & c_{kk} \end{bmatrix} \begin{bmatrix} 0 & 0 & \cdots & 0 \\ 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} \\
 &= s^2 \begin{bmatrix} c_{22} & \cdots & c_{k2} \\ \vdots & . & \vdots \\ c_{2k} & \vdots & c_{kk} \end{bmatrix} \\
 &= s^2 \mathbf{C}
 \end{aligned} \tag{19}$$

- A estatística de teste é dada por:

$$F = \frac{\widehat{\boldsymbol{\beta}}'(s^2\mathbf{C})^{-1}\widehat{\boldsymbol{\beta}}}{k-1} \sim F(k-1, n-k) \quad (20)$$

ou

$$F = \frac{\widehat{\boldsymbol{\beta}}'\widehat{\boldsymbol{\beta}}}{(s^2\mathbf{C})(k-1)} \sim F(k-1, n-k) \quad (21)$$

# Omissão de Variáveis Relevantes

- Suponha que o modelo verdadeiro seja

$$\mathbf{y} = \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{X}_2\boldsymbol{\beta}_2 + \mathbf{e} \quad (22)$$

- Porém o modelo estimado foi

$$\mathbf{y} = \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{e} \quad (23)$$

ou seja, estima-se um modelo caracterizado pela omissão de um conjunto de variáveis relevantes  $\mathbf{X}_2$ .

- O estimador de mínimos quadrados para eq. (23) é dado por:

$$\begin{aligned} \hat{\boldsymbol{\beta}}_1 &= (\mathbf{X}_1'\mathbf{X}_1)^{-1}\mathbf{X}_1'\mathbf{y} \\ &= (\mathbf{X}_1'\mathbf{X}_1)^{-1}\mathbf{X}_1'(\mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{X}_2\boldsymbol{\beta}_2 + \mathbf{e}) \\ &= \boldsymbol{\beta}_1 + (\mathbf{X}_1'\mathbf{X}_1)^{-1}\mathbf{X}_1'\mathbf{X}_2\boldsymbol{\beta}_2 + (\mathbf{X}_1'\mathbf{X}_1)^{-1}\mathbf{X}_1'\mathbf{e} \end{aligned} \quad (24)$$

- Tomando o valor esperado, temos:

$$\mathbb{E}(\hat{\beta}_1) = \beta_1 + (\mathbf{X}'_1 \mathbf{X}_1)^{-1} \mathbf{X}'_1 \mathbf{X}_2 \beta_2 \quad (25)$$

- Vemos que  $\hat{\beta}_1$  será viesado. Isso só não ocorre se  $\mathbf{X}_1 \mathbf{X}_2 = \mathbf{0}$ . Isto é, se os regressores incluídos no modelo sejam ortogonais aos regressores omitidos.
- Se algumas variável relevante for omitida do modelo, e se a correlação dessa variável com as variáveis incluídas no modelo não for zero, então o estimador de Mínimos Quadrados será viesado.**
- Na prática, é improvável que os regressores sejam ortogonais, de forma que deve-se esperar que a omissão de variáveis relevantes gere estimativas viesadas.

- O sinal do viés será determinado pelo sinal da covariância entre  $\mathbf{X}'_1\mathbf{X}_2$  e  $\beta_2$ . Temos as seguintes possibilidades:
  - 1 Se  $\mathbf{X}'_1\mathbf{X}_2 > 0$  e  $\beta_2 > 0$ : o sinal do viés será positivo;
  - 2 Se  $\mathbf{X}'_1\mathbf{X}_2 < 0$  e  $\beta_2 < 0$ : o sinal do viés será positivo;
  - 3 Se  $\mathbf{X}'_1\mathbf{X}_2 > 0$  e  $\beta_2 < 0$ : o sinal do viés será negativo;
  - 4 Se  $\mathbf{X}'_1\mathbf{X}_2 < 0$  e  $\beta_2 > 0$ : o sinal do viés será negativo;

## Viés de Omissão e Variância

- O que acontece com a **variância do estimador de mínimos quadrados** ao omitirmos variáveis relevantes?
- A variância do estimador de mínimos quadrados no modelo dado pela eq. (23) é dada por:

$$\text{var}(\hat{\beta}_1) = \sigma^2 (\mathbf{X}'_1 \mathbf{X}_1)^{-1} \quad (26)$$

- Caso fosse estimado o modelo verdadeiro dado pela eq. (22), a variância seria:

$$\begin{aligned} \text{var}(\hat{\beta}_{1,2}) &= \sigma^2 (\mathbf{X}'_1 \mathbf{M}_2 \mathbf{X}_1)^{-1} \\ &= \sigma^2 \left[ \mathbf{X}'_1 \mathbf{X}_1 - \mathbf{X}'_1 \mathbf{X}_2 (\mathbf{X}'_2 \mathbf{X}_2)^{-1} \mathbf{X}'_2 \mathbf{X}_1 \right]^{-1} \end{aligned} \quad (27)$$

em que  $\mathbf{M}_2 = \mathbf{I} - \mathbf{X}_2 (\mathbf{X}'_2 \mathbf{X}_2)^{-1} \mathbf{X}'_2$ .

- Podemos comparar as duas matrizes de variância comparando as suas inversas.

$$\text{var}(\hat{\beta}_1) - \text{var}(\hat{\beta}_{1.2}) = \left(\frac{1}{\sigma^2}\right) \mathbf{X}'_1 \mathbf{X}_2 (\mathbf{X}'_2 \mathbf{X}_2)^{-1} \mathbf{X}'_2 \mathbf{X}_1 \quad (28)$$

que é uma matriz positiva definida. O  $\hat{\beta}_1$  é viesado, porém ele possui menor variância do que  $\hat{\beta}_{1.2}$ .

- A inversa da variância de  $\hat{\beta}_1$  é maior que a inversa da variância de  $\hat{\beta}_{1.2}$ . Ou seja, a variância de  $\hat{\beta}_1$  é menor que a variância de  $\hat{\beta}_{1.2}$ .
- Outro problema diz respeito à estimação de  $\sigma^2$  que é necessária para realização de inferências (teste de hipótese e intervalos de confiança). O estimador usual é dado por:

$$s^2 = \frac{e'e}{n - k} \quad (29)$$



- Podemos mostrar que esse estimador também é viesado. Note que

$$\mathbf{e}_1 = \mathbf{M}_1 \mathbf{y} = \mathbf{M}_1 (\mathbf{X}_1 \boldsymbol{\beta}_1 + \mathbf{X}_2 \boldsymbol{\beta}_2 + \mathbf{e}) = \mathbf{M}_1 \mathbf{X}_2 \boldsymbol{\beta}_2 + \mathbf{M}_1 \mathbf{e} \quad (30)$$

- Para obter o valor esperado de  $\mathbf{e}_1' \mathbf{e}_1$ , usamos a mesma abordagem anterior e consideramos  $\mathbb{E}[\mathbf{X}_1' \mathbf{e}] = 0$ . Assim obtemos:

$$\begin{aligned} \mathbb{E}[\mathbf{e}_1' \mathbf{e}_1] &= \boldsymbol{\beta}_2' \mathbf{X}_2' \mathbf{M}_1 \mathbf{X}_2 \boldsymbol{\beta}_2 + \sigma^2 \text{tr}(\mathbf{M}_1) \\ &= \boldsymbol{\beta}_2' \mathbf{X}_2' \mathbf{M}_1 \mathbf{X}_2 \boldsymbol{\beta}_2 + (n - k) \sigma^2 \end{aligned} \quad (31)$$

- O primeiro termo é positivo, tal que  $s^2$  é viesado para cima, não sendo possível estimar  $\sigma^2$ . Portanto, não é possível testar hipóteses sobre o vetor de coeficientes  $\boldsymbol{\beta}_1$ .
- Conclusão:** se omitirmos variáveis relevantes da regressão, então obtemos estimativas para  $\boldsymbol{\beta}_1$  e  $\sigma^2$  viesadas!

- Suponha que o modelo verdadeiro seja

$$\mathbf{y} = \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{e} \quad (32)$$

- Porém o modelo estimado foi

$$\begin{aligned} \mathbf{y} &= \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{X}_2\boldsymbol{\beta}_2 + \mathbf{e} \\ &= \mathbf{X}\boldsymbol{\beta} + \mathbf{e} \end{aligned} \quad (33)$$

em que  $\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 & \mathbf{X}_2 \end{bmatrix}$  e  $\boldsymbol{\beta} = \begin{bmatrix} \boldsymbol{\beta}_1 \\ \boldsymbol{\beta}_2 \end{bmatrix}$ .

- Nesse caso, o estimador de mínimos quadrados é dado pela fórmula usual, e **não é viesado**:

$$\begin{aligned}\hat{\beta} &= (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y} \\ &= \beta + (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{e}\end{aligned}\tag{34}$$

- Note que

$$\mathbb{E}(\hat{\beta}) = \beta = \begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix} = \begin{bmatrix} \beta_1 \\ \mathbf{0} \end{bmatrix}\tag{35}$$

- Da mesma forma, a variância do estimador de mínimos quadrados é dada pela fórmula usual e **também não é viesada**.
- Tais resultados parecem indicar que a inclusão de variáveis irrelevantes não causa nenhum problema de estimação. Porém, **essa conclusão está errada!!**

- É importante pensar que temos duas situações:
  - ① Estimar um modelo omitindo uma variável relevante equivale a impor uma restrição falsa (restrição de que o coeficiente da variável é zero).
  - ② Estimar um modelo incluindo uma variável irrelevante equivale a deixar de impor uma restrição verdadeira (restrição de que o coeficiente da variável é zero).
- O custo da segunda situação é a **perda de precisão da estimação**. Conforme vimos, a variância do estimador de mínimos quadrados aumenta com a inclusão de novas variáveis explicativas.

# Variável Proxy

- Considere um modelo que assume um efeito aditivo da variável omitida dado por:

$$\mathbb{E}(y|x_1, x_2, \dots, x_k, q) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \gamma q \quad (36)$$

em que  $q$  é um fator omitido. Estamos interessados em  $\beta_j$  que são os efeitos parciais das variáveis explicativas observáveis.

- Observando a eq. (36) como um modelo estrutural, podemos escrever na forma de erro como:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \gamma q + \nu \quad (37)$$

$$\mathbb{E}(\nu|x_1, x_2, \dots, x_k, q) = 0 \quad (38)$$

em que  $\nu$  é o **erro estrutural**.

- Uma forma de manusear o aspecto não observável de  $q$  é incorporar ele dentro do termo de erro. Assim, podemos reescrever a eq. (37) como

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + u \quad (39)$$

$$u = \gamma q + \nu \quad (40)$$

- O termo de erro  $u$  consiste de duas partes. Sob a eq. (38),  $\nu$  tem média zero e é não correlacionado com  $x_1, x_2, \dots, x_k, q$ . Pela normalização,  $q$  também tem média zero.
- Assim,  $\mathbb{E}(u) = 0$ . Mas  $u$  é não correlacionado com  $x_j$  apenas se  $q$  é não correlacionado com  $x_j$ . Se  $q$  for correlacionado com algum dos regressores, o erro  $u$  também será, e teremos um problema de endogeneidade. Não podemos esperar estimativas consistentes de mínimos quadrados para  $\beta_j$ .
- Assim, o estimador de mínimos quadrados na presença de variável omitida é inconsistente ou estimador de mínimos quadrados é viesado.

- O viés de variável omitida pode ser eliminado ou no mínimo mitigado se é possível usar uma **variável proxy** par a variável não observada  $q$ .
- Para o uso de uma **variável proxy**, duas condições devem ser cumpridas:
  - A **variável proxy** deveria ser redundante (irrelevante) na equação estrutural;
  - A correlação entre a variável omitida  $q$  e cada  $x$  deve ser zero depois de controlarmos para  $z$ .

## Condição (1)

*Se  $z$  é uma variável proxy para  $q$ , então devemos esperar a redundância de  $z$  na eq. (41):*

$$\mathbb{E}(y|\mathbf{x}, q, z) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \gamma q + \delta z \quad (41)$$

*isto é,*

$$\mathbb{E}(y|\mathbf{x}, q, z) = \mathbb{E}(y|\mathbf{x}, q) \quad (42)$$

- Essa condição é fácil de interpretar:  $z$  é irrelevante para explicar  $y$  no sentido de média condicional, uma vez que  $\mathbf{x}$  e  $q$  tenham sido utilizados. Embora seja difícil de verificar isso, não podemos ir muito longe sem essa condição!



## Condição (2)

*É uma condição mais complicada. Requer que a correlação entre a variável omitida  $q$  e cada  $x_j$  seja zero uma vez que retiramos  $z$ . Podemos ver isso em termos da projeção linear:*

$$\mathbb{P}(q|1, x_1, x_2, \dots, x_k, z) = \mathbb{P}(q|z) \quad (43)$$

*É útil ver essa relação em termos de uma equação com o componente de erro não observado. Considere  $q$  como uma função linear de  $z$  e um termo de erro como:*

$$q = \theta_0 + \theta_1 z + r, \quad (44)$$

*em que, por definição,  $\mathbb{E}(r) = 0$  e a  $\text{cov}(z, r) = 0$  por conta de que  $\theta_0 + \theta_1 z$  é uma projeção linear de  $\mathbf{q}$  em  $\mathbf{1}, z$ .*

- Se  $z$  é uma *proxy* razoável para  $q$ ,  $\theta_1 \neq 0$ . Porém, a condição é mais forte: ela é equivalente a

$$\text{cov}(x_j, r) = 0 \quad (45)$$

para  $j = 1, 2, \dots, k$ .

- Esta condição requer que  $z$  seja próximo o suficiente e relacionado a  $q$  tal que, uma vez ele incluído, os  $x_j$  não são parcialmente correlacionados com  $q$ .
- A definição de **variável proxy** aqui não é universal. Enquanto assumimos que a **variável proxy** está satisfazendo a condição de redundância (41), nem sempre assumimos satisfazer a segunda condição.

- Para obter uma equação estimável, substituímos  $q$  na eq. (44) com a eq. (41) para obter:

$$y = (\beta_0 + \gamma\theta_0) + \beta_1x_1 + \beta_2x_2 + \cdots + \beta_kx_k + \gamma\theta_1z + (\gamma r + \nu) \quad (46)$$

- Sob o pressuposto feito, o termo de erro composto  $u = \gamma r + \nu$  é não correlacionado com  $x_j$  para todo  $j$ ; redundância de  $z$  significa que  $z$  é não correlacionado com  $\nu$  e, por definição,  $z$  é não correlacionado com  $r$ .
- Disso teremos que: a regressão de mínimos quadrados de  $y$  em  $1, x_1, x_2, \dots, x_k, z$  produz estimadores consistentes de  $(\beta_0 + \gamma\theta_0)$ ,  $\beta_1, \beta_2, \dots, \beta_k$  e  $\gamma\theta_1$ .
- Assim, podemos estimar os efeitos parciais de cada  $x_j$  sob o pressuposto da **variável proxy**.

## Variável *Proxy* Imperfeita

- Quando  $z$  é uma variável *proxy* imperfeita, então  $r$  na eq. (46) é correlacionada com um ou mais dos  $x_j$ . Assim, a projeção linear passa a ser:

$$q = \theta_0 + \rho_1 x_1 + \rho_2 x_2 + \cdots + \rho_k x_k + \theta_1 z + r, \quad (47)$$

a regressão da variável *proxy* resulta em  $\text{plim } \hat{\beta}_j = \beta_j + \gamma \rho_j$ . O estimador de mínimos quadrados com uma variável *proxy* imperfeita é inconsistente.

- A esperança é que  $\rho_j$  seja menor do que se  $z$  fosse omitido da projeção linear.

# Variável *proxy* imperfeita

- Se a inclusão da variável *proxy*  $z$  induz a uma substancial colinearidade, deve ser melhor usar o estimador de mínimos quadrados sem a variável *proxy*.
- É importante considerar que incluir  $z$  reduz a variância do erro se  $\theta_1 \neq 0$ :  $\text{var}(\gamma r + \nu) < \text{var}(\gamma q + \nu)$  porque  $\text{var}(r) < \text{var}(q)$ , e  $\nu$  é não correlacionado com  $r$  e  $q$ .
- **Incluir uma variável *proxy* pode reduzir a variância assintótica bem como mitigar o viés.**

# Exemplo

- Vamos aplicar o método da variável *proxy* para estimar o modelo estrutural

$$\log(\text{wage}) = \beta_0 + \beta_1 \text{exper} + \beta_2 \text{tenure} + \beta_3 \text{casado} + \beta_4 \text{sul} + \beta_5 \text{urbana} + \beta_6 \text{black} + \beta_7 \text{escolaridade} + \gamma \text{habil} + \nu$$

- Assumimos que  $QI$  satisfaz o pressuposto de variável *proxy*: em um modelo de projeção linear

$$\text{habil} = \theta_0 + \theta_1 QI + r$$

em que  $\mathbb{E}(r) = 0$  e  $\mathbb{E}(QI, r) = 0$ . Assumimos que  $r$  seja não correlacionado com todos os regressores da eq. de salários,  $\mathbb{E}(r|\mathbf{x}) = 0$ .

- A equação estimada **sem a variável *proxy* QI** é dada por

$$\begin{aligned} \log wage = & 5.40 + 0.014exper + 0.012tenure + 0.199casado \\ & (0.11) \quad (0.003) \quad (0.002) \quad (0.039) \\ & - 0.091sul + 0.184urbana - 0.188black \\ & (0.026) \quad (0.027) \quad (0.38) \\ & + 0.065escolaridade \\ & (0.008) \end{aligned}$$

- A equação estimada **com a variável *proxy* QI** é dada por

$$\begin{aligned} \log wage = & 5.18 + 0.014exper + 0.011tenure + 0.200casado \\ & (0.13) \quad (0.003) \quad (0.002) \quad (0.039) \\ & - 0.080sul + 0.182urbana - 0.143black \\ & (0.026) \quad (0.027) \quad (0.39) \\ & + 0.054escolaridade + 0.0036QI \\ & (0.007) \quad (0.0010) \end{aligned}$$

# ECONOMETRIA I

## TESTE DE HIPÓTESES LINEARES

Victor Oliveira

Núcleo de Economia Internacional e Desenvolvimento Econômico

PPGDE – 2024