

ECONOMETRIA I

TESTE DE HIPÓTESES LINEARES

Victor Oliveira

Núcleo de Economia Internacional e Desenvolvimento Econômico

PPGDE – 2023

- 1 Teste de Hipótese Lineares
- 2 Omissão de Variáveis Relevantes
- 3 Inclusão de Variáveis Irrelevantes
- 4 Uso de Variáveis **Proxy**
- 5 Variável *Proxy* Imperfeita

Teste de Hipótese

- Dado o modelo

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e} \quad (1)$$

podemos estar interessados em testar várias hipóteses sobre os parâmetros $\beta_1, \beta_2, \dots, \beta_k$. Por exemplo:

$$H_0 : \beta_2 = 0$$

$$H_0 : \beta_2 = -1$$

$$H_0 : \beta_2 + \beta_3 = 1$$

$$H_0 : \beta_2 = \beta_4$$

$$H_0 : \beta_2 - \beta_4 = 0$$

$$H_0 : \beta_2 = \beta_3 = \beta_4 = \dots = \beta_k = 0$$

$$H_0 : \beta_2 = \beta_3 = 0$$

- Qualquer uma dessas hipóteses pode ser rescrita no formato matricial:

$$\mathbf{R}\boldsymbol{\beta} = \mathbf{c} \quad (2)$$

em que \mathbf{R} é uma matriz de dimensão $q \times k$, $\boldsymbol{\beta}$ é um vetor de coeficiente lineares de dimensão $k \times 1$ e \mathbf{c} é um vetor de dimensão $q \times 1$.

- A matriz \mathbf{R} “codifica” as hipóteses a serem testadas. Cada linha corresponde a uma restrição linear sobre o vetor $\boldsymbol{\beta}$. Logo, q é o número de restrições a serem testadas.


- Assim, temos que um conjunto qualquer de hipóteses lineares é substituído por uma única hipótese matricial:

$$H_0: R\beta - c = 0 \quad (3)$$

- Questão:** o vetor $(R\beta - c)$ tem um comprimento maior do que zero?
- Duas situações
 - Se esse comprimento é nulo, significa aceitar o conjunto das hipóteses codificadas em R e c .
 - Se o comprimento é maior do que zero, corresponde a rejeição de um ou mais das hipóteses conjuntas originais.
- Como β é não conhecido, temos que o vetor $(R\beta - c)$ também será não conhecido. É por isso que vamos testar a hipótese nula através do estimador de mínimos quadrados. Assim, dado o estimador $\hat{\beta}$, podemos calcular o vetor $(R\hat{\beta} - c)$.

Espaço Geométrico

Figura 1: Geometria do teste de hipótese



- Quanto mais longe o vetor $(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c})$ estiver de $\mathbf{0}$, menos provável é que o vetor $(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c})$ seja igual a zero. Com isso, tenderemos a rejeitar a hipótese nula.
- Como em qualquer teste de hipótese, a questão principal é se o desvio de $(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c})$ em relação a $\mathbf{0}$ pode ser atribuído a erro de amostragem, ou se é de fato significativo.
- Para testar H_0 , vamos investigar a distribuição do quadrado do comprimento de $(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c})$, sob H_0 .
- Esse vetor nada mais é do que uma transformação linear do vetor aleatório $\hat{\boldsymbol{\beta}}$, cuja distribuição é dada por:

$$\hat{\boldsymbol{\beta}} \sim N\left(\boldsymbol{\beta}, \sigma^2(\mathbf{X}'\mathbf{X})^{-1}\right) \quad (4)$$

- Temos que:

$$\mathbb{E}(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c}) = \mathbb{E}(\mathbf{R}\boldsymbol{\beta} - \mathbf{c}) = 0 \quad (5)$$

sob a hipótese nula.

- E

$$\begin{aligned} \text{var}(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c}) &= \text{var}(\mathbf{R}\hat{\boldsymbol{\beta}}) = \mathbb{E}\left[(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{R}\boldsymbol{\beta})(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{R}\boldsymbol{\beta})'\right] \\ &= \mathbb{E}\left[\mathbf{R}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})'\mathbf{R}'\right] \\ &= \mathbf{R} \text{var}(\hat{\boldsymbol{\beta}}) \mathbf{R}' \\ &= \sigma^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}' \end{aligned} \quad (6)$$

- Assim,

$$(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c}) \sim N(\mathbf{0}, \sigma^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}') \quad (7)$$

- Se $(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c})$ é uma normal multivariada com média $\mathbf{0}$, o seu comprimento ao quadrado, dado por $(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c}) (\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c})'$ também será uma soma de quadrados de uma variáveis aleatórias normais.
- É uma variável aleatória não tabelada, mas com um forte “parentesco” com uma variável aleatória qui-quadrado.
- **Questão:** como torná-la uma qui-quadrado, com valores críticos conhecidos? Vamos usar um resultado para distribuições de formas quadráticas e mostrar que ela possui distribuição qui-quadrado.
- Se um vetor \mathbf{x} de dimensão $q \times 1$ tem distribuição

$$\mathbf{x} \sim N(\mathbf{0}, \Sigma) \text{ então } \mathbf{x}'\Sigma^{-1}\mathbf{x} \sim \chi^2(q) \quad (8)$$

- Assim, chegamos a uma variável aleatória tabelada, sobre a qual poderíamos realizar testes de hipóteses:

$$\left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c}\right)' \left[\sigma^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}'\right]^{-1} \left(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c}\right) \sim \chi^2(q) \quad (9)$$

- Essa expressão deve ser entendida como o quadrado do comprimento “padronizado” do vetor $(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c})$, isto é, medido em desvios padrões.
- O problema prático que surge com a aplicação acima é a presença de σ^2 , que é um parâmetro desconhecido.
- Contudo, sabemos que

$$\frac{\mathbf{e}'\mathbf{e}}{\sigma^2} \sim \chi^2(n - k) \quad (10)$$

e que esta estatística tem distribuição independente de $\hat{\boldsymbol{\beta}}$.

Distribuição do Teste de Hipótese

- Também sabemos que a razão entre duas variáveis qui-quadrado independentes, divididas pelos respectivos graus de liberdade n_1 e n_2 , gera uma variável com distribuição $F(n_1, n_2)$.
- Então podemos concluir que:

$$\frac{\frac{(R\hat{\beta} - c)' [R(X'X)^{-1}R']^{-1} (R\hat{\beta} - c)}{q}}{\frac{(e'e)}{(n-k)}} \sim F(q, n-k) \quad (11)$$

- Usando a definição de s^2 , obtemos:

$$\frac{(R\hat{\beta} - c)' [s^2 R(X'X)^{-1}R']^{-1} (R\hat{\beta} - c)}{q} \sim F(q, n-k) \quad (12)$$

- A estatística dada pela eq. (12) pode ser usada para testar hipóteses lineares sobre o vetor β .
- A regra de decisão será: valores elevados da estatística apontam para a rejeição de H_0 .
- **Observação:** a raiz quadrada de uma variável $F(1, n)$ é uma variável $t(n)$.
- Assim, no caso de uma única restrição ($q = 1$), a raiz quadrada da estatística F , eq. (12), equivale a uma estatística t .

Exemplo 1

- Vamos testar a hipótese nula $H_0: \beta_2 = 0$.
- A hipótese escrita no formato geral se torna: $\mathbf{R}\hat{\beta} - \mathbf{c} = \hat{\beta}_2$.
- Assim, $\text{var}(\mathbf{R}\hat{\beta} - \mathbf{c}) = s^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}' = \text{var}(\hat{\beta}_2)$. Usando a eq. (12), temos:

$$\frac{\hat{\beta}_2' [\text{var}(\hat{\beta}_2)]^{-1} \hat{\beta}_2}{1} = \frac{\hat{\beta}_2^2}{\text{var}(\hat{\beta}_2)} \sim F(1, n - k) \quad (13)$$

- Tirando a raiz quadrada, temos:

$$\frac{\hat{\beta}_2}{d.p.(\hat{\beta}_2)} \sim t(n - k) \quad (14)$$

Exemplo 2

- Vamos testar a hipótese nula $H_0: \beta_2 + \beta_3 = 1$. Com isso, $\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{c} = \hat{\beta}_2 + \hat{\beta}_3 - 1$.
- Assim,

$$s^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1} \mathbf{R}' =$$

$$= s^2 \begin{bmatrix} 0 & 1 & 1 & 0 & \cdots & 0 \end{bmatrix} \begin{bmatrix} c_{11} & c_{21} & c_{31} & \cdots & c_{k1} \\ c_{12} & c_{22} & c_{32} & \cdots & c_{k2} \\ c_{13} & c_{23} & c_{33} & \cdots & c_{k3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ c_{1k} & c_{2k} & c_{3k} & \cdots & c_{kk} \end{bmatrix} \begin{bmatrix} 0 \\ 1 \\ 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \quad (15)$$

- Desse modo,

$$\begin{aligned}
 s^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}' &= s^2(c_{22} + c_{23} + c_{32} + c_{33}) \\
 &= s^2(c_{22} + 2c_{23} + c_{33}) \\
 &= \text{var}(\hat{\beta}_2) + 2\text{cov}(\hat{\beta}_2, \hat{\beta}_3) + \text{var}(\hat{\beta}_3) \\
 &= \text{var}(\hat{\beta}_2 + \hat{\beta}_3)
 \end{aligned} \tag{16}$$

- Logo,

$$\frac{(\hat{\beta}_2 + \hat{\beta}_3 - 1)' [\text{var}(\hat{\beta}_2 + \hat{\beta}_3)]^{-1} (\hat{\beta}_2 + \hat{\beta}_3 - 1)}{1} = \frac{(\hat{\beta}_2 + \hat{\beta}_3 - 1)^2}{\text{var}(\hat{\beta}_2 + \hat{\beta}_3)}$$

que segue $\sim F(1, n - k)$.

- Tirando a raiz quadrada, temos:

$$\frac{\hat{\beta}_2 + \hat{\beta}_3 - 1}{d.p.(\hat{\beta}_2 + \hat{\beta}_3)} \sim t(n - k) \quad (17)$$

Caso Geral

- Generalizando, testamos a hipótese nula $H_0: \beta_2 = \beta_3 = \dots = \beta_k = \mathbf{0}$.
- Assim,

$$R\hat{\beta} - c = \begin{bmatrix} \hat{\beta}_2 \\ \hat{\beta}_3 \\ \vdots \\ \hat{\beta}_k \end{bmatrix} = \hat{\beta} \quad (18)$$

- Desse modo,

$$\begin{aligned}
 s^2 \mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}' &= \\
 &= s^2 \begin{bmatrix} 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{bmatrix} \begin{bmatrix} c_{11} & c_{21} & c_{31} & \cdots & c_{k1} \\ c_{12} & c_{22} & c_{32} & \cdots & c_{k2} \\ c_{13} & c_{23} & c_{33} & \cdots & c_{k3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ c_{1k} & c_{2k} & c_{3k} & \cdots & c_{kk} \end{bmatrix} \begin{bmatrix} 0 & 0 & \cdots & 0 \\ 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} \\
 &= s^2 \begin{bmatrix} c_{22} & \cdots & c_{k2} \\ \vdots & . & \vdots \\ c_{2k} & \vdots & c_{kk} \end{bmatrix} \\
 &= s^2 \mathbf{C}
 \end{aligned} \tag{19}$$

- A estatística de teste é dada por:

$$F = \frac{\widehat{\boldsymbol{\beta}}'(s^2\mathbf{C})^{-1}\widehat{\boldsymbol{\beta}}}{k-1} \sim F(k-1, n-k) \quad (20)$$

ou

$$F = \frac{\widehat{\boldsymbol{\beta}}'\widehat{\boldsymbol{\beta}}}{(s^2\mathbf{C})(k-1)} \sim F(k-1, n-k) \quad (21)$$

Omissão de Variáveis Relevantes

- Suponha que o modelo verdadeiro seja

$$\mathbf{y} = \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{X}_2\boldsymbol{\beta}_2 + \mathbf{e} \quad (22)$$

- Porém o modelo estimado foi

$$\mathbf{y} = \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{e} \quad (23)$$

ou seja, estima-se um modelo caracterizado pela omissão de um conjunto de variáveis relevantes \mathbf{X}_2 .

- O estimador de mínimos quadrados para eq. (23) é dado por:

$$\begin{aligned} \hat{\boldsymbol{\beta}}_1 &= (\mathbf{X}_1'\mathbf{X}_1)^{-1}\mathbf{X}_1'\mathbf{y} \\ &= (\mathbf{X}_1'\mathbf{X}_1)^{-1}\mathbf{X}_1'(\mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{X}_2\boldsymbol{\beta}_2 + \mathbf{e}) \\ &= \boldsymbol{\beta}_1 + (\mathbf{X}_1'\mathbf{X}_1)^{-1}\mathbf{X}_1'\mathbf{X}_2\boldsymbol{\beta}_2 + (\mathbf{X}_1'\mathbf{X}_1)^{-1}\mathbf{X}_1'\mathbf{e} \end{aligned} \quad (24)$$

- Tomando o valor esperado, temos:

$$\mathbb{E}(\hat{\beta}_1) = \beta_1 + (\mathbf{X}'_1 \mathbf{X}_1)^{-1} \mathbf{X}'_1 \mathbf{X}_2 \beta_2 \quad (25)$$

- Vemos que $\hat{\beta}_1$ será viesado. Isso só não ocorre se $\mathbf{X}_1 \mathbf{X}_2 = \mathbf{0}$. Isto é, se os regressores incluídos no modelo sejam ortogonais aos regressores omitidos.
- **Se algumas variável relevante for omitida do modelo, e se a correlação dessa variável com as variáveis incluídas no modelo não for zero, então o estimador de Mínimos Quadrados será viesado.**
- Na prática, é improvável que os regressores sejam ortogonais, de forma que deve-se esperar que a omissão de variáveis relevantes gere estimativas viesadas.

- O sinal do viés será determinado pelo sinal da covariância entre $\mathbf{X}'_1\mathbf{X}_2$ e β_2 . Temos as seguintes possibilidades:
 - 1 Se $\mathbf{X}'_1\mathbf{X}_2 > 0$ e $\beta_2 > 0$: o sinal do viés será positivo;
 - 2 Se $\mathbf{X}'_1\mathbf{X}_2 < 0$ e $\beta_2 < 0$: o sinal do viés será positivo;
 - 3 Se $\mathbf{X}'_1\mathbf{X}_2 > 0$ e $\beta_2 < 0$: o sinal do viés será negativo;
 - 4 Se $\mathbf{X}'_1\mathbf{X}_2 < 0$ e $\beta_2 > 0$: o sinal do viés será negativo;

Viés de Omissão e Variância

- O que acontece com a **variância do estimador de mínimos quadrados** ao omitirmos variáveis relevantes?
- A variância do estimador de mínimos quadrados no modelo dado pela eq. (23) é dada por:

$$\text{var}(\hat{\beta}_1) = \sigma^2 (\mathbf{X}'_1 \mathbf{X}_1)^{-1} \quad (26)$$

- Caso fosse estimado o modelo verdadeiro dado pela eq. (22), a variância seria:

$$\begin{aligned} \text{var}(\hat{\beta}_{1,2}) &= \sigma^2 (\mathbf{X}'_1 \mathbf{M}_2 \mathbf{X}_1)^{-1} \\ &= \sigma^2 \left[\mathbf{X}'_1 \mathbf{X}_1 - \mathbf{X}'_1 \mathbf{X}_2 (\mathbf{X}'_2 \mathbf{X}_2)^{-1} \mathbf{X}'_2 \mathbf{X}_1 \right]^{-1} \end{aligned} \quad (27)$$

em que $\mathbf{M}_2 = \mathbf{I} - \mathbf{X}_2 (\mathbf{X}'_2 \mathbf{X}_2)^{-1} \mathbf{X}'_2$.

- Podemos comparar as duas matrizes de variância comparando as suas inversas.

$$\text{var}(\hat{\beta}_1) - \text{var}(\hat{\beta}_{1.2}) = \left(\frac{1}{\sigma^2}\right) \mathbf{X}'_1 \mathbf{X}_2 (\mathbf{X}'_2 \mathbf{X}_2)^{-1} \mathbf{X}'_2 \mathbf{X}_1 \quad (28)$$

que é uma matriz positiva definida. O $\hat{\beta}_1$ é viesado, porém ele possui menor variância do que $\hat{\beta}_{1.2}$.

- A inversa da variância de $\hat{\beta}_1$ é maior que a inversa da variância de $\hat{\beta}_{1.2}$. Ou seja, a variância de $\hat{\beta}_1$ é menor que a variância de $\hat{\beta}_{1.2}$.
- Outro problema diz respeito à estimação de σ^2 que é necessária para realização de inferências (teste de hipótese e intervalos de confiança). O estimador usual é dado por:

$$s^2 = \frac{e'e}{n - k} \quad (29)$$

- Podemos mostrar que esse estimador também é viesado. Note que

$$\mathbf{e}_1 = \mathbf{M}_1 \mathbf{y} = \mathbf{M}_1 (\mathbf{X}_1 \boldsymbol{\beta}_1 + \mathbf{X}_2 \boldsymbol{\beta}_2 + \mathbf{e}) = \mathbf{M}_1 \mathbf{X}_2 \boldsymbol{\beta}_2 + \mathbf{M}_1 \mathbf{e} \quad (30)$$

- Para obter o valor esperado de $\mathbf{e}'_1 \mathbf{e}_1$, usamos a mesma abordagem anterior e consideramos $\mathbb{E}[\mathbf{X}'_1 \mathbf{e}] = 0$. Assim obtemos:

$$\begin{aligned} \mathbb{E}[\mathbf{e}'_1 \mathbf{e}_1] &= \boldsymbol{\beta}'_2 \mathbf{X}'_2 \mathbf{M}_1 \mathbf{X}_2 \boldsymbol{\beta}_2 + \sigma^2 \text{tr}(\mathbf{M}_1) \\ &= \boldsymbol{\beta}'_2 \mathbf{X}'_2 \mathbf{M}_1 \mathbf{X}_2 \boldsymbol{\beta}_2 + (n - k) \sigma^2 \end{aligned} \quad (31)$$

- O primeiro termo é positivo, tal que s^2 é viesado para cima, não sendo possível estimar σ^2 . Portanto, não é possível testar hipóteses sobre o vetor de coeficientes $\boldsymbol{\beta}_1$.
- Conclusão:** se omitirmos variáveis relevantes da regressão, então obtemos estimativas para $\boldsymbol{\beta}_1$ e σ^2 viesadas!

- Suponha que o modelo verdadeiro seja

$$\mathbf{y} = \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{e} \quad (32)$$

- Porém o modelo estimado foi

$$\begin{aligned} \mathbf{y} &= \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{X}_2\boldsymbol{\beta}_2 + \mathbf{e} \\ &= \mathbf{X}\boldsymbol{\beta} + \mathbf{e} \end{aligned} \quad (33)$$

em que $\mathbf{X} = \begin{bmatrix} \mathbf{X}_1 & \mathbf{X}_2 \end{bmatrix}$ e $\boldsymbol{\beta} = \begin{bmatrix} \boldsymbol{\beta}_1 \\ \boldsymbol{\beta}_2 \end{bmatrix}$.

- Nesse caso, o estimador de mínimos quadrados é dado pela fórmula usual, e **não é viesado**:

$$\begin{aligned}\hat{\beta} &= (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{y} \\ &= \beta + (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{e}\end{aligned}\tag{34}$$

- Note que

$$\mathbb{E}(\hat{\beta}) = \beta = \begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix} = \begin{bmatrix} \beta_1 \\ \mathbf{0} \end{bmatrix}\tag{35}$$

- Da mesma forma, a variância do estimador de mínimos quadrados é dada pela fórmula usual e **também não é viesada**.
- Tais resultados parecem indicar que a inclusão de variáveis irrelevantes não causa nenhum problema de estimação. Porém, **essa conclusão está errada!!**

- É importante pensar que temos duas situações:
 - ① Estimar um modelo omitindo uma variável relevante equivale a impor uma restrição falsa (restrição de que o coeficiente da variável é zero).
 - ② Estimar um modelo incluindo uma variável irrelevante equivale a deixar de impor uma restrição verdadeira (restrição de que o coeficiente da variável é zero).
- O custo da segunda situação é a **perda de precisão da estimação**. Conforme vimos, a variância do estimador de mínimos quadrados aumenta com a inclusão de novas variáveis explicativas.

Variável Proxy

- Considere um modelo que assume um efeito aditivo da variável omitida dado por:

$$\mathbb{E}(y|x_1, x_2, \dots, x_k, q) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \gamma q \quad (36)$$

em que q é um fator omitido. Estamos interessados em β_j que são os efeitos parciais das variáveis explicativas observáveis.

- Observando a eq. (36) como um modelo estrutural, podemos escrever na forma de erro como:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \gamma q + \nu \quad (37)$$

$$\mathbb{E}(\nu|x_1, x_2, \dots, x_k, q) = 0 \quad (38)$$

em que ν é o **erro estrutural**.

- Uma forma de manusear o aspecto não observável de q é incorporar ele dentro do termo de erro. Assim, podemos reescrever a eq. (37) como

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + u \quad (39)$$

$$u = \gamma q + \nu \quad (40)$$

- O termo de erro u consiste de duas partes. Sob a eq. (38), ν tem média zero e é não correlacionado com x_1, x_2, \dots, x_k, q . Pela normalização, q também tem média zero.
- Assim, $\mathbb{E}(u) = 0$. Mas u é não correlacionado com x_j apenas se q é não correlacionado com x_j . Se q for correlacionado com algum dos regressores, o erro u também será, e teremos um problema de endogeneidade. Não podemos esperar estimativas consistentes de mínimos quadrados para β_j .
- Assim, o estimador de mínimos quadrados na presença de variável omitida é inconsistente ou estimador de mínimos quadrados é viesado.

- O viés de variável omitida pode ser eliminado ou no mínimo mitigado se é possível usar uma **variável proxy** par a variável não observada q .
- Para o uso de uma **variável proxy**, duas condições devem ser cumpridas:
 - A **variável proxy** deveria ser redundante (irrelevante) na equação estrutural;
 - A correlação entre a variável omitida q e cada x deve ser zero depois de controlarmos para z .

Condição (1)

Se z é uma variável proxy para q , então devemos esperar a redundância de z na eq. (41):

$$\mathbb{E}(y|\mathbf{x}, q, z) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + \gamma q + \delta z \quad (41)$$

isto é,

$$\mathbb{E}(y|\mathbf{x}, q, z) = \mathbb{E}(y|\mathbf{x}, q) \quad (42)$$

- Essa condição é fácil de interpretar: z é irrelevante para explicar y no sentido de média condicional, uma vez que \mathbf{x} e q tenham sido utilizados. Embora seja difícil de verificar isso, não podemos ir muito longe sem essa condição!

Condição (2)

É uma condição mais complicada. Requer que a correlação entre a variável omitida q e cada x_j seja zero uma vez que retiramos z . Podemos ver isso em termos da projeção linear:

$$\mathbb{P}(q|1, x_1, x_2, \dots, x_k, z) = \mathbb{P}(q|z) \quad (43)$$

É útil ver essa relação em termos de uma equação com o componente de erro não observado. Considere q como uma função linear de z e um termo de erro como:

$$q = \theta_0 + \theta_1 z + r, \quad (44)$$

em que, por definição, $\mathbb{E}(r) = 0$ e a $\text{cov}(z, r) = 0$ por conta de que $\theta_0 + \theta_1 z$ é uma projeção linear de \mathbf{q} em $\mathbf{1}, z$.

- Se z é uma *proxy* razoável para q , $\theta_1 \neq 0$. Porém, a condição é mais forte: ela é equivalente a

$$\text{cov}(x_j, r) = 0 \quad (45)$$

para $j = 1, 2, \dots, k$.

- Esta condição requer que z seja próximo o suficiente e relacionado a q tal que, uma vez ele incluído, os x_j não são parcialmente correlacionados com q .
- A definição de **variável proxy** aqui não é universal. Enquanto assumimos que a **variável proxy** está satisfazendo a condição de redundância (41), nem sempre assumimos satisfazer a segunda condição.

- Para obter uma equação estimável, substituímos q na eq. (44) com a eq. (41) para obter:

$$y = (\beta_0 + \gamma\theta_0) + \beta_1x_1 + \beta_2x_2 + \cdots + \beta_kx_k + \gamma\theta_1z + (\gamma r + \nu) \quad (46)$$

- Sob o pressuposto feito, o termo de erro composto $u = \gamma r + \nu$ é não correlacionado com x_j para todo j ; redundância de z significa que z é não correlacionado com ν e, por definição, z é não correlacionado com r .
- Disso teremos que: a regressão de mínimos quadrados de y em $1, x_1, x_2, \dots, x_k, z$ produz estimadores consistentes de $(\beta_0 + \gamma\theta_0)$, $\beta_1, \beta_2, \dots, \beta_k$ e $\gamma\theta_1$.
- Assim, podemos estimar os efeitos parciais de cada x_j sob o pressuposto da **variável proxy**.

Variável *Proxy* Imperfeita

- Quando z é uma variável *proxy* imperfeita, então r na eq. (46) é correlacionada com um ou mais dos x_j . Assim, a projeção linear passa a ser:

$$q = \theta_0 + \rho_1 x_1 + \rho_2 x_2 + \cdots + \rho_k x_k + \theta_1 z + r, \quad (47)$$

a regressão da variável *proxy* resulta em $\text{plim } \hat{\beta}_j = \beta_j + \gamma \rho_j$. O estimador de mínimos quadrados com uma variável *proxy* imperfeita é inconsistente.

- A esperança é que ρ_j seja menor do que se z fosse omitido da projeção linear.

Variável *proxy* imperfeita

- Se a inclusão da variável *proxy* z induz a uma substancial colinearidade, deve ser melhor usar o estimador de mínimos quadrados sem a variável *proxy*.
- É importante considerar que incluir z reduz a variância do erro se $\theta_1 \neq 0$: $\text{var}(\gamma r + \nu) < \text{var}(\gamma q + \nu)$ porque $\text{var}(r) < \text{var}(q)$, e ν é não correlacionado com r e q .
- **Incluir uma variável *proxy* pode reduzir a variância assintótica bem como mitigar o viés.**

Exemplo

- Vamos aplicar o método da variável *proxy* para estimar o modelo estrutural

$$\log(\text{wage}) = \beta_0 + \beta_1 \text{exper} + \beta_2 \text{tenure} + \beta_3 \text{casado} + \beta_4 \text{sul} + \\ \beta_5 \text{urbana} + \beta_6 \text{black} + \beta_7 \text{escolaridade} + \gamma \text{habil} + \nu$$

- Assumimos que QI satisfaz o pressuposto de variável *proxy*: em um modelo de projeção linear

$$\text{habil} = \theta_0 + \theta_1 QI + r$$

em que $\mathbb{E}(r) = 0$ e $\mathbb{E}(QI, r) = 0$. Assumimos que r seja não correlacionado com todos os regressores da eq. de salários, $\mathbb{E}(r|\mathbf{x}) = 0$.

- A equação estimada **sem a variável *proxy* QI** é dada por

$$\begin{aligned} \log wage = & 5.40 + 0.014exper + 0.012tenure + 0.199casado \\ & (0.11) \quad (0.003) \quad (0.002) \quad (0.039) \\ & - 0.091sul + 0.184urbana - 0.188black \\ & (0.026) \quad (0.027) \quad (0.38) \\ & + 0.065escolaridade \\ & (0.008) \end{aligned}$$

- A equação estimada **com a variável *proxy* QI** é dada por

$$\begin{aligned} \log wage = & 5.18 + 0.014exper + 0.011tenure + 0.200casado \\ & (0.13) \quad (0.003) \quad (0.002) \quad (0.039) \\ & - 0.080sul + 0.182urbana - 0.143black \\ & (0.026) \quad (0.027) \quad (0.39) \\ & + 0.054escolaridade + 0.0036QI \\ & (0.007) \quad (0.0010) \end{aligned}$$

ECONOMETRIA I

TESTE DE HIPÓTESES LINEARES

Victor Oliveira

Núcleo de Economia Internacional e Desenvolvimento Econômico

PPGDE – 2023